

**ESTIMASI PEMETAAN KEMISKINAN DENGAN DEEP
LEARNING PADA BIG DATA FUSI CITRA SATELIT
MULTISUMBER DAN POINT OF INTEREST**

(Studi Kasus: Provinsi Jawa Timur)

SALWA RIZQINA PUTRI

221810596

**PROGRAM STUDI : KOMPUTASI STATISTIK PROGRAM DIV
PEMINATAN : SAINS DATA**



POLITEKNIK STATISTIKA STIS

JAKARTA

2022

**ESTIMASI PEMETAAN KEMISKINAN DENGAN DEEP
LEARNING PADA BIG DATA FUSI CITRA SATELIT
MULTISUMBER DAN POINT OF INTEREST**

(Studi Kasus: Provinsi Jawa Timur)

SALWA RIZQINA PUTRI

221810596

**PROGRAM STUDI : KOMPUTASI STATISTIK PROGRAM DIV
PEMINATAN : SAINS DATA**



**POLITEKNIK STATISTIKA STIS
JAKARTA
2022**

**ESTIMASI PEMETAAN KEMISKINAN DENGAN DEEP
LEARNING PADA BIG DATA FUSI CITRA SATELIT
MULTISUMBER DAN POINT OF INTEREST
(Studi Kasus: Provinsi Jawa Timur)**

SKRIPSI

**Diajukan sebagai Salah Satu Syarat untuk Memperoleh Sebutan
Sarjana Sains Terapan pada Politeknik Statistika STIS**

Oleh:

SALWA RIZQINA PUTRI

221810596



POLITEKNIK STATISTIKA STIS

JAKARTA

2022

PERNYATAAN

Skripsi dengan Judul

ESTIMASI PEMETAAN KEMISKINAN DENGAN DEEP

LEARNING PADA BIG DATA FUSI CITRA SATELIT

MULTISUMBER DAN POINT OF INTEREST

(Studi Kasus: Provinsi Jawa Timur)

Oleh:

SALWA RIZQINA PUTRI

221810596

adalah benar – benar hasil penelitian sendiri dan bukan hasil plagiat atau hasil karya orang lain. Jika di kemudian diketahui ternyata skripsi ini hasil plagiat atau hasil karya orang lain, penulis bersedia skripsi ini dinyatakan tidak sah dan sebutan Sarjana Terapan dicabut atau dibatalkan.

Jakarta, 5 Juli 2022

Salwa Rizqina Putri

**ESTIMASI PEMETAAN KEMISKINAN DENGAN DEEP
LEARNING PADA BIG DATA FUSI CITRA SATELIT
MULTISUMBER DAN POINT OF INTEREST
(Studi Kasus: Provinsi Jawa Timur)**

Oleh:

**SALWA RIZQINA PUTRI
221810596**

Tim Penguji

Penguji I :

Setia Pramana, Ph.D
NIP 197707222000031002

Penguji II :

Dr. Eng. Lya Hulliyyatus Suada SST., MT.
NIP 198902072010122001

Mengetahui/Menyetujui

Program Diploma IV
Ketua Program Studi Komputasi Statistik

Pembimbing

Yunarso Anang, Ph.D
NIP 197006161988121001

Dr. Eng. Arie Wahyu Wijayanto, SST., M.T.
NIP 198512222009021002

© **Hak Cipta milik Politeknik Statistika STIS, Tahun 2022**

Hak Cipta dilindungi undang-undang

- *Dilarang mengutip sebagian atau seluruh karya tulis, hasil analisis, perancangan, basis data, program, dan artefak hasil skripsi ini tanpa mencantumkan atau menyebutkan sumbernya.*
 - *Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik atau tinjauan suatu masalah.*
 - *Pengutipan tidak merugikan kepentingan yang wajar Politeknik Statistika STIS.*
- *Dilarang mengumpulkan dan memperbanyak sebagian atau seluruh karya tulis, hasil analisis, perancangan, basis data, program, dan artefak hasil skripsi ini dalam bentuk apapun*

PRAKATA

Syukur Alhamdulillah penulis ucapkan ke hadirat Allah SWT, akhirnya hanya berkat pertolongan-Nya penulis dapat menyelesaikan skripsi yang berjudul “Estimasi Pemetaan Kemiskinan dengan *Deep Learning* Pada *Big Data* Fusi Citra Satelit Multisumber dan *Point of Interest* (Studi Kasus: Provinsi Jawa Timur)”. Untuk itu penulis mengucapkan terima kasih kepada:

1. Ibu Dr. Erni Tri Astuti selaku Direktur Politeknik Statistika STIS,
2. Bapak Yunarso Anang Sulistiadi, Ph.D., selaku Ketua Program Studi D-IV Komputasi Statistik Politeknik Statistika STIS,
3. Bapak Dr. Eng Arie Wahyu Wijayanto, SST., MT. selaku dosen pembimbing yang telah membimbing dengan sepenuh hati dalam penyusunan skripsi ini,
4. Bapak Setia Pramana Ph.D dan Ibu Dr. Eng. Lya Hulliyyatus Suadaa SST., MT. selaku dosen penguji yang telah memberikan koreksi dan saran,
5. Ayah, Ibu, dan Hafidz serta seluruh keluarga besar penulis,
6. Teman-teman (Nasiya, Yoga, Tata, Widya, Rifqi, Talitha, Rifja, Hani, *Bimbelholics* 60, Asugrejo 60) yang setia membersamai penulis dalam penggarapan skripsi ini.

Penulis menyiari bahwa skripsi ini masih mempunyai banyak kekurangan baik dari sisi substansi maupun penyusunannya. Saran dan masukan sangat penulis harapkan. Semoga skripsi ini dapat bermanfaat bagi banyak pihak.

Jakarta, 5 Juli 2022

Salwa Rizqina Putri

ABSTRAK

SALWA RIZQINA PUTRI, "Estimasi Pemetaan Kemiskinan dengan *Deep Learning* Pada *Big Data* Fusi Citra Satelit Multisumber Dan *Point of Interest* (Studi Kasus: Provinsi Jawa Timur)".

x+147 halaman

Untuk mendukung target pengentasan kemiskinan pemerintah, diperlukan penyajian data alternatif estimasi kemiskinan yang lebih granular dalam cakupan wilayah dan dapat diperbarui dengan waktu dan biaya yang lebih rendah sehingga dapat melengkapi keterbatasan data kemiskinan resmi. Penelitian ini bertujuan untuk membangun estimasi pemetaan kemiskinan pada level grid 1,5 km berdasarkan *big data* fusi citra satelit multisumber dan *point of interest* (POI). Hasil yang diperoleh menunjukkan bahwa 1) *Relative Spatial Poverty Index* (RSPI) yang dibangun dapat memetakan daerah terdeprivasi spasial di Jawa Timur dan berkorelasi kuat dengan kemiskinan resmi, 2) telah dibangun model terbaik estimasi kemiskinan dengan *big data* fusi citra satelit multisumber dan POI mengimplementasikan ekstraksi fitur *zonal statistics* yaitu CNN-1D dan model terbaik estimasi kemiskinan dengan citra satelit siang dan malam hari mengimplementasikan ekstraksi fitur *transfer learning* yaitu Resnet-34 + MLP, 3) hasil estimasi pemetaan kemiskinan yang dibangun dengan model CNN-1D berdasarkan *big data* fusi citra satelit multisumber dan POI dipilih sebagai peta kemiskinan terbaik dengan RMSE 1,95, MAE 1,61, MAPE 19,99%, korelasi Pearson 0,94, dan *adjusted R²* 0,84 berdasarkan data kemiskinan resmi level kabupaten/kota, 4) telah dibangun *map dashboard* interaktif berbasis *website* untuk memudahkan pemangku kepentingan dalam memanfaatkan hasil penelitian. Integrasi hasil penelitian dengan data kemiskinan resmi diharapkan dapat mendukung pengambilan keputusan terkait pengentasan kemiskinan di Indonesia.

Kata kunci: kemiskinan, *big data*, citra satelit multisumber, *point of interest*, *deep learning*.

DAFTAR ISI

PRAKATA	i
ABSTRAK	ii
DAFTAR ISI.....	iii
DAFTAR TABEL.....	v
DAFTAR GAMBAR	v
DAFTAR LAMPIRAN	vii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Identifikasi dan Rumusan Masalah.....	7
1.3 Tujuan Penelitian	8
1.4 Manfaat Penelitian	8
1.5 Cakupan dan Batasan Penelitian.....	11
1.6 Sistematika Penulisan	12
BAB II KAJIAN PUSTAKA	15
2.1 Landasan Teori.....	15
2.2 Penelitian Terkait	38
BAB III METODOLOGI.....	43
3.1 Ruang Lingkup Penelitian.....	43
3.2 Metode Penelitian	44
3.3 Kerangka Penelitian	69
BAB IV HASIL DAN PEMBAHASAN	72
4.1 Hasil Pembangunan Indeks Kemiskinan Spasial Relatif	72
4.1.3 Hasil Penghitungan Indeks RSPI	85
4.1.4 Hasil Evaluasi RSPI.....	87
4.2 Hasil Pembangunan Model Estimasi Kemiskinan.....	91
4.3 Pembangunan dan Evaluasi Peta Kemiskinan Level Grid 1,5 km..	107
4.4 Hasil Pembangunan <i>Dashboard</i> Visualisasi Hasil Penelitian	114
BAB V KESIMPULAN DAN SARAN.....	124
5.1 Kesimpulan	124
5.2. Saran.....	126

DAFTAR PUSTAKA.....	128
LAMPIRAN	139
RIWAYAT HIDUP	150

DAFTAR TABEL

No. Tabel	Judul Tabel	Halaman
1.	Pita Spektral Citra Satelit VIIRS Stray Light Corrected Nighttime Day/Night Band Composites Version 1	23
2.	Pita Spektral Citra Satelit Sentinel-2 MSI Level-2A	24
3.	Pita Spektral Citra Satelit MOD11A1.061 Terra Land Surface Temperature and Emissivity Daily Global 1km	27
4.	Penelitian Terdahulu yang Memanfaatkan <i>Big Data</i> Citra Satelit Multisumber dan POI untuk Pemetaan Kemiskinan	41
5.	Data yang Digunakan pada Penelitian	47
6.	Quality Assessment Band Satelit Sentinel-2 dan MODIS	53
7.	Arsitektur Resnet-34	60
8.	Koefisien Korelasi dan Interpretasinya (Sugiyono, 2010)	63
9.	Hasil Analisis Korelasi Variabel Geospasial dan Kemiskinan Resmi	83
10.	Hasil Penghitungan Bobot RSPI.....	85
11.	Analisis Korelasi RSPI dengan Kemiskinan Resmi Level Kabupaten	88
12.	Evaluasi Numerik RSPI	88
13.	Pemilihan Parameter/Hyperparameter Model Machine Learning	94
14.	Arsitektur CNN Model Estimasi Dataset 1 (Citra Satelit Multisumber dan POI)	95
15.	Hasil Evaluasi 5-Cross Validation Pembangunan Model Berdasarkan Dataset 1 (Citra Satelit Multisumber Dan POI)	95
16.	Hasil Agregasi Rata-Rata Hasil Evaluasi 5-Fold Cross Validation pada Pembangunan Model Kemiskinan Dataset 1	98
17.	Perbandingan Akurasi Model dengan Fitur Lengkap dan Fitur Hasil Seleksi	99

18.	Pemilihan <i>Parameter/Hyperparameter</i> Pembangunan Model <i>Dataset 2</i> (Citra Satelit Siang dan Malam Hari)	102
19.	Arsitektur CNN Model Estimasi Dataset 2 (Citra Satelit Siang dan Malam Hari).....	104
20.	Hasil Evaluasi <i>5-fold Cross Validation</i> Pembangunan Model Berdasarkan <i>Dataset 2</i> (Citra Satelit Siang dan Malam Hari)	104
21.	Hasil Evaluasi Rata-Rata 5-Fold Cross Validation	107
22.	Hasil Evaluasi Numerik pada Level Kecamatan dan Kabupaten	109
23.	Hasil Penghitungan Korelasi dan Koefisien Determinasi Hasil Pemetaan Model Terbaik	111

DAFTAR GAMBAR

No. Gambar	Judul Tabel	Halaman
1.	Perkembangan Persentase dan Jumlah Penduduk Miskin Indonesia.....	2
2.	Target Pengentasan Kemiskinan Indonesia	4
3.	Arsitektur MLP	35
4.	Bagian Utama CNN	35
5.	Konvolusi pada CNN-1D.....	37
6.	Visualisasi Arsitektur ResNet-34.....	38
7.	Peta Literatur.....	39
8.	Provinsi Jawa Timur sebagai Wilayah Studi dan Angka Kemiskinan Resmi Level Kabupatennya	43
9.	Diagram Alir Penelitian	50
10.	Diagram Alir Pengumpulan dan Preprocessing Data.....	52
11.	Visualisasi Citra yang Banyak Tertutup Awan (kiri) dan Citra yang Sudah Melalui Tahap <i>Cloud Selection</i> dan <i>Cloud Masking</i> serta <i>Median Reducing</i> (kanan).....	53
12.	Visualisasi data raster yang diperoleh: NTL (nanowatts/cm ² /sr), NDVI (indeks), BUI (indeks), NDWI (indeks), LST (Kelvin), CO (mol/m ²), NO ₂ (mol/m ²), and SO ₂ (mol/m ²).....	54
13.	Visualisasi data yang diperoleh dari POI.....	55
14.	Citra Satelit Siang Hari (RGB) Jawa Timur	56
15.	Citra Siang Hari yang Sudah Dipotong dan Diaugmentasi.....	57
16.	Kemiskinan Resmi Level Kabupaten (kanan) dan Kemiskinan Level Kecamatan Hasil SAE.....	58
17.	Arsitektur Resnet-34 dengan <i>Fully Connected Layer</i> yang Diekstrak.....	60

18.	Visualisasi Pembangunan Model Estimasi Kemiskinan	66
19.	Kerangka Penelitian.....	69
20.	Identifikasi Visual NTL.....	74
21.	Identifikasi Visual NDVI	75
22.	Identifikasi Visual BUI.....	76
23.	Identifikasi Visual NDWI.....	77
24.	Identifikasi Visual LST	78
25.	Identifikasi Visual CO	79
26.	Identifikasi Visual NO ₂	79
27.	Identifikasi Visual SO ₂	80
28.	Visualisasi Data Citra Satelit Multisumber di Level Kabupaten.....	81
29.	Visualisasi Data POI dan Kemiskinan di Level Kabupaten	82
30.	Visualisasi RSPI ₁	86
31.	Visualisasi RSPI ₂	87
32.	Hasil Identifikasi Visual RSPI.....	90
33.	Perbandingan Visual RSPI dengan Kemiskinan Resmi Level Kabupaten	91
34.	Visualisasi Data a) POI <i>Density</i> , b) POI <i>Distance</i> , dan c) Kemiskinan Hasil SAE pada Level Kecamatan	92
35.	Visualisasi Data a) NTL, b) NDVI, c) BUI, d) NDWI, e) LST, f) CO, g) NO ₂ , dan h) SO ₂ pada Level Kecamatan	93
36.	Visualisasi Evaluasi pada 5-Fold Cross Validation Pembangunan Model Berdasarkan <i>Dataset 1</i> (Citra Satelit Multisumber dan POI)	97
37.	Hasil Penghitungan <i>Feature Importance</i> pada a) Model DTR dan b) Model RFR.....	98
38.	<i>Confusion Matrix</i> Model Resnet-34 pada Data <i>Test</i>	101

39.	Visualisasi evaluasi pada <i>5-fold cross validation</i> pembangunan model berdasarkan <i>Dataset 2</i> (citra satelit siang dan malam hari)	106
40.	Estimasi Pemetaan Kemiskinan yang Dibangun Berdasarkan Model CNN-1D Dengan <i>Dataset 1</i>	108
41.	Estimasi Pemetaan Kemiskinan yang Dibangun Berdasarkan Model Resnet-34 + MLP Dengan <i>Dataset 2</i>	108
42.	<i>Scatter Plot</i> Hasil Estimasi Kemiskinan	110
43.	Visualisasi Hasil Estimasi Kemiskinan pada Level Kecamatan dan Kabupaten	112
44.	Evaluasi Deskriptif Hasil Estimasi Pemetaan Kemiskinan.....	113
45.	<i>Map Dashboard</i> 2D RSPI	115
46.	<i>Map Dashboard</i> 2D Estimasi Kemiskinan	115
47.	Visualisasi Penggunaan Fitur Hover.....	116
48.	Visualisasi Penggunaan Fitur <i>Zoom</i>	117
49.	Visualisasi Penggunaan Fitur Legenda	118
50.	Visualisasi Identifikasi Visual <i>Google Satellite</i> dengan Fitur Legenda..	118
51.	Visualisasi Identifikasi Wilayah Google Maps dengan Fitur Legenda...	119
52.	Visualisasi Penggunaan Fitur <i>Measure Distance</i>	119
53.	Visualisasi Penggunaan Fitur Search	120
54.	Visualisasi Penggunaan Fitur <i>Search</i> untuk Estimasi Kemiskinan di Sekitar Titik Tertentu	120
55.	<i>Map Dashboard</i> 3D RSPI	121
56.	<i>Map Dashboard</i> 3D Estimasi Kemiskinan	121
57.	Hasil Implementasi Fitur <i>Zoom</i> , <i>Rotate</i> , dan <i>Orbit Map Dashboard</i> 3D	122
58.	Hasil Implementasi Fitur <i>Grid Info</i>	123
59.	Hasil Implementasi Fitur <i>Measure Distance</i> <i>Map Dashboard</i> 3D	123

DAFTAR LAMPIRAN

No. Gambar	Judul Lampiran	Halaman
1.	Source Code Pengumpulan Data Satelit NOAA-VIIRS.....	139
2.	<i>Source Code</i> Pengumpulan Data Satelit Sentinel-2	139
3.	<i>Source Code</i> Pengumpulan Data Satelit MODIS	140
4.	<i>Source Code</i> Pengumpulan Data Satelit Sentinel-5P	141
5.	Source Code Resnet-34 Feature Extraction.....	142
6.	<i>Source Code</i> Pembangunan Model <i>Support Vector Regression</i> (SVR)..	145
7.	Source Code Pembangunan Model Decision Tree Regression (DTR)....	146
8.	Source Code Pembangunan Model Random Forest Regression (RFR)..	146
9.	Source Code Pembangunan Model Multiple Layer Perceptron (MLP) ..	147
10.	Source Code Pembangunan Model Convolutional Neural Network – 1D (CNN-1D).....	148

BAB I

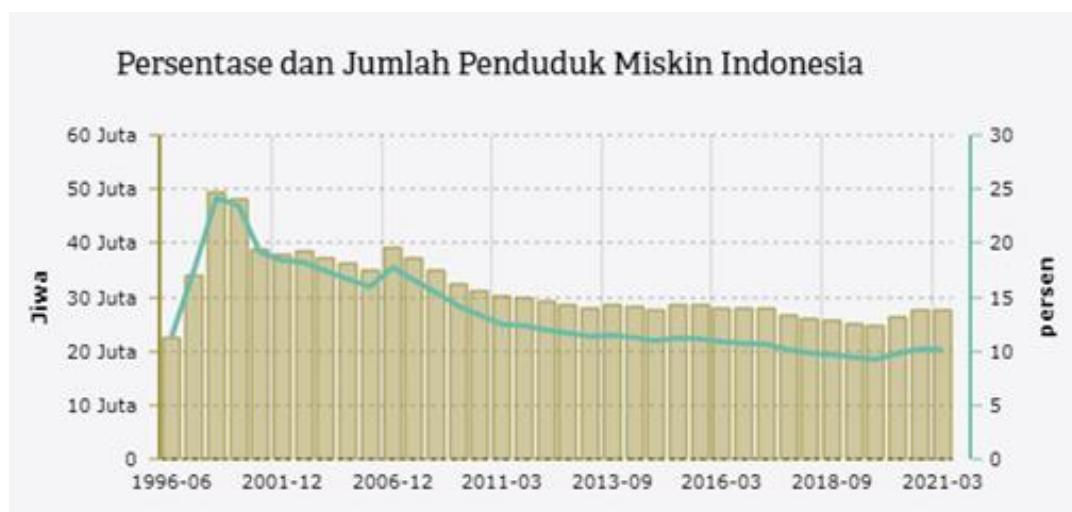
PENDAHULUAN

1.1 Latar Belakang

Kemiskinan merupakan masalah kompleks dan merupakan dampak dari konsep politik yang memerlukan tindakan khusus dalam penanganannya (Alcock, 1997). Menurut Bank Dunia, kemiskinan didefinisikan sebagai kondisi hilangnya kesejahteraan (*deprivation of well-being*) (World Bank, 2009). Kemiskinan menjadi masalah historis yang hampir semua negara belum mampu menyelesaiannya dengan tuntas (PBB, 2015). Menurut Perserikatan Bangsa Bangsa (PBB), terdapat sekitar 8,2% orang di dunia yang hidup dalam kemiskinan pada tahun 2019 (PBB, 2020). Untuk mengatasi masalah kemiskinan, PBB mengusulkan pengentasan kemiskinan atau ‘*end poverty in all its forms everywhere*’ sebagai tujuan pertama *Sustainable Development Goals* (SDGs) yang diharapkan tercapai pada tahun 2030 (PBB, 2015). Sebagai konsekuensinya, pengentasan kemiskinan menjadi tugas yang menantang bagi semua negara, terutama bagi negara berkembang (X. Zhao et al., 2019b).

Indonesia adalah salah satu negara berkembang yang menghadapi kemiskinan. Kemiskinan di Indonesia sudah menjadi masalah yang mendapat perhatian khusus sejak krisis ekonomi tahun 1998. Pada Maret 2019, persentase penduduk miskin di Indonesia sudah mencapai 9,41%, tetapi angka ini naik menjadi 9,78% pada Maret 2020 dan 10,41% pada Maret 2021 (BPS, 2021). Seperti yang

tersaji di Gambar 1, pada tahun 2019, persentase penduduk miskin Indonesia (garis biru) berada di titik paling rendah kemudian naik kembali. Hal ini menunjukkan bahwa pengambilan kebijakan terkait pengentasan kemiskinan Indonesia perlu diperhatikan kembali.



Sumber: Badan Pusat Statistik (BPS) (diolah)

Gambar 1. Perkembangan Persentase dan Jumlah Penduduk Miskin Indonesia

Terdapat dua pendekatan penghitungan kemiskinan, yaitu pendekatan moneter dan multidimensi. Kemiskinan moneter didefinisikan sebagai ketidakmampuan dari sisi ekonomi untuk mencukupi kebutuhan dasar (makanan, perumahan, sandang, pendidikan, dan kesehatan) yang diukur dari pendekatan pengeluaran (BPS, 2021). Sedangkan kemiskinan multidimensi memiliki cakupan yang lebih luas meliputi berbagai deprivasi yang dialami masyarakat yaitu kesehatan (nutrisi dan kematian anak), pendidikan (lama sekolah dan kehadiran di sekolah), dan standar hidup (bahan bakar memasak, sanitasi, air minum, listrik, dan rumah) (Alkire et al., 2021).

Di Indonesia, data kemiskinan moneter diperbarui setiap enam bulan untuk level provinsi dan satu tahun untuk level kabupaten, sedangkan data kemiskinan

multidimensi yang dihitung pada level rumah tangga memiliki rentang pembaruan relatif lebih lama, bahkan data tahun 2015 masih digunakan sampai sekarang. Hal ini terjadi karena penghitungan kemiskinan moneter menggunakan pendekatan pengeluaran yang relatif lebih sederhana dalam pengukurannya. Oleh karena itu, kemiskinan moneter dijadikan sebagai pendekatan kemiskinan yang disepakati dunia dan digunakan di berbagai negara meskipun hanya dapat menjelaskan kemiskinan dari sisi pengeluaran saja. Dengan pertimbangan tersebut, kemiskinan dengan pendekatan moneter dijadikan sebagai acuan dalam penelitian ini.

Untuk mengatasi kemiskinan di Indonesia, pemerintah menargetkan angka kemiskinan moneter Indonesia untuk dapat mencapai 6,5-7% di tahun 2024 dan 4,4-5% di tahun 2030 (Bappenas, 2020). Akan tetapi, sampai September 2021, angka kemiskinan moneter Indonesia masih berada di angka 9,71% (BPS, 2021). Untuk dapat memenuhi target tersebut, diperlukan penilaian, pemantauan, dan evaluasi kemiskinan yang dilakukan secara komprehensif (Bexell & Jönsson, 2017). Gambar 2 menunjukkan target pengentasan kemiskinan yang ingin dicapai pemerintah Indonesia.



Sumber: Peta Jalan SDGs Indonesia Menuju 2030

Gambar 2. Target Pengentasan Kemiskinan Indonesia

Sejauh ini, pemantauan kemiskinan Indonesia dilakukan berdasarkan data kemiskinan resmi yang diperoleh melalui Survei Sosial Ekonomi Nasional (Susenas). Pengumpulan data Susenas dilakukan secara konvesional melalui survei berbasis rumah tangga dengan sampel besar (320.000 rumah tangga pada Maret 2020 dan 750.000 rumah tangga pada September 2020) sehingga memerlukan biaya dan tenaga yang juga besar serta waktu pengumpulan yang lama. Hal ini menyebabkan data kemiskinan resmi hanya dapat disajikan pada level kabupaten setiap satu tahun dan pada level provinsi setiap enam bulan, padahal pemantauan kemiskinan memerlukan data aktual yang lebih granular dalam segi cakupan wilayah (Afifah & Faradis, 2019). Keterbatasan penyajian data kemiskinan dianggap sebagai salah satu faktor utama ketidakefektifan pemberian bantuan sosial (Laurentcia & Yusran, 2021) yang merupakan salah satu strategi utama penanggulangan kemiskinan Indonesia berdasarkan Rencana Pembangunan Jangka Menengah Nasional 2020-2024 (Bappenas, 2020). Oleh karena itu, diperlukan data alternatif estimasi kemiskinan yang lebih granular dalam cakupan wilayah dan dapat diperbarui dengan waktu dan biaya yang lebih rendah untuk mendukung keterbatasan data kemiskinan resmi.

Di sisi lain, penggunaan *big data* citra satelit hasil penginderaan jauh dan *point of interest* (POI) berbasis *crowd-sourced* berpotensi untuk melengkapi keterbatasan data kemiskinan resmi. Penginderaan jauh merupakan metode yang dapat menangkap karakteristik suatu wilayah bumi dengan rekaman elektromagnetik jarak jauh yang diperoleh melalui satelit (Campbell & Wynne, 2011). POI merupakan *geodataset* yang berisi informasi lokasi titik-titik penting di

permukaan bumi yang dapat diperoleh melalui OpenStreetMap (OSM) dengan periode pembaruan sangat cepat. Data ini dapat memberikan informasi terkait struktur perkotaan dan fasilitas ekonomi (Yao, Li, et al., 2017).

Dibandingkan data survei sosial ekonomi konvensional, *big data* citra satelit hasil penginderaan jauh dan POI merupakan sumber daya yang berharga (Triscowati et al., 2020, 2019; Wijayanto et al., 2020) karena keunikan dan objektifitasnya dalam mengamati fenomena sosial ekonomi dan fisik dari perspektif multi-skala secara efektif dan akurat (Shi et al., 2020). Pengumpulan data dengan metode ini memiliki beberapa kelebihan yaitu dapat menangkap keadaan sebenarnya (populasi) sampai level *grid*, memiliki periode pembaruan yang lebih cepat, dan dapat diperoleh dengan biaya relatif terjangkau atau bahkan gratis. Akan tetapi, kualitas data yang diperoleh bergantung pada tutupan awan (citra satelit) dan input pengguna (POI).

Penelitian sebelumnya menunjukkan bahwa pemanfaatan *deep learning* pada citra satelit tangkapan foto permukaan siang dan malam hari dapat digunakan dalam estimasi pemetaan kemiskinan (Jean et al., 2016b). *Deep learning* adalah bagian khusus dari *machine learning* dengan kekuatan dan fleksibilitas luar biasa dalam merepresentasikan dunia sebagai konsep hierarki bersarang, dengan setiap konsep didefinisikan sebagai konsep yang lebih sederhana dan lebih abstrak (Goodfellow et al., 2016). Akan tetapi, pengaplikasian ekstraksi fitur yang mendasari pemetaan kemiskinan pada metode tersebut masih abstrak dan tidak dilakukan dengan pendekatan yang dapat diinterpretasikan (Puttanapong et al., 2022).

Disamping itu, citra satelit yang dapat diperoleh melalui penginderaan jauh satelit multisumber seperti *Visible Infrared Imaging Radiometer Suite* (VIIRS) yang menangkap yang *nighttime light intensity* (NTL) untuk menunjukkan sebaran aktivitas ekonomi malam hari; Sentinel-2 yang menangkap *Normalized Difference Vegetation Index* (NDVI) untuk mendeteksi daerah perdesaan menurut informasi vegetasi, *Built-Up Index* (BUI) untuk mendeteksi daerah urban menurut sebaran bangunan, dan *Normalized Difference Water Index* (NDWI) untuk mendeteksi tutupan lahan; *Moderate Resolution Imaging Spectroradiometer* (MODIS) yang menangkap *land surface temperature* (LST) untuk menunjukkan sebaran daerah urban menurut suhu permukaan; dan Sentinel-5P yang menangkap emisi gas CO, NO₂, dan SO₂ untuk menunjukkan aktivitas ekonomi menurut polusi udara serta POI *Density* dan POI *Distance* yang menunjukkan kepadatan aktivitas ekonomi dan aksesibilitas berpotensi dalam menggambarkan kemiskinan dalam bentuk yang lebih detail yang dapat diinterpretasikan (Putri et al., 2022). Akan tetapi, penelitian yang memanfaatkan potensi tersebut untuk pemetaan kemiskinan, khususnya kemiskinan moneter, belum pernah dilakukan di Indonesia. Selain itu, pemanfaatan *deep learning* yang mengintegrasikan potensi tersebut juga belum pernah dilakukan sebelumnya.

Oleh karena itu, kontribusi penelitian ini adalah pada pengimplementasian *deep learning* pada citra satelit multisumber dan POI untuk memetakan kemiskinan dengan pendekatan yang lebih dapat diinterpretasikan. Untuk memfokuskan lingkup wilayah, penelitian ini mengambil Jawa Timur sebagai wilayah studi karena merupakan provinsi dengan jumlah penduduk miskin terbanyak di Indonesia selama enam tahun terakhir (2015-2021) (BPS, 2021).

1.2 Identifikasi dan Rumusan Masalah

Berdasarkan uraian latar belakang, dapat disimpulkan bahwa demi mendukung target pengentasan kemiskinan yang ingin dicapai pemertintah Indonesia, diperlukan penyajian data alternatif estimasi kemiskinan yang lebih granular dalam cakupan wilayah dan dapat diperbarui dengan waktu dan biaya yang lebih rendah untuk melengkapi keterbatasan data kemiskinan resmi.

Adanya keterbatasan pada metode pengumpulan dan penyajian data kemiskinan di Indonesia saat ini menunjukkan terbukanya peluang untuk mengeksplorasi metode alternatif. *Big data* citra satelit multisumber dan *point of interest* (POI) merupakan sumber data alternatif yang berpotensi untuk dapat menggambarkan kemiskinan dengan lebih detail karena kelebihannya yaitu dapat menangkap keadaan sebenarnya (populasi) sampai level *grid*, memiliki periode pembaruan yang lebih cepat, dan dapat diperoleh dengan biaya relatif terjangkau atau bahkan gratis. Oleh karena itu, dirumuskan empat masalah yang menjadi pokok bahasan dalam penelitian ini.

1. Bagaimana pemanfaatan *big data* citra satelit multisumber dan POI dalam mengidentifikasi kemiskinan dari pendekatan geografis?
2. Bagaimana implementasi *deep learning* pada pembangunan model estimasi pemetaan kemiskinan dengan *big data* citra satelit multisumber dan POI?
3. Bagaimana evaluasi pemetaan kemiskinan yang dibangun dari model estimasi pada poin sebelumnya?
4. Bagaimana penyajian hasil estimasi pemetaan kemiskinan agar dapat dengan mudah diakses dan diidentifikasi oleh pemangku kepentingan?

1.3 Tujuan Penelitian

Berdasarkan latar belakang dan identifikasi masalah yang telah diuraikan, dirumuskan empat tujuan yang ingin dicapai pada penelitian ini.

1. Membangun indeks kemiskinan spasial relatif untuk memetakan kemiskinan spasial pada level *grid* 1,5 km
2. Membangun model estimasi pemetaan kemiskinan dengan *big data* citra satelit multisumber dan *Point of Interest* (POI) serta model estimasi pemetaan kemiskinan dengan citra satelit siang dan malam hari mengimplementasikan *deep learning*
3. Membangun dan mengevaluasi estimasi pemetaan kemiskinan level *grid* 1,5 km
4. Membangun *map dashboard* interaktif berbasis *website* untuk menyajikan hasil pemetaan kemiskinan

1.4 Manfaat Penelitian

Mengacu pada latar belakang dan rumusan masalah yang diuraikan serta keempat tujuan yang telah dijabarkan, diharapkan penelitian ini dapat memberikan manfaat baik dari sisi teoritis maupun sisi praktis.

1.4.1 Manfaat Teoritis

Bagi pengembangan ilmu pengetahuan, diharapkan penelitian ini dapat berkontribusi dalam:

1. Memberikan inovasi pemetaan daerah terdeprivasi spasial yang menunjukkan kemiskinan spasial dengan memanfaatkan *big data* citra satelit multisumber dan POI
2. Memperkenalkan pendekatan baru pemetaan kemiskinan dengan *big data* citra satelit multisumber dan POI di Indonesia
3. Memberikan inovasi dan menunjukkan performa pemanfaatan *deep learning* pada citra satelit multisumber dan POI untuk pemetaan kemiskinan
4. Memberikan inovasi penyajian pemetaan kemiskinan dengan *map dashboard* berbasis *website*
5. Menjadi rujukan penelitian selanjutnya khususnya terkait pemanfaatan penginderaan jauh untuk mengidentifikasi kondisi sosial-ekonomi di suatu daerah

1.4.2 Manfaat Praktis

Dari hasil penelitian ini, diharapkan terpenuhinya manfaat praktis yang dapat diuraikan menjadi manfaat akademis bagi penulis, manfaat teknis bagi pemangku kepentingan, manfaat sosial bagi masyarakat Jawa Timur, dan manfaat umum bagi pembaca.

1. Manfaat Akademis Bagi Penulis

Penelitian ini diharapkan dapat menambah pemahaman penulis terkait permasalahan aktual yang menjadi perhatian dunia saat ini khususnya kemiskinan. Berangkat dari masalah tersebut, diharapkan penelitian ini dapat menambah wawasan penulis terkait penggunaan sumber data baru khususnya *big data* fusi citra satelit multisumber dan POI dalam mendukung data kemiskinan resmi. Selain itu, penelitian ini juga diharapkan dapat menambah

pengalaman penulis dalam mengimplementasikan *deep learning* khususnya dalam pembangunan model kemiskinan berdasarkan *big data* fusi citra satelit multisumber dan POI.

2. Manfaat Teknis Bagi Pemangku Kepentingan

Peta kemiskinan hasil penelitian yang granular sampai pada level *grid* 1,5 km diharapkan dapat menjadi data alternatif dalam melengkapi keterbatasan data kemiskinan resmi yang hanya tersedia sampai level kabupaten/kota. Peta kemiskinan yang kemudian disajikan dalam *map dashboard* interaktif diharapkan dapat memudahkan pemangku kepentingan dalam mengidentifikasi kondisi kemiskinan di suatu wilayah spesifik. Hasil interpretasi tersebut diharapkan dapat menjadi dasar dalam pengambilan keputusan terkait usaha pengentasan kemiskinan misalnya dengan memetakan daerah spesifik yang perlu menjadi perhatian dalam penyaluran bantuan sosial.

Selain itu, peta kemiskinan yang dibangun dapat menujukkan kondisi kemiskinan di suatu wilayah dengan biaya yang relatif rendah dari pengumpulan data konvensional sehingga informasi kemiskinan yang diperoleh dapat lebih aktual. Karena dibangun berdasarkan citra satelit dan POI dengan periode pembaruan paling lama satu bulan, diharapkan model estimasi pemetaan kemiskinan yang dibangun pada penelitian ini dapat digunakan untuk pemetaan kemiskinan dengan periode pembaruan satu bulan. Penyajian data kemiskinan ini diharapkan dapat menambah rujukan data aktual pemangku kepentingan.

3. Manfaat Sosial Bagi Masyarakat Jawa Timur

Hasil penelitian ini diharapkan dapat memberikan wawasan dan meningkatkan kepedulian masyarakat Jawa Timur terkait kondisi kemiskinan di wilayah tempat tinggalnya. Oleh karena itu, diharapkan hasil penelitian ini dapat dapat menggerakan masyarakat Jawa Timur untuk ikut andil baik secara langsung maupun tidak langsung dalam usaha pengentasan kemiskinan di Jawa Timur.

4. Manfaat Umum Bagi Pembaca

Penelitian ini diharapkan dapat menyajikan informasi terkait kemiskinan sebagai masalah yang diangkat pada penelitian ini. Selain itu, diharapkan hasil penelitian ini dapat memberikan pemahaman bagi pembaca terkait inovasi ditawarkan yaitu pengimplementasian *deep learning* pada *big data* fusi citra satelit multisumber dan POI untuk membangun estimasi pemetaan kemiskinan yang lebih *granular*.

1.5 Cakupan dan Batasan Penelitian

Pada penelitian ini, Provinsi Jawa Timur dipilih sebagai wilayah studi kasus dan tahun 2020 dipilih sebagai waktu referensi. Jawa Timur terpilih sebagai wilayah studi pada panelitian ini karena merupakan provinsi dengan jumlah penduduk miskin terbanyak di Indonesia pada tahun 2015-2021 (BPS, 2021). Penelitian ini hanya berfokus pada kemiskinan moneter karena keterbatasan data kemiskinan multidimensi. Dalam evaluasi numerik hasil penelitian, penghitungan nilai akurasi hanya dapat dilakukan di level kabupaten atau kecamatan karena tidak tersedianya data kemiskinan resmi secara granular sampai resolusi spasial yang

sama dengan hasil penelitian. Evaluasi deskriptif juga dilakukan secara tidak langsung dengan bantuan citra satelit resolusi tinggi seperti *Google Earth*, peta *Google Maps*, tangkapan kamera *Google Street View*, dan data pendukung lainnya. Metode verifikasi lapangan (*ground truth check*) yang merupakan metode ideal belum dapat dilakukan karena kendala pandemi Covid-19 dan keterbatasan sumber daya manusia.

1.6 Sistematika Penulisan

Penulisan makalah skripsi ini disusun secara sistematis berdasarkan pedoman penulisan skripsi Politeknik Statistika STIS Tahun Akademik 2021/2022. Bagian awal makalah skripsi mencakup 1) halaman sampul, 2) halaman judul, 3) halaman pernyataan, 4) halaman pengesahan, 5) prakata, 6) abstrak, 7) daftar isi, 8) daftar tabel, 9) daftar gambar, dan 10) daftar lampiran. Bagian isi makalah skripsi dibagi menjadi lima bab yaitu Bab I (Pendahuluan), Bab II (Kajian Pustaka), Bab III (Metodologi), Bab IV (Hasil dan Pembahasan), dan Bab V (Kesimpulan dan Saran).

Bab I (Pendahuluan) pada penelitian ini secara umum menjelaskan pentingnya penelitian ini dilakukan. Latar belakang pada pendahuluan penelitian ini menjelaskan kemiskinan sebagai masalah yang diangkat dan inovasi yang ditawarkan untuk mendukung usaha pengentasan kemiskinan di Indonesia. Identifikasi dan rumusan masalah menjelaskan dan merinci lingkup masalah yang menjadi fokus penelitian. Tujuan penelitian merinci hal-hal yang ingin diperoleh dari penelitian. Manfaat penelitian yang dibagi menjadi manfaat teoritis dan manfaat praktis menjabarkan kebermanfaatan yang diharapkan dari hasil penelitian

ini. Cakupan dan batasan penelitian menjelaskan Jawa Timur sebagai wilayah studi dan tahun 2020 sebagai waktu referensi serta berbagai batasan yang membatasi penelitian. Sistematika penulisan menjelaskan struktur penyusunan makalah.

Bab II (Kajian Pustaka) pada penelitian ini memuat landasan teori yang menjadi acuan pada penelitian ini dan penelitian-penelitian terdahulu yang mendasari penelitian ini. Landasan teori menjelaskan konsep definisi yang menjadi acuan peneliti dalam menjalankan penelitian. Penelitian terkait membahas secara sistematis penelitian-penelitian terdahulu yang serupa dengan penelitian ini serta kontribusi yang diberikan penelitian ini atas penelitian-penelitian terdahulu tersebut.

Bab III (Metodologi) secara umum menjabarkan lingkup dan metode yang diaplikasikan pada penelitian. Ruang lingkup penelitian menjelaskan Jawa Timur sebagai wilayah studi pada penelitian ini. Data dan sumber data merinci dan menjelaskan data, sumber data, dan variabel yang digunakan pada penelitian. Tahapan penelitian menjabarkan secara terperinci tahapan yang dilalui pada proses penelitian. Kerangka pikir menjelaskan secara sistematis alur berpikir peneliti dalam menngimplementasikan penelitian ini.

Bab IV (Hasil dan Pembahasan) yang mencakup 1) hasil penghitungan indeks kemiskinan spasial relatif (*Relative Spatial Poverty Index*; RSPI), 2) hasil pembangunan model estimasi pemetaan kemsikinan dengan *big data* citra satelit multisumber dan POI serta pembangunan model estimasi pemetaan kemsikinan dengan citra satelit siang dan malam hari, 3) hasil pembangunan, evaluasi, dan penyajian hasil estimasi kemiskinan pada level *grid* 1,5 km, dan 4) hasil

pembangunan *map dashboard* interaktif berbasis *website* sebagai penyajian akhir hasil penelitian.

Bab V (Kesimpulan dan Saran) berisi kesimpulan yang diperoleh dari hasil penelitian ini serta rekomendasi berupa saran dari peneliti untuk para penerima manfaat penelitian ini. Bagian akhir makalah skripsi ini memuat 1) daftar pustaka, 2) lampiran, dan 3) daftar riwayat hidup.

BAB II

KAJIAN PUSTAKA

2.1 Landasan Teori

2.1.1 Kemiskinan

Kemiskinan adalah keadaan ketika satu orang atau lebih gagal memenuhi tingkat kesejahteraan ekonomi yang dianggap merupakan tingkat minimum yang wajar, baik dalam arti absolut atau menurut standar masyarakat tertentu (Lipton & Ravallion, 1995). Badan Pusat Statistik (BPS) memandang kemiskinan sebagai ketidakmampuan dari segi ekonomi dalam mencukupi kebutuhan dasar baik makanan maupun non-makanan yang dihitung berdasarkan pengeluaran (BPS, 2021).

Menurut BPS, penduduk dengan pengeluaran rata-rata dibawah garis kemiskinan dapat dikategorikan sebagai penduduk miskin. Garis Kemiskinan atau GK menunjukkan nilai pengeluaran minimum dalam rupiah yang dibutuhkan seseorang dalam pemenuhan kebutuhan makanan (GKM) serta non-makanan (GKNM). GKM atau Garis Kemiskinan Makanan dihitung berdasarkan nilai rupiah pengeluaran pemenuhan kebutuhan makanan minimum yang setara dengan 2100 kilokalori per kapita per hari. GKNM atau Garis Kemiskinan Non-Makanan dihitung berdasarkan nilai rupiah pengeluaran pemenuhan kebutuhan non-makanan minimum. Kebutuhan non-makanan tersebut berupa kebutuhan sandang,

perumahan, kesehatan, dan pendidikan. Penghitungan garis kemiskinan diformulasikan sebagai berikut (BPS, 2021).

$$GK = GKM + GKNM \quad (1)$$

GK dihitung berdasarkan kelompok referensi atau yang kemudian disebut kelompok kelas marginal yaitu 20% dari penduduk dengan pengeluaran perkapita dibawah GKS (Garis Kemiskinan Sementara). Nilai GKS adalah GK pada periode sebelumnya yang sudah di-*inflate* berdasarkan inflasi umum atau IHK. Kemudian dilanjutkan penghitungan GKM dan GKNM pada kelompok kelas marginal. Penyetaraan nilai pengeluaran untuk kebutuhan makanan minimum dilakukan dengan menghitung harga rata-rata kalori komoditas referensi dengan formula sebagai berikut (BPS, 2021).

$$GKM_{jp}^* = \sum_{k=1}^n P_{jkp} \cdot Q_{jkp} = \sum_{k=1}^n V_{jkp} \quad (2)$$

Dengan GKM_{jp}^* mewakili GKM wilayah j (sebelum disetarakan menjadi 2100 kilokalori) provinsi p . P_{jkp} mewakili rata-rata harga komoditas k di wilayah j dan provinsi p . Q_{jkp} mewakili rata-rata komoditas k yang dikonsumsi di wilayah j provinsi p . V_{jkp} mewakili nilai pengeluaran untuk konsumsi komoditas k di wilayah j provinsi p . j mewakili wilayah (perkotaan dan pedesaan). p mewakili provinsi ke- p , n mewakili banyaknya komoditas acuan. Kemudian, GKM_j disetarakan dengan 2100 kilokalori dengan mengalikan 2100 terhadap harga implisit rata-rata kalori menurut wilayah j dari penduduk referensi, sehingga:

$$\overline{HK}_{jp} = \frac{\sum_{k=1}^n V_{jkp}}{\sum_{k=1}^n K_{jkp}} \quad (3)$$

Dengan K_{jkp} mewakili kalori dari komoditas k di wilayah j di provinsi p . \overline{HK}_{jp} mewakili harga rata-rata kalori di wilayah j di provinsi p (BPS, 2021).

GKNM dihitung dengan menjumlahkan nilai pengeluaran minimum dari komoditas non-makanan terpilih. Penyempurnaan komoditas terpilih dilakukan setiap tahun untuk menyesuaikan dengan pola konsumsi penduduk. Nilai kebutuhan minimum per komoditas dihitung melalui rasio pengeluaran komoditas terhadap total pengeluaran komoditas yang tercatat dalam Susenas Modul Konsumsi. Rasio yang dimaksud dihitung dari berdasarkan hasil Survei Paket Komoditas Kebutuhan Dasar (SPKKD) 2004. Nilai kebutuhan minimum non-makanan dapat diformulasikan sebagai berikut (BPS, 2021).

$$GKNM_{jp} = \sum_{k=1}^n r_{kj} V_{kjp} \quad (4)$$

Dengan $GKNM_{jp}$ mewakili pengeluaran minimum non-makanan atau garis kemiskinan non-makanan wilayah j dan provinsi p . V_{kjp} mewakili nilai pengeluaran per komoditas atau subkelompok non-makanan wilayah j dan provinsi p . r_{kj} mewakili pengeluaran komoditas atau subkelompok non-makanan k menurut wilayah (hasil SPKKD 2004) dan wilayah j . k mewakili jenis komoditas non-makanan terpilih. j mewakili wilayah (perkotaan atau perdesaan). p mewakili provinsi ke- p (BPS, 2021).

Formula berikut menunjukkan penghitungan persentase penduduk miskin atau penduduk dengan pengeluaran dibawah garis kemiskinan.

$$P_\alpha = \frac{1}{n} \sum_{i=1}^q \left[\frac{z - y_i}{z} \right]^\alpha \quad (5)$$

Dengan α adalah 0. z adalah garis kemiskinan. y_i adalah nilai rata-rata pengeluaran per kapita sebulan penduduk yang berada dibawah garis kemiskinan ($i = 1, 2, 3, \dots, q$), $y_i < z$. q adalah banyaknya penduduk yang berada di bawah garis kemiskinan. n adalah jumlah penduduk (BPS, 2021).

Kemiskinan merupakan masalah yang diangkat pada tujuan pertama *Sustainable Development Goals* (SDGs). SDGs menargetkan pemberantasan kemiskinan dalam segala bentuk di manapun untuk dicapai pada tahun 2030. Rassanjani (2018) menyatakan bahwa konvergensi agenda, kerjasama-kemitraan, program pengentasan kemiskinan yang mapan, pendanaan alternatif seperti bantuan sosial, dan inovasi basis data merupakan faktor kunci yang dapat memengaruhi pencapaian target SDGs Indonesia. Beberapa faktor yang menyebabkan kemiskinan di Indonesia yaitu produk domestik bruto (PDB), rata-rata lama sekolah, harapan hidup, dan sebaran infrastruktur pemerintah (Asrol & Ahmad, 2018). Kemiskinan berdampak signifikan terhadap keberlangsungan kehidupan seperti kelaparan (Sharma, 2019), permasalahan kesehatan (Billings & Thornton, 2021), peningkatan kasus kriminal (Imran et al., 2018), dan bahkan kematian.

2.1.2 Big Data

Big data adalah istilah untuk kumpulan data besar yang memiliki struktur besar, bervariasi, kompleks, dan memerlukan proses lanjutan untuk dapat dianalisis atau divisualisasikan (Sagiroglu & Sinanc, 2013). *Big data* dapat didefinisikan melalui setidaknya tiga karakteristik yaitu volume, kecepatan (*velocity*), dan variasi (*variety*). *Big data* memiliki data dengan volume *terabytes* atau tersusun atas

milyaran *record*, dengan kecepatan pengumpulan data sangat cepat atau dikumpulkan dengan *batch*, *real-time*, atau *stream processing*, bervariasi tinggi atau memerlukan analisis khusus untuk dapat memahami kontennya (Zikopoulos & Eaton, 2011).

Geospatial big data merupakan istilah yang merujuk pada *big data* dengan informasi spasial Yao et al. (2017). *Geospatial big data* dapat merefleksikan karakteristik lahan seperti perkotaan dan penggunaan lahan serta aktivitas manusia (McCoy, 2017). Citra satelit yang dapat diperoleh dari penginderaan jauh berbagai satelit dan *point of interest* (POI) merupakan contoh *geospatial big data*. *Geospatial big data* tersebut dapat menangkap aktivitas penduduk dari aspek geografis sehingga dapat digunakan untuk memetakan daerah terdeprivasi spasial dan estimasi kemiskinan (Shi et al., 2020).

2.1.3 Citra Satelit

Citra satelit didefinisikan sebagai gambar hasil rekaman lensa kamera atau sensor yang dipasang pada satelit di luar angkasa dengan ketinggian lebih dari 400 km dari permukaan bumi (BPS, 2022). Citra satelit diperoleh dari proses penginderaan jauh atau *remote sensing*. Sensor dari penginderaan jauh merekam energi yang dipantulkan atau dipancarkan oleh objek yang berada pada permukaan bumi (BPS, 2022).

Penginderaan jauh atau *remote sensing* didefinisikan sebagai pengukuran dari objek pada permukaan bumi menggunakan data yang diperoleh melalui pesawat atau satelit (Schowengerdt, 2006). *Remote sensing* meliputi seluruh metode untuk mendapatkan citra atau bentuk lain perekaman elektromagnetik dari

permukaan bumi pada jarak tertentu, termasuk juga berbagai perlakuan dan *preprocessing* dari citra yang diperoleh (Campbell & Wynne, 2011). Sistem *remote sensing*, terutama yang dipasang pada satelit, dapat menangkap pandangan permukaan bumi secara berulang dan konsisten, sehingga dapat digunakan untuk memantau perubahan permukaan bumi jangka pendek maupun jangka panjang sebagai dampak proses alam atau aktivitas manusia (Schowengerdt, 2006).

Penginderaan jauh bersifat multifungsi karena merupakan sumber data dasar, ilmu pengetahuan, dan alat. Penginderaan jauh merupakan sumber data dasar karena hasil yang diukur dari sifat fisis benda-benda jauh dengan menggunakan energi yang dipantulkan dan dipancarkan, terlepas dari di mana mereka direkam merupakan data. Penginderaan jauh adalah ilmu karena memanfaatkan proses ilmiah: pengukuran, pengolahan data, interpretasi hasil, dan inferensi ilmiah. Penginderaan jauh adalah alat karena hasil yang diperoleh dari proses ilmiah ini dapat digunakan untuk berbagai keperluan, mulai dari pembuatan inventarisasi sumber daya hingga pemecahan masalah ekologi (Moore, 1979).

Terdapat empat jenis resolusi yang sering digunakan dalam menerangkan data penginderaan jauh yaitu resolusi spasial, resolusi temporal, resolusi spektral, dan resolusi radiometrik.

1. Resolusi Spasial

Resolusi spasial menunjukkan ukuran objek terkecil yang dapat dideteksi pada citra satelit hasil penginderaan jauh. Unit dasar yang menunjukkan resolusi spasial dalam data raster citra satelit disebut sebagai piksel (BPS, 2022). Resolusi spasial 10 m menunjukkan bahwa ukuran satu piksel dalam citra tersebut mewakili area seluas 10 x 10 m atau setara dengan

100 m². Semakin kecil area yang dicakup oleh satu piksel citra satelit, maka semakin tinggi pula resolusi dari citra tersebut, informasi yang disajikan pun juga semakin rinci (Suwargana, 2013). Dengan kata lain, objek yang divisualisasikan lebih detail. Citra satelit dapat diklasifikasikan sebagai citra satelit resolusi sangat tinggi seperti Piades (0,5 m), citra satelit resolusi tinggi seperti ikonos (4 m), citra satelit resolusi medium seperti Landasat (15-30 m) dan Sentinel-2 (10 m), dan citra satelit resolusi rendah seperti MODIS (250-1000 m) (BPS, 2022).

2. Resolusi Temporal

Resolusi temporal menunjukkan waktu tempuh yang diperlukan satelit penginderaan jauh dalam menyelesaikan orbit dan mengunjungi area yang sama (BPS, 2022). Biasanya, satuan dari resolusi temporal adalah hari, semakin banyak jumlah waktu yang diperlukan untuk mengindera daerah yang sama menunjukkan semakin rendahnya resolusi temporal penginderaan citra satelit tersebut (Syah, 2010). Resolusi temporal suatu penginderaan citra satelit dikatakan tinggi jika rentang waktu penginderaan pada daerah yang sama berkisar antara <24 jam sampai tiga hari, sedang jika rentangnya 4-16 hari, dan rendah jika rentangnya >16 hari (Suwargana, 2013). Resolusi temporal bergantung pada jenis orbit satelit, karakteristik sensor satelit, serta lebar sapuan citra (BPS, 2022).

3. Resolusi Spektral

Resolusi spektral menjelaskan kemampuan sensor satelit penginderaan jauh dalam memberikan tingkat kedetailan dari spektrum elektromagnetik pada

suatu panjang gelombang (BPS, 2022). Resolusi spektral menunjukkan banyaknya jumlah pita spektral (*bands*) yang terdapat pada citra hasil penginderaan jauh. Semakin tinggi resolusi spektral suatu sensor penginderaan jauh, semakin banyak pula pita spektral yang ditangkap dengan jarak panjang gelombang yang semakin sempit (BPS, 2022).

4. Resolsi Radiometrik

Resolusi radiometrik menunjukkan jumlah informasi yang dimiliki dalam setiap piksel, yaitu jumlah bit yang mewakili energi yang direkam pada citra satelit hasil penginderaan jauh (BPS, 2022). Resolusi radiometrik dapat didefinisikan sebagai jangkauan representasi atau kuantisasi data raster yang dapat berupa 2 bit dengan jangkauan 0-1, 8 bit dengan jangkauan 0-255, 10 bit dengan jangkauan 0-1023, dan 16 bit dengan jangkauan 0-65535 (Oktaviani & Johan, 2016). Semakin besar bit yang dimiliki sensor, maka semakin besar pula resolusi radiometrik sensor penginderaan jauh tersebut (Syah, 2010).

Citra satelit dapat diperoleh dari beberapa satelit (multisumber) misalnya VIIRS, Sentinel-2, MODIS, Sentinel-5P. Pembahasan berikut akan berfokus pada perolehan citra satelit hasil penginderaan jauh satelit-satelit tersebut dan kaitannya dengan kondisi sosial ekonomi khususnya kemiskinan.

2.1.3.1 *Visible Infrared Imaging Radiometer Suite (VIIRS)*

VIIRS merupakan satelit yang mengumpulkan data pencitraan cahaya (*luminosity*) suatu daerah yang dikumpulkan selama 40 tahun (Elvidge et al., 2017).

Tabel 1 menunjukkan pita spektral yang disediakan dalam *Dataset VIIRS Stray Light Corrected Nighttime Day/Night Band Composites Version 1*.

Tabel 1. Pita Spektral Citra Satelit VIIRS *Stray Light Corrected Nighttime Day/Night Band Composites Version 1*

Nama Pita	Minimum	Maksimum	Satuan	Deskripsi
(1)	(2)	(3)	(4)	(5)
avg_rad	-1,5	193565	nanoWatts/cm ² /sr	Nilai kecerahan DNB rata-rata
cf_cvg	0	84		Jumlah total pengamatan yang masuk ke setiap piksel. Pita ini dapat digunakan untuk mengidentifikasi daerah dengan jumlah pengamatan yang rendah dimana kualitasnya berkurang.

Sumber: *Earth Observation Group, Payne Institute for Public Policy, Colorado School of Mines*

Night-time light (NTL) adalah citra satelit yang paling umum digunakan untuk menggambarkan kemiskinan (Naizhuo Zhao et al., 2020). NTL dapat merekam cahaya dari aktivitas manusia di malam hari dan telah terbukti memiliki kemampuan untuk memperkirakan berbagai parameter sosial ekonomi, termasuk kemiskinan. Semakin tinggi nilai NTL menunjukkan semakin tingginya aktivitas ekonomi di suatu daerah (N. Zhou et al., 2015). Kecerahan malam hari (*nighttime light*; NTL) dapat digunakan sebagai pendekatan untuk mengidentifikasi kegiatan ekonomi di suatu daerah yang dapat menggambarkan kondisi sosial ekonomi termasuk kemiskinan secara tidak langsung (X. Zhao et al., 2019a).

2.1.3.2 Sentinel-2 Multispectral Instrument Level-2A

Sentinel-2 merupakan satelit radar yang memiliki kemampuan menangkap permukaan bumi dengan cara menembus tutupan awan atau yang lebih dikenal dengan *Synthetic Aperture Radar Ground Range Detected* (SAR-GRD) (Wijayanto et al., 2020). Sentinel-2 MSI (*Multispectral Instrument*) Level-2A yang diluncurkan pada tahun 2015 merupakan satelit pencitraan optik milik Eropa. Citra hasil penginderaan satelit ini memiliki resolusi spasial cukup tinggi jika dibandingkan dengan kelompok satelit resolusi menengah lainnya yaitu mencapai 10 m pada pita B4 (*Red*), B3 (*Green*), B2 (*Blue*), dan B8 (*Near Infrared/NIR*). Tabel 2 menunjukkan pita spektral citra Sentinel-2 beserta resolusi spasialnya. Adapun resolusi temporal atau frekuensi kunjungan kembali satelit ini ke suatu lokasi tertentu adalah 10 hari dan 5 hari untuk kunjungan dengan dua satelit.

Tabel 2. Pita Spektral Citra Satelit Sentinel-2 MSI Level-2A

Nama Pita	Deskripsi	Resolusi Spasial
(1)	(2)	(3)
B1	<i>Aerosols</i>	60 m
B2	<i>Blue</i>	10 m
B3	<i>Green</i>	10 m
B4	<i>Red</i>	10 m
B5	<i>Vegetation Red Edge (VRE) 1</i>	10 m
B6	<i>Vegetation Red Edge (VRE) 2</i>	20 m
B7	<i>Vegetation Red Edge (VRE) 3</i>	20 m
B8	<i>Near Infrared (NIR)</i>	10 m
B8A	<i>Narrow NIR</i>	20 m
B9	<i>Water Vapor</i>	60 m
B10	<i>Cirrus</i>	60 m
B11	<i>Shortwave Infrared (SWIR) 1</i>	20 m

Nama Pita	Deskripsi	Resolusi Spasial
(1)	(2)	(3)
B12	<i>Shortwave Infrared (SWIR) 1</i>	20 m

Sumber: *The European Space Agency (ESA) 2021*

Sentinel-2 adalah misi pencitraan multi-spektral yang luas yang mendukung studi Copernicus *Land Monitoring*, termasuk pemantauan vegetasi, penutup tanah dan air, serta pengamatan jalur air pedalaman dan wilayah pesisir. Kombinasi pita hasil penginderaan satelit Sentinel-2 dapat digunakan untuk membangun berbagai indeks komposit contohnya *Normalized Difference Vegetation Index* (NDVI), *Built-up Index* (BUI), dan *Normalized Difference Vegetation Index* (NDWI).

- ***Normalized Difference Vegetation Index (NDVI)***

Normalized Difference Vegetation Index (NDVI) merupakan indeks vegetasi yang dianalisis berdasarkan nilai kecerahan pantulan dan penyerapan pita *near-infrared* (NIR) dan pita merah (C. Zhou et al., 2020). Penghitungan NDVI menurut Purevdorj et al., (1998) didefinisikan melalui persamaan berikut.

$$NDVI = \frac{NIR_{band\ 8} - Red_{band\ 4}}{NIR_{band\ 8} + Red_{band\ 4}} \quad (6)$$

NDVI mengukur vegetasi hijau dari tumbuhan dan menangkap perubahan dalam lingkungan ekologi (Li et al., 2017). NDVI secara signifikan berkorelasi dengan kemiskinan positif tinggi atau positif rendah (Dawson et al., 2018).

- ***Built-up Index (BUI)***

Built-up Index (BUI) merupakan indeks bangunan yang dapat digunakan untuk memetakan wilayah perkotaan (Kaimaris & Patias, 2016) yang terkait dengan kemiskinan daerah (Alkire et al., 2021). BUI diperoleh melalui penghitungan selisih *Normalized Difference Built-up Index* (NDBI) dan NDVI yang secara matematis didefinisikan melalui formula berikut.

$$BUI = NDBI - NDVI \quad (7)$$

Normalized Difference Built-up Index (NDBI) merupakan indeks bangunan yang dianalisis berdasarkan reflektansi spektral *Short-wave infrared* (SWIR) dan *near-infrared* (NIR). Indeks komposit ini dapat digunakan untuk memetakan daerah terbangun yang membedakan daerah urban dan suburban (Karanam & Neela, 2017). Formula penghitungan NDBI menurut Zha et al. (2003) didefinisikan melalui persamaan berikut.

$$NDBI = \frac{SWIR_{band\ 1} - NIR_{band\ 8}}{SWIR_{band\ 1} + NIR_{band\ 8}} \quad (8)$$

Semakin tinggi nilai NDBI menunjukkan semakin besar kemungkinan suatu daerah merupakan daerah terbangun (He et al., 2010).

- ***Normalized Difference Water Index* (NDWI)**

Normalized Difference Water Index (NDWI) merupakan indeks yang digunakan untuk memetakan tutupan lahan terutama untuk membedakan daerah perairan dan daratan karena nilainya yang sensitif terhadap perubahan kadar air cair tajuk vegetasi (Gao, 1996). Secara

teoritis, nilai NDWI di atas 0 menunjukkan hasil citra badan air, sebaliknya nilai di bawah 0 menunjukkan hasil citra non-perairan (McFeeters, 1996). Formula penghitungan NDWI didefinisikan melalui persamaan berikut.

$$NDWI = \frac{Green_{band\ 3} - NIR_{band\ 8}}{Green_{band\ 3} + NIR_{band\ 8}} \quad (9)$$

2.1.3.3 MODIS (MOD11A1.006 *Terra Land Surface Temperature and Emissivity*)

Sensor MODIS diluncurkan oleh *National Aeronautics and Space Administration* (NASA) *Earth Observing System* (EOS) untuk menyediakan informasi terkait atmosfer, lahan, dan proses laut (Wan et al., 2004). Data MODIS Terra tersedia pada pukul 10.30–12.00 pagi dan sore hari (siang/malam) waktu setempat, sedangkan sensor MODIS Aqua mengumpulkan citra selama 1.00–3.00 pagi dan sore (siang/malam) (Yang et al., 2017). Salah satu produk satelit MODIS, MOD11A1 V6 memberikan nilai suhu permukaan tanah (LST) dan emisivitas harian. Nilai suhu diturunkan dari produk petak MOD11_L2. Citra disediakan bersama dengan pita suhu permukaan siang dan malam hari dengan indikator kualitasnya adalah pita MODIS 31 dan 32 dan enam lapisan pengamatan. Tabel 3 menunjukkan pita spektral yang disediakan dalam *Dataset MOD11A1.061 Terra Land Surface Temperature and Emissivity Daily Global 1 km*.

Tabel 3. Pita Spektral Citra Satelit MOD11A1.061 Terra *Land Surface Temperature and Emissivity Daily Global 1km*

Nama Pita	Minimum	Maksimum	Scale	Offset	Satuan	Deskripsi
(1)	(2)	(3)	(4)	(5)	(6)	(7)
LST_Day_1km	7500	65535	0,02		Kelvin	Suhu permukaan

Nama Pita	Minimum (1)	Maksimum (2)	Scale (3)	Offset (4)	Satuan (5)	Deskripsi (6)
						tanah siang hari
QC_Day						Indikator kualitas LST siang hari
Day_view_time	0	240	0,1		Jam	Waktu lokal observasi
Day_view_angle	0	130		-65	Derajat	Sudut puncak pengamatan siang hari
Emis_31	1	255	0,002	0,49		Emisifitas pita 31
Emis_32	1	255	0,002	0,49		Emisifitas pita 32

Sumber: *The Land Processes Distributed Active Archive Center (LP DAAC)*

Land surface temperature (LST) merupakan salah satu produk MODIS yang menangkap suhu permukaan tanah. Suhu permukaan tanah berubah seiring dengan konversi penggunaan energi yang berkaitan dengan populasi dan pertumbuhan ekonomi (D. Zhou et al., 2018). Daerah dengan suhu permukaan tanah yang lebih tinggi menunjukkan bahwa populasi dan pertumbuhan ekonomi daerah tersebut cenderung tinggi.

2.1.3.4. Sentinel-5P

Sentinel-5 *Precursor* adalah satelit yang diluncurkan pada 13 Oktober 2017 oleh Badan Antariksa Eropa untuk memantau polusi udara. Sentinel-5P adalah satelit yang diluncurkan untuk memantau atmosfer (Veefkind et al., 2012). Satelit ini dapat menangkap berbagai polutan udara seperti CO , NO_2 , dan SO_2 .

- **Karbon Monoksida (CO)**

Karbon monoksida (CO) adalah gas jejak atmosfer yang penting untuk memahami kondisi kimia troposfer. Di daerah perkotaan, CO dapat menjadi polutan atmosfer utama (Copernicus Sentinel-5P (processed by ESA), 2018).. Sumber utama CO adalah pembakaran bahan bakar fosil, pembakaran biomassa, dan oksidasi atmosfer dari metana dan hidrokarbon lainnya. Karbon monoksida (CO) dikeluarkan oleh berbagai sumber, termasuk kendaraan bermotor, pembangkit listrik, kebakaran hutan, dan insinerator (Stephens & Cadle, 1991). Penelitian sebelumnya menunjukkan bahwa polutan karbon monoksida (CO) memiliki efek signifikan terhadap pertumbuhan ekonomi yang berkaitan dengan kemiskinan (Fujii & Managi, 2016).

- **Nitrogen Dioksida (NO_2)**

Nitrogen dioksida (NO_2) yang terdapat pada lapisan troposfer dan stratosfer. NO_2 memasuki atmosfer sebagai akibat dari aktivitas antropogenik (terutama pembakaran bahan bakar fosil dan pembakaran biomassa) dan proses alami (kebakaran hutan, kilat, dan proses mikrobiologi di tanah) (Copernicus Sentinel-5P (processed by ESA), 2021).

Nitrogen dioksida (NO_2) adalah salah satu polutan kualitas udara utama yang menjadi perhatian di banyak kawasan perkotaan dan industri di seluruh dunia (Virghileanu et al., 2020). NO_2 dapat digunakan untuk menggambarkan kemiskinan suatu wilayah mengingat polusi udara NO_2 terkait dengan kondisi ekonomi (Han et al., 2021). Daerah dengan aktivitas industri dan ekonomi yang tinggi akan memiliki polusi NO_2 yang tinggi.

- **Sulfur Dioksida (SO_2)**

SO_2 merupakan polutan yang dihasilkan akibat kepadatan populasi dan konsumsi energi (Bakhsh et al., 2022). SO_2 dapat digunakan untuk menggambarkan kemiskinan suatu wilayah karena kemiskinan erat kaitannya dengan kepadatan populasi penduduk (Wilde et al., 2016), konsumsi energi yang erat kaitannya dengan kepadatan populasi penduduk menghasilkan SO_2 . Daerah dengan jumlah populasi penduduk tinggi akan memiliki polusi SO_2 yang tinggi, begitu pula sebaliknya.

2.1.4 Point of Interest (POI)

Point of interest (POI) adalah istilah yang digunakan dalam kartografi (mengacu pada peta atau *geodataset*) untuk mewakili fitur tertentu yang menempati titik tertentu. POI yang diperoleh melalui OpenStreetMap (OSM) merupakan salah satu contoh *geospatial big data*, data ini dapat memberikan informasi terkait struktur perkotaan dan fasilitas ekonomi. (Yao, Li, et al., 2017). Data yang diturunkan dari POI seperti POI *density* dan POI *distance* dapat menunjukkan kenyamanan populasi untuk melancarkan kegiatan produksi dan derajat pembangunan sosioekonomi yang sangat berkaitan dengan kemiskinan (Shi et al,

2020). Pada penelitian sebelumnya (Tingzon, Orden, Sy, Sekara, Weber, Fatehkia, Garcia, et al., 2019), turunan data POI dapat menunjukkan kemiskinan.

POI yang diperoleh melalui OpenStreetMap merupakan *geospatial big data* karena memenuhi ketiga karakteristik *big data* yang didefinisikan Zikopoulos & Eaton (2011), yaitu volume, *velocity*, dan *variety*. Dari karakteristik volume, dataset POI berisi miliaran titik lokasi yang tersebar di seluruh dunia. Dari karakteristik *velocity*, POI diperbarui secara *real-time* berdasarkan poin yang ditambahkan oleh pengguna OpenStreetMap. Dari karakteristik *variety*, pemanfaatan data POI sebagai proksi kemiskinan memerlukan penghitungan khusus seperti POI *density* yang diperkenalkan oleh Shi et al. (2020) dan POI *distance* yang diperkenalkan oleh Tingzon et al. (2019).

2.1.5 Machine Learning

Machine learning adalah bagian dari pendekatan kecerdasan artifisial (*Artificial Intelligence*; AI) yang berusaha untuk mempelajari secara otomatis hubungan dan pola bermakna dari contoh dan pengamatan berupa data yang sudah ada (Bishop & Nasrabadi, 2006). Model *machine learning* banyak digunakan untuk melakukan estimasi karena berfokus pada pencapaian akurasi terbaik yang tentunya sangat dibutuhkan dalam kasus estimasi (Moroff et al., 2021). Tidak seperti model statistika yang bergantung pada banyak asumsi, model *machine learning* tidak banyak terikat asumsi dan cenderung menghasilkan performa yang lebih baik pada data yang tidak dikontrol dengan hati-hati pada pengumpulannya atau desain eksperimennya (seperti *big data*) serta cenderung lebih baik pada data dengan hubungan nonliner atau interaksi yang rumit (Ij, 2018). Namun, meskipun

cenderung menghasilkan prediksi yang lebih baik pada kasus tersebut, model *machine learning* sulit untuk diinterpretasikan (Ij, 2018).

Algoritma *machine learning* diklasifikasikan menjadi beberapa kategori menurut tujuannya yaitu *supervised learning*, *unsupervised learning*, *semi-supervised learning*, dan *reinforcement learning* (Belaidouni & Miraoui, 2016). Pada *supervised learning*, data yang sudah dilabeli dengan nilai sebenarnya digunakan untuk melatih algoritma. Permasalahan pada *supervised learning* dapat dikategorikan menjadi kasus klasifikasi dan kasus regresi. Kasus klasifikasi adalah ketika variabel keluaran adalah kategori, seperti Ya/Tidak, Benar/Salah, atau kasus multilabel. Sebaliknya, kasus regresi adalah ketika ingin memetakan input ke output dengan tipe data kontinu seperti berat badan, tinggi badan, dan lain sebagainya. Pembahasan berikut akan berfokus pada algoritma-algoritma *machine learning* yang dapat digunakan pada kasus regresi.

2.1.5.1 Decision Tree Regression (DTR)

Dalam pemodelan *decision tree*, pohon (*tree*) mewakili segmentasi data yang dibuat dengan menerapkan serangkaian aturan sederhana (Rathore & Kumar, 2016). Pembangunan model *decision tree* dilakukan dengan membagi domain data (*node*) secara rekursif menjadi dua *subdomain* sedimikian rupa sehingga *subdomain* memiliki perolehan informasi yang lebih tinggi daripada simpul yang terbelah (Suthaharan, 2016). Metode *decision tree* untuk kasus regresi disebut *decision tree regression*. Adapun keuntungan utama dari *decision tree regression* dibandingkan teknik pemodelan lainnya adalah menghasilkan model yang dapat mewakili aturan yang dapat lebih mudah diinterpretasikan (Gilpin et al., 2018).

2.1.5.2 Random Forest Regression (RFR)

Random forest dapat didefinisikan sebagai metode ansambel pohon keputusan (*decision tree*), model ini menggunakan banyak pohon keputusan yang mengambil secara acak data latih untuk dipelajari (Breiman, 2001). Masing-masing pohon keputusan memberikan suara (*voting*) untuk menentukan keputusan hasil prediksi. Pemilihan fitur memainkan peran kunci utama pada pembangunan model ini karena *random forest* mencoba untuk memilih fitur paling penting dalam konstruksi pohon keputusan (Breiman, 2001).

2.1.5.3 Support Vector Regression (SVR)

Support Vector Regression (SVR) adalah implementasi *Support Vector Machine* (SVM) pada kasus regresi. SVM dapat secara sederhana didefinisikan sebagai usaha pencarian garis pemisah atau *hyperplane* terbaik yang dapat memisahkan dua kelas *input* data (Somvanshi et al., 2016). Konsep SVR didasarkan pada peminimalan resiko, yaitu untuk mengestimasi fungsi dengan cara meminimalkan batas atas dari *error* general, sehingga SVR mampu mengatasi *overfitting* (Yasin et al., 2014).

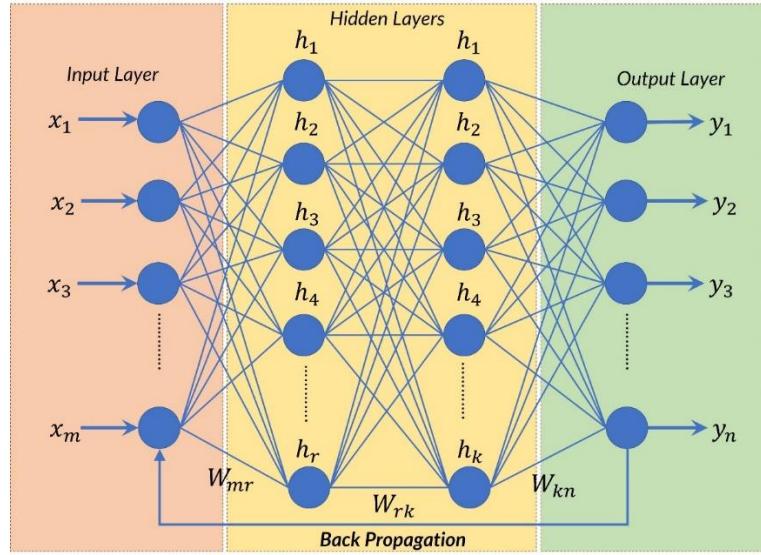
2.1.6 Deep Learning

Deep learning adalah bagian khusus dari *machine learning* dengan kekuatan dan fleksibilitas luar biasa dalam merepresentasikan dunia sebagai konsep hierarki bersarang (tumpukan *layer*), dengan setiap *layer* mengandung konsep yang lebih sederhana dan lebih abstrak (Bengio et al., 2017). *Deep learning* adalah representasi jaringan saraf *neural network* dengan *layer* yang lebih dalam.

Deep learning menemukan struktur rumit dalam kumpulan data besar dengan menggunakan algoritma *backpropagation* untuk menunjukkan bagaimana mesin harus mengubah parameter internalnya yang digunakan untuk menghitung representasi di setiap lapisan dari representasi di *layer* sebelumnya (LeCun et al., 2015). *Multiple Layer Perceptron* (MLP) dan *Convolutional Neural Network* adalah contoh algoritma yang mengimplementasikan konsep *deep learning*.

2.1.6.1 Multi Layer Perceptron (MLP)

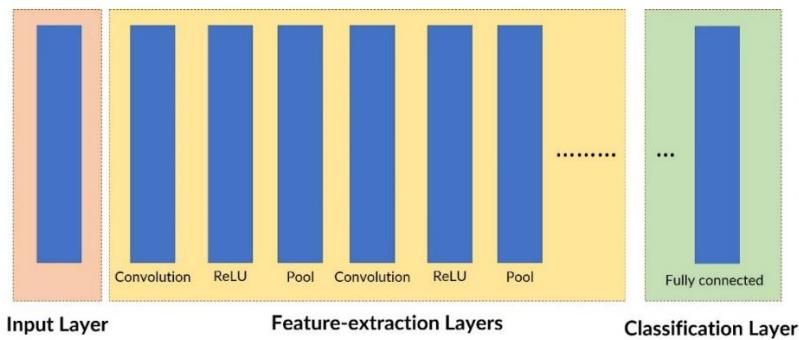
Multi Layer Perceptron (MLP) adalah arsitektur *feed forward neural network* dengan banyak lapisan *perceptron* yang difusikan (Sen et al., 2020). MLP secara umum tersusun atas tiga jenis lapisan (*layer*) yaitu *input layer*, *hidden layer* dan *output layer* seperti yang diilustrasikan pada Gambar 3 (Abirami & Chitra, 2020). *Input layer* menerima data untuk diproses, *hidden layer* yang berada diantara *input* dan *output layer* memegang peranan penting dalam komputasi pada arsitektur MLP, *output layer* bertugas melakukan prediksi nilai pengeluaran berdasarkan penghitungan dari pada *hidden layer*. Pada arsitektur ini data mengalir maju (*feed forward*) dan *perceptron* dalam MLP dilatih dengan algoritma *back propagation* (Abirami & Chitra, 2020).



Gambar 3. Arsitektur MLP

2.1.6.2 Convolutional Neural Network-1D (CNN-1D)

Convolutional neural network (CNN) adalah jenis *feed-forward neural network* yang secara umum terdiri dari operasi konvolusi yang diikuti proses *pooling* (LeCun et al., 1998). Terdapat tiga bagian utama CNN seperti yang diilustrasikan pada Gambar 4 yaitu *input layer*, *feature-extraction layers*, dan *classification layer* (Patterson & Gibson, 2017).



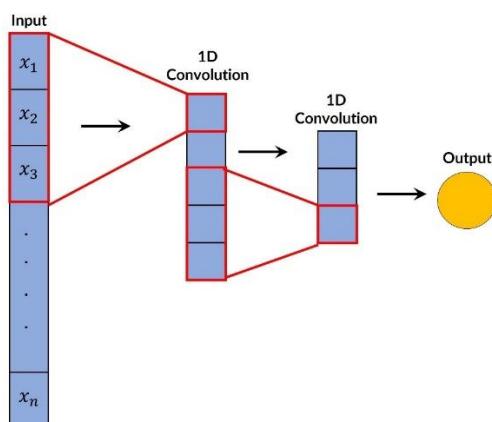
Gambar 4. Bagian Utama CNN

Input layer menerima input data, *feature-extraction layer* terdiri atas urutan berulang *convolutional* dan *pooling layer* dengan *Rectified Linear Unit* (ReLU)

sebagai fungsi aktivasi. Lapisan ini mengekstrak sejumlah fitur dalam gambar dan secara progresif membangun fitur tingkat tinggi. Lapisan terakhir, *classification layer*, berisi *fully connecter layer* untuk mengambil urutan yang lebih tinggi fitur dan menghasilkan probabilitas kelas untuk tugas klasifikasi, atau nilai nyata untuk regresi.

Sederhananya, konvolusi merubah *input data* dengan menggunakan *patch* persegi (*kernel* atau filter) yang terhubung secara lokal ke *neuron* di lapisan sebelumnya. *Convolutional layer* adalah bagian inti dari arsitektur CNN. Tujuan dari lapisan ini adalah untuk mempelajari fitur tingkat tinggi dalam data melalui operasi matematika yang disebut konvolusi. Lapisan ini akan menghitung *dot product* antara wilayah *neuron* di *input layer* dan nilai-nilai dalam *kernel (weights)* (Patterson & Gibson, 2017).

CNN-1D (*Convolutional Neural Network-1D*) adalah aplikasi CNN dengan input berupa matriks satu dimensi. CNN-1D telah banyak diaplikasikan pada kasus yang pengklasifikasian citra satelit hasil *remote sensing* (Nurmasari, 2021; Saadi, 2021). Gambar 5 menunjukkan ilustrasi konvolusi pada *convolutional layer* pada CNN-1D menurut (Shenfield & Howarth, 2020).



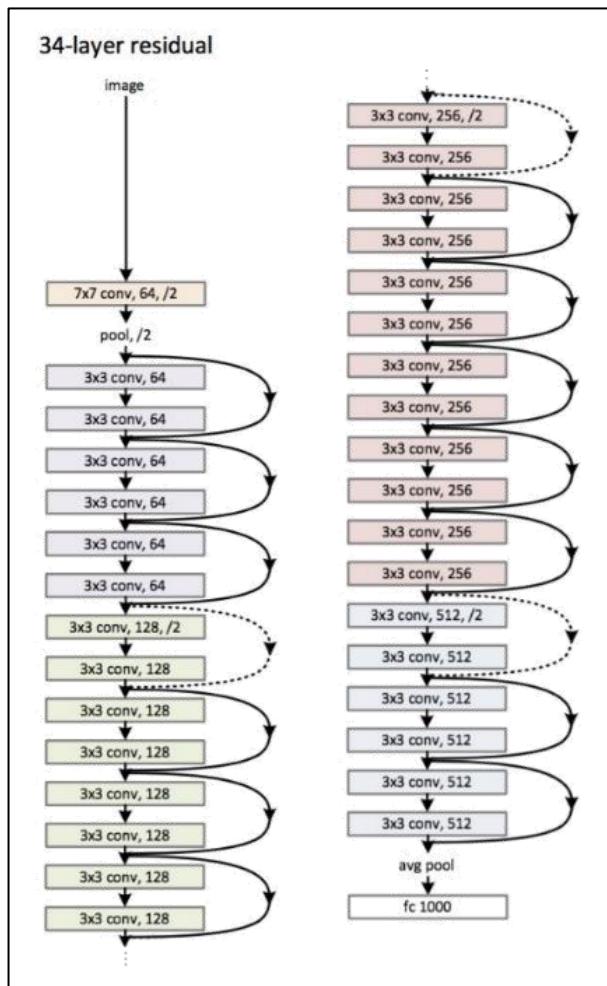
Gambar 5. Konvolusi pada CNN-1D

2.1.7 Transfer Learning

Terdapat beberapa hal yang dapat menentukan kualitas model CNN. Salah satunya adalah jumlah data yang digunakan untuk pembangunan model. Data latih (*train data*) yang lebih banyak akan menghasilkan model dengan performa yang lebih baik. Sumber daya yang cukup juga diperlukan untuk mengembangkan model dari awal. Strategi untuk mengatasi masalah tersebut adalah dengan menggunakan model CNN dengan kualitas hasil baik yang telah dilatih sebelumnya dan kemudian melatihnya lebih lanjut untuk melakukan tugas lain. Idenya adalah dengan mengambil pengetahuan yang dipelajari pada *pre-trained model* dan menerapkannya pada tugas baru. *Pre-trained model* adalah model yang dibuat oleh orang lain untuk memecahkan masalah yang sama. Hal ini disebut sebagai *transfer learning* yang mana diimplementasikan sebagai jalan pintas untuk mempercepat proses pelatihan dan meningkatkan kinerja model pembelajaran mendalam (Patterson & Gibson, 2017).

ResNet adalah arsitektur yang sering diimplementasikan untuk kasus *transfer learning*. ResNet (*residual network*) merupakan arsitektur CNN yang mengimplementasikan infrastruktur *residual building block*. Sebuah pintasan (*shortcut connection*) digunakan oleh pada *residual building block* untuk melewati setiap *convolutional layer* yang secara efektif mengurangi masalah hilangnya gradien atau ledakan gradien akibat peningkatan kedalaman di jaringan saraf (Wen et al., 2020). Hal ini dapat membantu dalam pembangunan struktur CNN yang lebih fleksibel dan dapat digunakan pada pembangunan arsitektur jaringan saraf yang

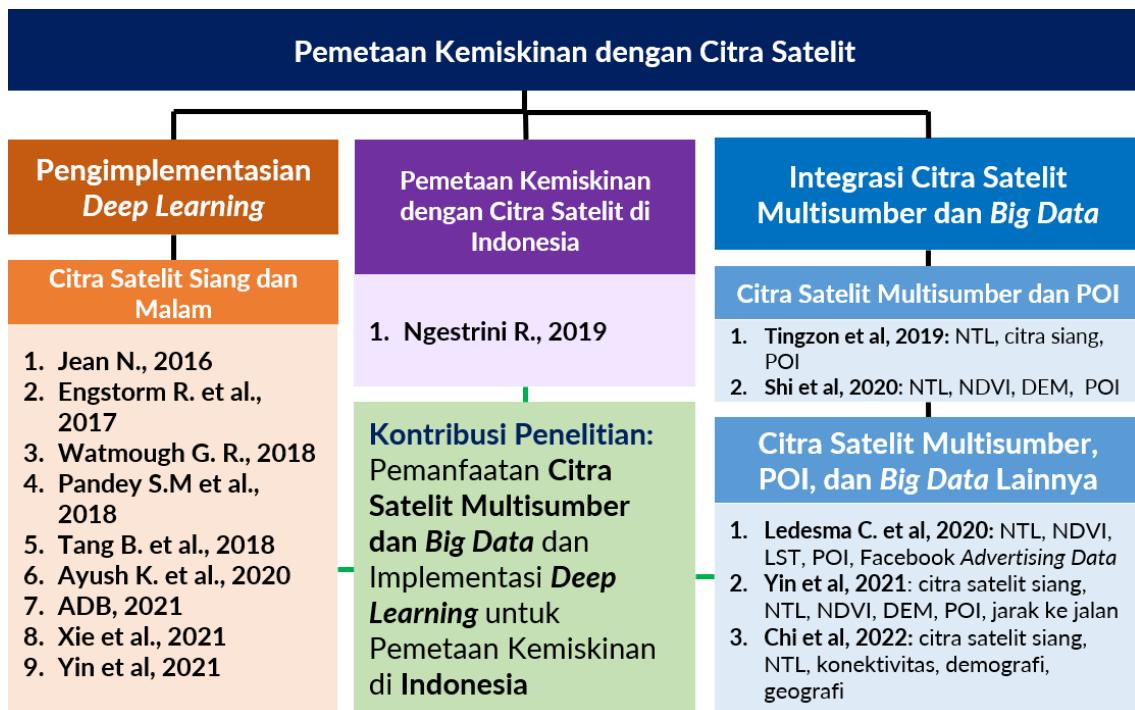
lebih dalam tanpa harus menggunakan memori yang besar sehingga dapat mendukung performa kinerja model. Gambar 6 menunjukkan visualisasi arsitektur Resnet-34.



Gambar 6. Visualisasi Arsitektur ResNet-34

2.2 Penelitian Terkait

Gambar 7 merupakan peta literatur yang menjelaskan secara sistematis penelitian terdahulu yang melandasi penelitian ini.



Gambar 7. Peta Literatur

Penelitian terkait penggunaan citra satelit untuk estimasi kemiskinan, khususnya dengan mengimplementasikan *deep learning* pada citra satelit siang dan malam hari, pertama kali dilakukan oleh Jean et al, (2016) yang kemudian banyak diimplementasikan pada penelitian-penelitian selanjutnya. Hasil yang diperoleh menunjukkan bahwa model yang dibangun dapat membedakan secara semantik fitur bermakna seperti wilayah perkotaan, jalan, badan air, daerah pertanian, dan lain-lain. Model ini dapat digunakan untuk pemetaan kemiskinan level *grid* di beberapa negara Afrika, Filipina, Thailand, dan wilayah lainnya. Di Indonesia, penelitian serupa masih sangat terbatas, Ngestrin (2019) memetakan kemiskinan Indonesia pada level *grid* 5 km dengan mengadopsi metode pada penelitian sebelumnya dan memperoleh akurasi sekitar 70%.

Di sisi lain, pada banyak penelitian internasional, topik penelitian ini semakin banyak dikaji dan terus dikembangkan. Misalnya melalui penggunaan *big data* fusi citra satelit multisumber dan POI. Hasil yang diperoleh menunjukkan bahwa penggunaan *big data* citra satelit multisumber dan *big data* lainnya seperti POI dapat digunakan untuk memetakan kemiskinan di berbagai wilayah studi seperti China, Filipina, dan beberapa negara di Afrika (Chi et al., 2022; Yin et al., 2020). Sayangnya, pengembangan ini masih belum pernah diterapkan di Indonesia. Selain itu, pengimplementasian *deep learning* pada citra satelit multisumber dan POI masih belum pernah dilakukan sebelumnya.

Tabel 4 secara komprehensif menjelaskan beberapa penelitian terdahulu yang menjadi landasan utama penelitian ini. Berdasarkan Gambar 7, Tabel 4, dan uraian sebelumnya maka dapat disimpulkan bahwa kontribusi penelitian ini adalah pada 1) pemanfaatan *big data* citra satelit multisumber dan POI untuk pemetaan kemiskinan di Indonesia, 2) pengimplementasian *deep learning* pada *big data* citra satelit multisumber dan POI.

Tabel 4. Penelitian Terdahulu yang Memanfaatkan *Big Data* Citra Satelit Multisumber dan POI untuk Pemetaan Kemiskinan

No.	Pengarang	Tujuan	Metode	Lokasi Studi	Data dan Sumber Data	Akses
(1)	(2)	(3)	(4)	(5)	(6)	(7)
1.	Jean et al., 2016	Membangun model estimasi kemiskinan	<i>Transfer Learning</i> (Resnet34) dan <i>ridge regression</i>	Negara-negara di Afrika	Citra satelit siang hari: Google Static Maps	Terbatas
					Citra satelit malam hari: DMSP OLS	Terbuka
2.	Martinez et al., 2020	Membangun model estimasi kemiskinan	<i>Transfer Learning</i> (Resnet34) dan <i>ridge regression</i>	Filipina dan Thailand	Citra satelit siang hari: Sentinel-2 dan Landsat-8	Terbuka
					Citra satelit malam hari: NOAA-VIIRS	Terbuka
3.	Ngestrini, 2019	Membangun model estimasi kemiskinan	<i>Transfer Learning</i> (Resnet34) dan <i>ridge regression</i>	Indonesia	Citra satelit siang hari: Google Static Maps	Terbatas
					Citra satelit malam hari: DMSP OLS	Terbuka
4.	X. Zhao et al., 2019	Membangun model estimasi kemiskinan	<i>Machine learning</i>	Bangladesh dan Nepal	NTL: VIIRS-NOAA	Terbuka
					Peta tutupan lahan: Landsat-8	Terbuka
					POI: Baidu API	Terbuka
					Data penyewaan rumah	Terbatas
5.	Ledesma et al., 2020	Membangun model estimasi kemiskinan	Regresi linier dan <i>machine learning</i>	Filipina	<i>Social media advertising data:</i> Facebook API	Terbatas
					NTL: VIIRS	Terbuka
					<i>Land surface temperature:</i> MODIS	Terbuka
					NDVI : Landsat-7	Terbuka
					POI : Open Street Map	Terbuka
6.	Shi et al., 2020		Pembangunan indeks		NTL: VIIRS	Terbuka

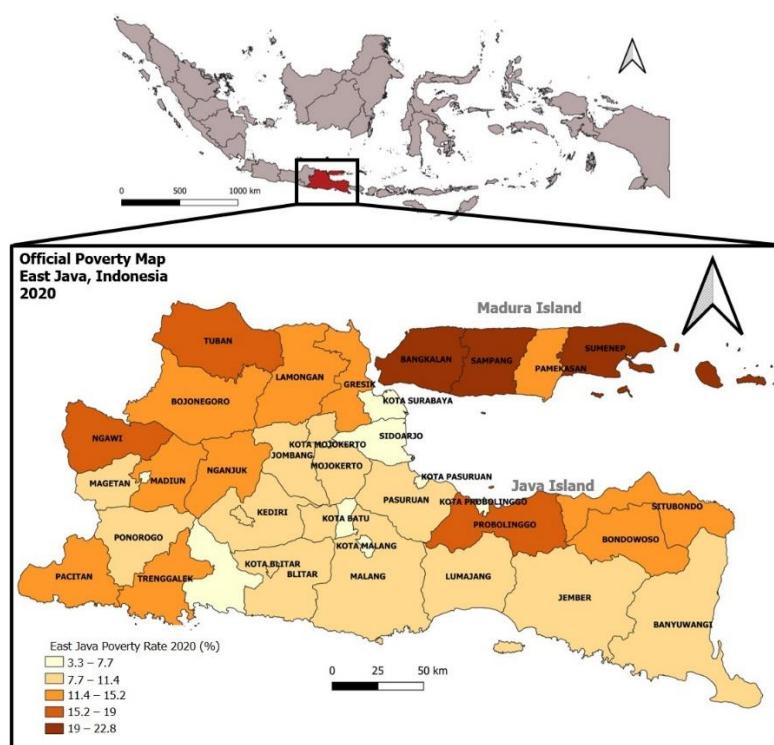
No.	Pengarang	Tujuan	Metode	Lokasi Studi	Data dan Sumber Data	Akses
(1)	(2)	(3)	(4)	(5)	(6)	(7)
7.	Xu et al., 2021	Membangun <i>comprehensive poverty index</i> (CPI)	<i>Machine learning</i>	Chongqing, China	<i>Digital Elevation Model (DEM): SRTM</i>	Terbuka
					<i>NDVI: Geospatial Data Cloud</i>	Terbuka
					<i>POI: Open Street Map</i>	Terbuka
8.	Puttanapong et al., 2022	Membangun model estimasi kemiskinan	<i>Machine learning</i>	China bagian tenggara	NTL: VIIRS	Terbuka
					<i>Digital Elevation Model (DEM): SRTM</i>	Terbuka
					Tutupan lahan: FROM-GLC	Terbuka
					Data aksesibilitas ke kota: <i>Malaria Atlas Project</i>	Terbuka
					NTL: DMSP-OLS dan VIIRS-	Terbuka
9.	Topik Penelitian	Prediksi pemetaan kemiskinan dengan resolusi spasial 1,5 km	<i>Membangun relative spatial poverty index (RSPI) dan model estimasi kemiskinan dengan pendekatan deep learning</i>	Thailand	NOAA	Terbuka
					LST: MODIS	Terbuka
					NDVI: MODIS	Terbuka
					POI: OpenStreetMap dan lain-lain.	Terbuka
					NTL: VIIRS	Terbuka
					NDVI, BUI, NDWI: Sentinel-2	Terbuka
				Jawa Timur, Indonesia	CO, NO ₂ , SO ₂ : Sentinel-5P	Terbuka
					LST: MODIS	Terbuka
					POI Density, POI Distance: OSM	Terbuka
					Citra satelit siang hari: Sentinel-2	Terbuka

BAB III

METODOLOGI

3.1 Ruang Lingkup Penelitian

Penelitian ini mengambil wilayah studi kasus di Provinsi Jawa Timur, Indonesia dengan tahun referensi 2020. Jawa Timur adalah provinsi terluas di Pulau Jawa dengan 38 kabupaten/kota dan 666 kecamatan. Jawa Timur dipilih sebagai wilayah studi pada panelitian ini karena merupakan provinsi dengan jumlah penduduk miskin terbanyak di Indonesia pada tahun 2015-2021 menurut BPS (BPS, 2021).



Gambar 8. Provinsi Jawa Timur sebagai Wilayah Studi dan Angka Kemiskinan Resmi Level Kabupatennya

Kemiskinan Jawa Timur terkonsentrasi di kabupaten-kabupaten di Pulau Madura, bagian timur laut provinsi Jawa Timur. Pada tahun 2020, kemiskinan Kabupaten Sampang tertinggi di Jawa Timur mencapai 22,78%, disusul Bangkalan (20,56%), dan Sumenep (20,18%) (BPS, 2020). Kota Batu (3,89%) dan Kota Malang (4,44%) adalah kota dengan tingkat kemiskinan terendah di Jawa Timur (BPS, 2020). Kota Surabaya sebagai kota metropolitan terbesar di Jawa Timur dan terbesar kedua di Indonesia memiliki tingkat kemiskinan terendah keempat di angka 5,02% (BPS, 2020; Santoso & Aulia, 2018).

3.2 Metode Penelitian

3.2.1 Data dan Sumber Data

Terdapat empat jenis data yang digunakan dalam penelitian ini. Pertama, *Dataset 1* yang mencakup indikator kemiskinan dari citra satelit hasil penginderaan jauh yang diperoleh dari *big data* geospasial citra satelit multisumber dan POI. Citra satelit multisumber yang digunakan pada penelitian ini di antaranya *nighttime light intensity* (NTL) dari NOAA-VIIRS, *Normalized Difference Vegetation Index* (NDVI), *Built-up Index* (BUI), and *Normalized Difference Water Index* (NDWI) dari Sentinel-2, *Land Surface Temperature* (LST) dari MODIS, *Carbon Monoxide* (CO), *Nitrogen Dioxide* (NO₂), and *Sulfur Dioxide* (SO₂) dari Sentinel-5P. Citra satelit multisumber yang dikumpulkan tersebut merupakan indikator kemiskinan sesuai studi literatur dan penelitian sebelumnya serta telah diidentifikasi secara visual oleh peneliti untuk kondisi citra Provinsi Jawa Timur. Sumber data citra satelit hasil penginderaan jauh yang dipilih adalah sumber yang menyediakan citra satelit dengan resolusi tertinggi yang aksesnya terbuka dan gratis. Data citra satelit

penginderaan jauh dikumpulkan dan diproses sebelumnya melalui *Google Earth Engine*, *platform* berbasis *cloud* yang dirancang untuk menyimpan dan memproses data geografis bumi. *Google Earth Engine* mendukung pemrosesan data citra satelit sampai kasus klasifikasi (Nurmasari & Wijayanto, 2021; Putri & Wijayanto, 2021; Saadi & Wijayanto, 2021).

Big data geospasial *Point of Interest* (POI) yang digunakan pada penelitian ini dikumpulkan dari OpenStreetMap (OSM). POI difilter untuk mendapatkan titik-titik yang terkait dengan kemiskinan menurut penelitian sebelumnya (Ledesma, Garonita, Flores, Tingzon, et al., 2020; Tingzon, Orden, Sy, Sekara, Weber, Fatehkia, Herranz, et al., 2019). Dalam penelitian ini, POI diambil pada bulan Juli 2020. Terdapat lebih dari 13.000 POI yang dikumpulkan dari empat kategori (pendidikan, kesehatan, ekonomi, dan tempat wisata) meliputi hotel, restoran, rumah sakit, objek wisata, sekolah, teater, *mall*, universitas, dan lain-lain. Data ini menggambarkan aksesibilitas suatu wilayah.

Kedua, *Dataset 2* yang mencakup citra satelit siang dan malam hari. Citra satelit siang hari yang digunakan pada penelitian ini adalah tangkapan foto permukaan bumi pada siang hari yang diperoleh dari penginderaan satelit Sentinel-2. Citra satelit siang hari yang diperoleh merupakan citra *multiband* yang terdiri atas tiga pita spektral yaitu *red*, *green*, dan *blue* (RGB). Citra satelit malam hari yang digunakan pada *Dataset 2* sama dengan *Dataset 1* yaitu bersumber dari penginderaan satelit NOAA-VIIRS. Data citra satelit siang dan malam hari diperoleh dan di-*preprocess* melalui *Google Earth Engine* (GEE).

Cakupan wilayah dan referensi waktu pengumpulan citra satelit pada *Dataset 1* dan *Dataset 2* adalah Provinsi Jawa Timur pada 1 Januari - 31 Desember

2020. Data yang digunakan dalam penelitian ini disajikan secara sistematis pada Tabel 5. Dari Tabel 5 terlihat bahwa resolusi spasial satelit tertinggi adalah Sentinel-2 (10 m) dan terendah adalah Sentinel-5P (1,1 km). Untuk mengakomodasi resolusi terendah, peta kemiskinan resolusi spasial 1,5 km dipilih sebagai output dari penelitian ini.

Ketiga, data tingkat kemiskinan resmi. Data tingkat kemiskinan resmi pada level kabupaten/kota diperoleh berdasarkan SUSENAS 2020. Untuk kepentingan pembangunan model estimasi pada Tujuan 2, digunakan data tingkat kemiskinan di level kecamatan yang diperoleh dengan pendekatan *Small Area Estimation* (SAE) sederhana *Broad Area Ratio Estimation* (BARE). Pendekatan ini sudah banyak digunakan pada beberapa penelitian serupa (Asian Development Bank, 2020; Coondoo et al., 2011).

Keempat, data tambahan yaitu estimasi kepadatan populasi pada level *grid* 100 m yang diperoleh dari BPS. Estimasi tersebut diperoleh berdasarkan data Sensus Penduduk 2020. Data ini digunakan pada penelitian untuk mengeksklusikan daerah yang tidak berpenduduk pada peta estimasi kemiskinan karena kemiskinan erat kaitannya dengan keberadaan penduduk (Wilde et al., 2016).

Tabel 5. Data yang Digunakan pada Penelitian

No.	Variabel	Pendekatan Kemiskinan	Referensi	Sumber Data	Tahun	Periode Pembaruan	Level Penyajian	Korelasi dengan Kemiskinan*
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
Dataset 1								
1.	<i>Nighttime Light Intensity</i> (NTL)	Deteksi sebaran aktivitas ekonomi	(Chen et al., 2015; Elvidge et al., 2009; Ghosh et al., 2013; Shi et al., 2015, 2019; Yu et al., 2018; N. Zhao et al., 2017; Naizhuo Zhao et al., 2020; N. Zhou et al., 2015)	NOAA-VIIRS	2020	1 bulan	<i>Grid</i> 750 m	Negatif
2.	<i>Normalized Difference Vegetation Index</i> (NDVI)	Deteksi daerah pedesaan menurut vegetasi	(Ahmed, 2018; Dawson et al., 2018; Zheng et al., 2021)	Sentinel-2	2020	5 hari	<i>Grid</i> 10 m	Positif
3.	<i>Built-Up Index</i> (BUI)	Deteksi daerah urban menurut sebaran bangunan	(Kaimaris & Patias, 2016; Lee et al., 2010)					Negatif
4.	<i>Normalized Difference Water Index</i> (NDWI)	Deteksi tutupan lahan	(Ahmed, 2018; Zheng et al., 2021)					Positif

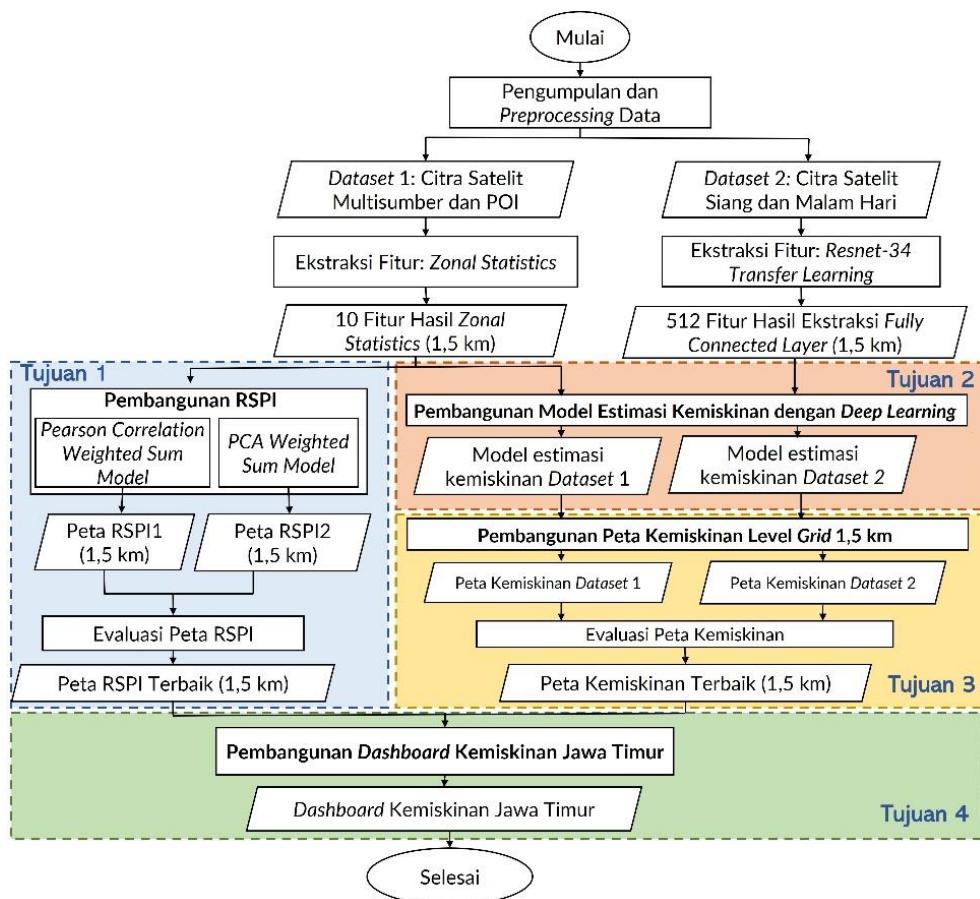
No.	Variabel	Pendekatan Kemiskinan	Referensi	Sumber Data	Tahun	Periode Pembaruan	Level Penyajian	Korelasi dengan Kemiskinan*)
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
5.	<i>Land Surface Temperature (LST)</i>	Deteksi daerah urban menurut sebaran suhu permukaan	(Ahmed, 2018; Huang et al., 2011)	MODIS	2020	4 hari	<i>Grid</i> 1000 m	Negatif
6.	<i>Carbon Monoxide (CO)</i>	Deteksi aktivitas ekonomi berdasarkan polusi yang dihasilkan	(Yu Wang et al., 2021)	Sentinel-5P	2020	< 1 hari	<i>Grid</i> 1113,2 m	Negatif
7.	<i>Nitrogen Dioxide (NO₂)</i>		(Han et al., 2021)					Negatif
8.	<i>Sulfur Dioxide (SO₂)</i>		(Bakhsh et al., 2022)					Negatif
9.	<i>POI Density</i>	Menunjukkan kepadatan aktivitas ekonomi suatu wilayah	(Shi et al., 2020)	Open Street Map	2020	Dinamis	<i>Points</i>	Negatif
10.	<i>POI Distance</i>	Menunjukkan aksesibilitas suatu wilayah	(Ledesma, Garonita, Flores, & Tingzon, 2020; Tingzon, Orden, Sy, Sekara, Weber, Fatehkia, Garcia, et al., 2019)					Positif
Dataset 2								
11.	Citra Satelit Siang Hari (RGB)	Earth's surface daytime capture	(Jean et al., 2016b)	Sentinel-2	2020	5 hari	10 m	-

No.	Variabel	Pendekatan Kemiskinan	Referensi	Sumber Data	Tahun	Periode Pembaruan	Level Penyajian	Korelasi dengan Kemiskinan*)
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
12.	<i>Nighttime Light Intensity</i> (NTL)	Deteksi sebaran aktivitas ekonomi	(Chen et al., 2015; Elvidge et al., 2009; Ghosh et al., 2013; Shi et al., 2015, 2019; Yu et al., 2018; N. Zhao et al., 2017; Naizhuo Zhao et al., 2020; N. Zhou et al., 2015)	NOAA-VIIRS	2020	1 bulan	Grid 750 m	Negatif
Data Kemiskinan								
13.	Tingkat Kemiskinan Level Kabupaten	Persentase kemiskinan level kabupaten untuk pembangunan RSPI		SUSENAS	2020	1 tahun	Kabupaten/ Kota	-
14.	Tingkat Kemiskinan Level Kecamatan	Persentase kemiskinan level kecamatan untuk estimasi kemiskinan		SUSENAS, SP2020, and PBDT	2020 dan 2015 (PBDT)	1 tahun dan tidak diketahui (PBDT)	Kecamatan	-
Data Tambahan								
15.	Estimasi Populasi Grid	Kepadatan populasi level grid		BPS	2020	Tidak diketahui	Grid 100 m	Negatif

Ket: *) Korelasi dengan kemiskinan menurut referensi

3.2.2 Tahapan Penelitian

Output yang diharapkan pada penelitian ini adalah peta kemiskinan spasial yang memetakan indeks kemiskinan spasial relatif (*Relative Spatial Poverty Index; RSPI*) dan peta estimasi kemiskinan moneter pada resolusi spasial 1,5 km yang disajikan dalam *map dashboard* interaktif. Untuk mendapatkan hasil tersebut, dilakukan sejumlah tahap pada penelitian ini yang secara sistematis dijelaskan melalui diagram alir pada Gambar 9. Diagram Alir Penelitian. Keseluruhan tahapan penelitian ini dilakukan dengan memanfaatkan *Google Earth Engine* (GEE), QGIS 3.10.4, Python 3.6.9 dengan *Google Colab* dan *Google Drive*.



Gambar 9. Diagram Alir Penelitian

Penelitian dimulai dari pengumpulan dan *preprocessing* data sehingga didapat *Dataset 1* yaitu citra satelit multisumber dan POI serta *Dataset 2* yaitu citra

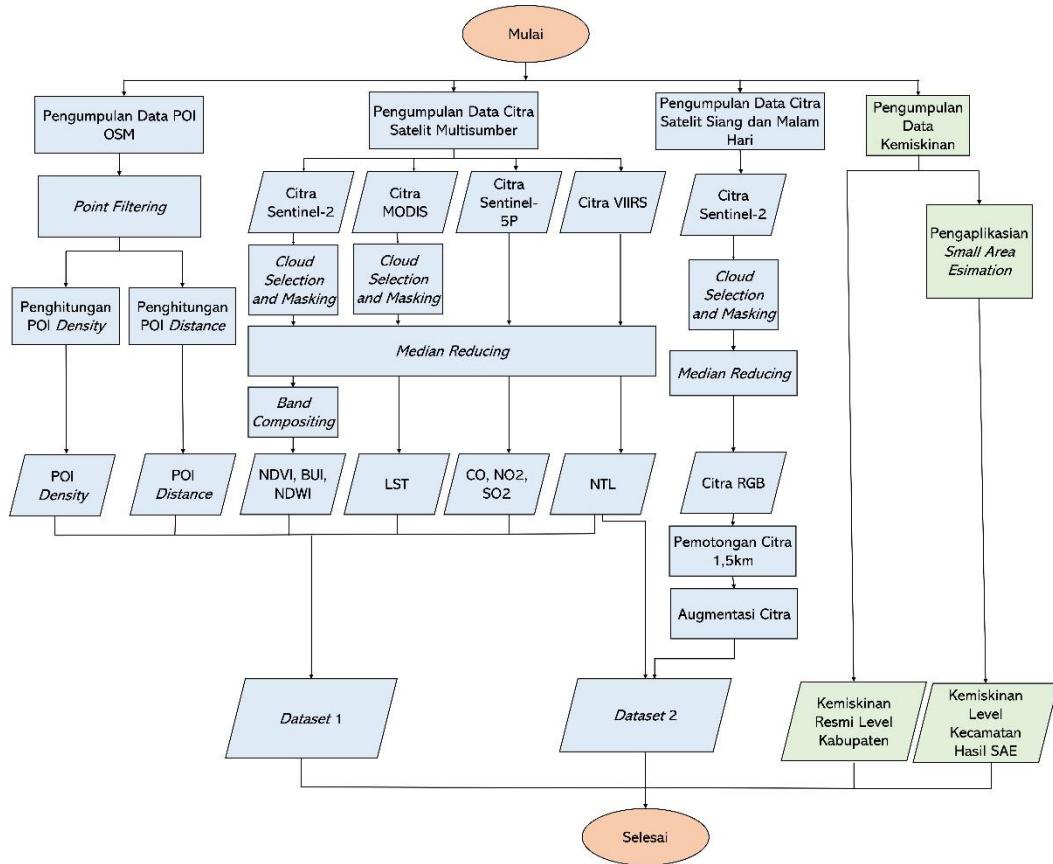
satelit siang dan malam hari. Ekstraksi fitur kemudian dilakukan pada masing-masing *dataset*. Ekstraksi fitur *zonal statistics* pada *Dataset 1* sehingga diperoleh *dataset* berisi sepuluh fitur citra satelit multisumber dan POI dengan resolusi spasial 1,5 km. Ekstraksi fitur berbasis *transfer learning* dengan arsitektur *Resnet-34* dilakukan pada *Dataset 2* sehingga diperoleh *dataset* berisi 512 fitur yang didapat dari *fully connected layer* model *Resnet-34* dengan resolusi spasial 1,5 km.

Hasil ekstraksi fitur *Dataset 1* kemudian digunakan untuk membangun indeks kemiskinan spasial relatif (RSPI) untuk memenuhi Tujuan 1. Untuk memenuhi Tujuan 2, model estimasi kemiskinan berbasis *deep learning* pada penelitian ini dibangun dengan dua skenario yaitu menggunakan hasil ekstraksi fitur *Dataset 1* dan *Dataset 2* sehingga diperoleh model estimasi kemiskinan *Dataset 1* dan model estimasi kemiskinan *Dataset 2*. Untuk memenuhi Tujuan 3, masing-masing model estimasi kemiskinan kemudian digunakan untuk membangun peta estimasi kemiskinan *Dataset 1* dan peta estimasi kemiskinan *Dataset 2*. Evaluasi numerik kemudian dilakukan untuk memilih peta kemiskinan terbaik. Peta kemiskinan terbaik kemudian disajikan pada *map dashboard* interaktif kemiskinan Jawa Timur berbasis *website* untuk memenuhi Tujuan 4.

3.2.2.1 Pengumpulan dan *Preprocessing* Data

Data yang dikumpulkan dari sumber data yang telah diuraikan kemudian di-*preprocess*. *Preprocessing data* adalah salah satu tahapan penting khususnya untuk menyiapkan data dan mengubahnya ke format yang sesuai untuk dianalisis (TamilSelvi et al., 2015). Dalam penelitian ini, *preprocessing* data sebagian besar bertujuan untuk membersihkan dan meningkatkan kualitas data untuk dianalisis.

Preprocessing menurut keempat jenis data yang digunakan pada penelitian ini dijelaskan secara sistematis melalui diagram alir pada Gambar 10.



Gambar 10. Diagram Alir Pengumpulan dan *Preprocessing* Data

***Preprocessing* Citra Satelit Multisumber**

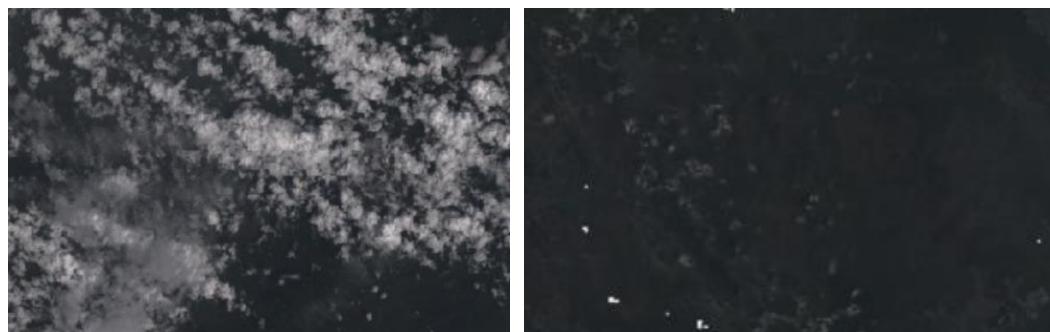
Data citra satelit hasil penginderaan jauh dikumpulkan dan di-*preprocess* melalui *Google Earth Engine*. *Preprocessing* yang dilakukan meliputi *cloud selection* dan *cloud masking* untuk mendapatkan kumpulan citra bebas awan, *median reducing* untuk mendapatkan nilai median citra yang dikumpulkan, dan komposisi *band* untuk mendapatkan nilai NDVI, BUI, dan NDWI.

Cloud selection dan *cloud masking* dari citra satelit Sentinel-2 dan MODIS dilakukan, berdasarkan *quality assessment* yang dijelaskan pada Tabel 6.

Tabel 6. Quality Assessment Band Satelit Sentinel-2 dan MODIS

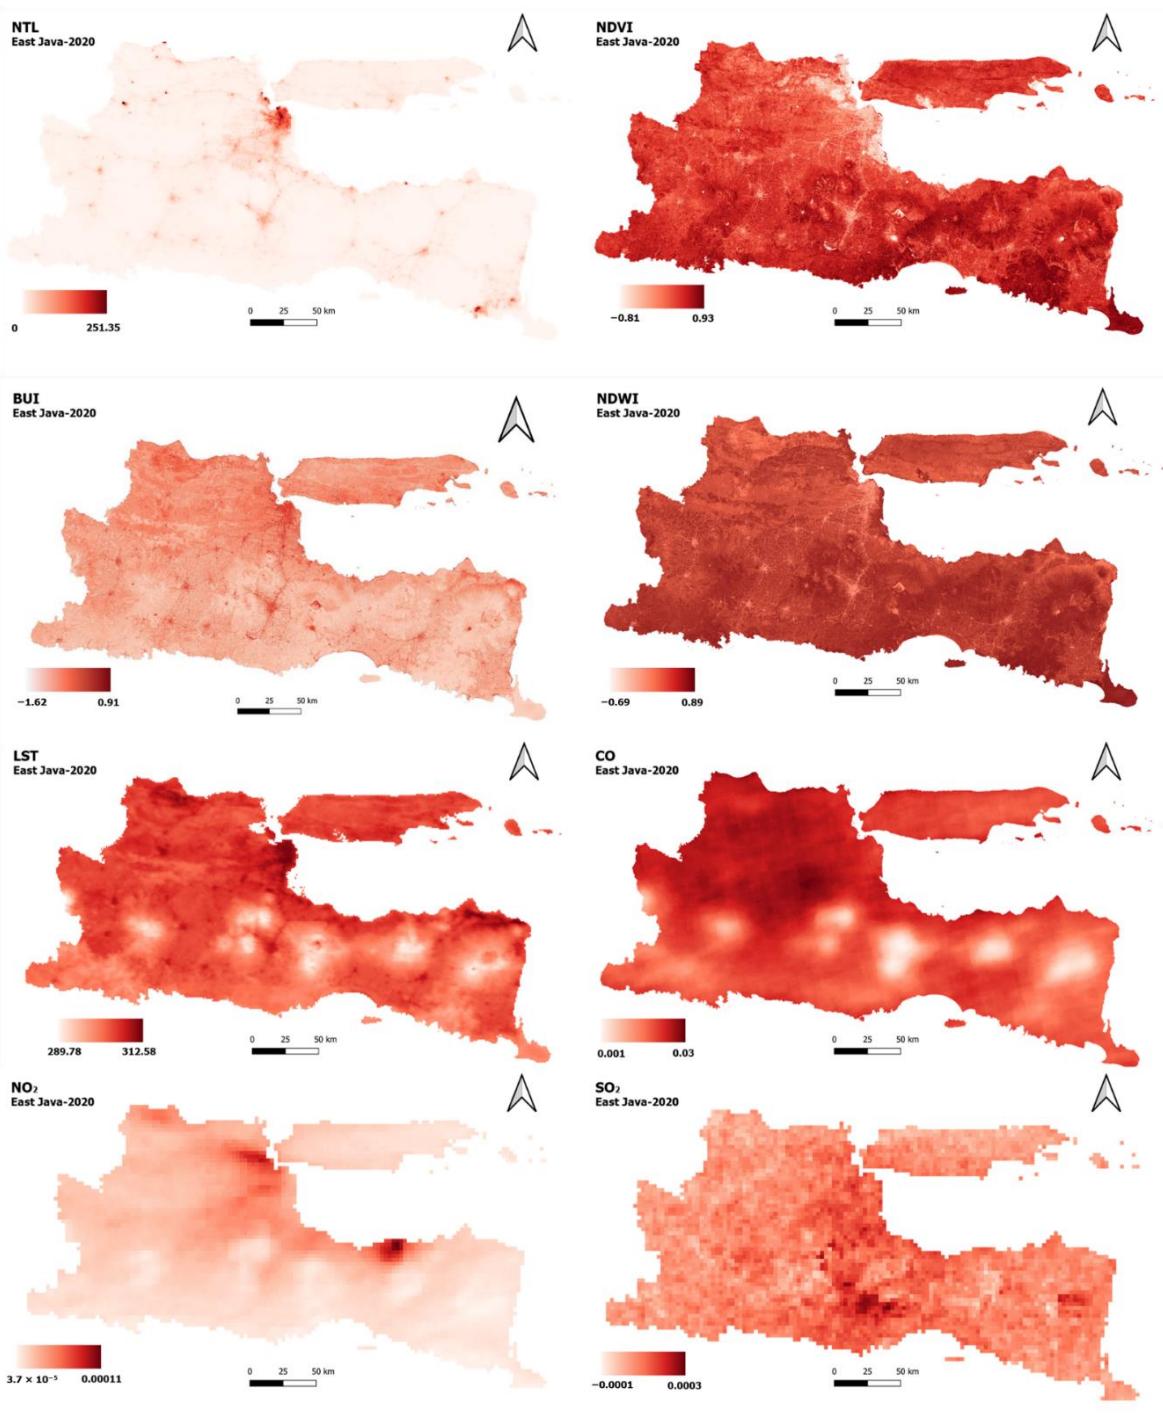
Sumber Satelit (1)	Pita (2)	<i>Quality Assessment</i> (3)	Nilai (4)
Sentinel-2	QA60	Bit 10 (<i>opaque clouds</i>)	0
		Bit 11 (<i>cirrus clouds</i>)	0
MODIS Terra LST Daily	QC_Day	Bits 0–1 (<i>Mandatory QA flags</i>)	0

Data NTL yang terkumpul merupakan citra komposit yang telah dikoreksi tutupan awan menggunakan produk VIIRS *Cloud Mask* (VCM). Reduksi median kemudian dilakukan untuk mendapatkan satu nilai untuk setiap pengamatan yang mewakili citra satelit dari satu tahun. Gambar 11 menunjukkan ilustrasi bagaimana *cloud selection* dan *cloud masking* serta *median reducing* dilakukan pada citra Sentinel-2.



Gambar 11. Visualisasi Citra yang Banyak Tertutup Awan (kiri) dan Citra yang Sudah Melalui Tahap *Cloud Selection* dan *Cloud Masking* serta *Median Reducing* (kanan)

Untuk mendapatkan nilai NDVI, BUI, dan NDWI dari citra Sentinel-2, dilakukan *band compositing* dengan menggunakan formula yang dijelaskan pada persamaan pada bagian 2.1.3.2. Gambar 12 menunjukkan visualisasi citra satelit berwarna yang telah dikumpulkan dan di-*preprocess*.



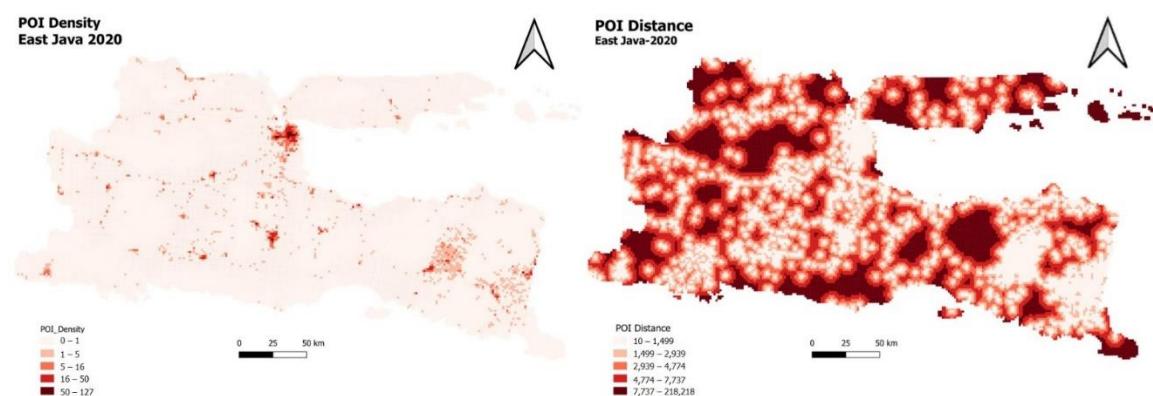
Gambar 12. Visualisasi data raster yang diperoleh: NTL (nanowatts/cm²/sr), NDVI (indeks), BUI (indeks), NDWI (indeks), LST (Kelvin), CO (mol/m²), NO₂ (mol/m²), and SO₂ (mol/m²).

Preprocessing Point of Interest (POI)

Point of Interest (POI) diperoleh dengan memanfaatkan API OSM.

Preprocessing kemudian dilakukan untuk memfilter *points* yang menunjukkan kemiskinan pada penelitian sebelumnya (Ledesma, Garonita, Flores, Tingzon, et al., 2020; Tingzon, Orden, Sy, Sekara, Weber, Fatehkia, Herranz, et al., 2019). Dalam penelitian ini, POI diambil pada bulan Juli 2020. Terdapat lebih dari 13.000 POI yang dikumpulkan dari empat kategori (pendidikan, kesehatan, ekonomi, dan tempat wisata) meliputi hotel, restoran, rumah sakit, objek wisata, sekolah, teater, *mall*, universitas, dan lain-lain.

Preprocessing dilanjutkan dengan menghitung POI *Density* dan POI *Distance*. POI *Density* diperoleh dengan menghitung jumlah POI pada level *grid* 1,5 km. POI *distance* diperoleh dengan menghitung jarak *euclidean* titik tengah *grid* 1,5 km ke POI terdekat. Gambar 13 menunjukkan visualisasi hasil *preprocessing* yang dilakukan.



Gambar 13. Visualisasi data yang diperoleh dari POI

Preprocessing Citra Satelit Siang dan Malam Hari

Untuk membangun model estimasi menggunakan citra satelit siang dan malam hari, dilakukan *preprocessing* citra satelit seperti yang dijelaskan pada

bagian sebelumnya, meliputi *cloud selection* dan *cloud masking*, serta *median reducing*. Sehingga didapat tangkapan foto permukaan bumi pada siang hari yang diilustrasikan pada Gambar 14.



Gambar 14. Citra Satelit Siang Hari (RGB) Jawa Timur

Citra siang hari yang diperoleh kemudian dipotong dengan ukuran $1,5 \times 1,5$ km yang dilanjutkan dengan augmentasi. Pemotongan citra dilakukan dengan menggunakan fitur ‘*clip raster by mask layer*’ yang terdapat pada menu *Extraction* pada QGIS. Pemotongan dilakukan berdasarkan *vector grid* 1,5 km. Citra yang dipotong kemudian dilabeli berdasarkan indeks yang berasosiasi dengan lokasi *grid*.

Hasil pemotongan citra kemudian *diupload* ke *Google Drive* dan dibaca pada *Google Colab* bersama dengan *vector grid* yang berasosiasi. Citra kemudian diaugmentasi. Augmentasi citra merupakan pembuatan citra buatan dengan gangguan atau modifikasi pada *dataset* citra yang sudah ada, sambil mempertahankan label sampel yang baru dibuat (Bloice et al., 2017). Metode ini adalah metode yang sering digunakan untuk menghasilkan lebih banyak data pelatihan dengan upaya rendah, atau ketika akumulasi sampel baru tidak lagi layak.

Augmentasi data paling sering digunakan dalam cabang *machine learning* yang berkaitan dengan analisis gambar (Hauberg et al., 2016). Augmentasi citra yang dilakukan pada penelitian ini diantaranya pembalikan (*flip*) dan pengubahan kontras. Gambar 15 menunjukkan ilustrasi hasil pemotongan dan augmentasi citra satelit siang hari.

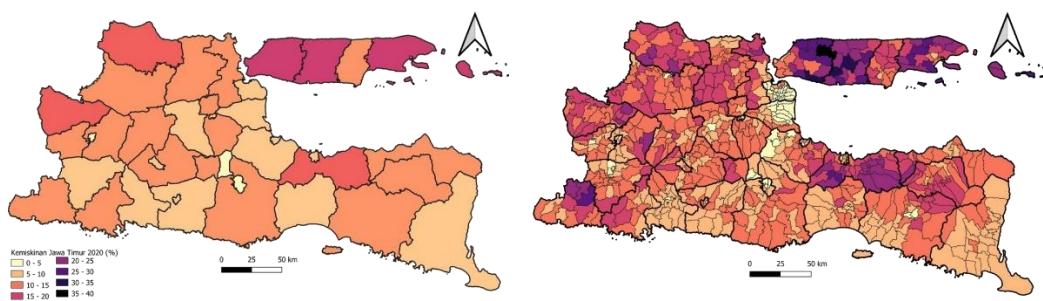


Gambar 15. Citra Siang Hari yang Sudah Dipotong dan Diaugmentasi
Preprocessing Data Kemiskinan

Untuk kepentingan estimasi kemiskinan, dibutuhkan informasi kemiskinan yang lebih granular. Data kemiskinan resmi yang dipublikasikan BPS hanya tersedia sampai level kabupaten saja. Oleh karena itu, diaplikasikan *Broad Area Ratio Estimation* (BARE) agar diperoleh nilai variabel dependen yang lebih representatif pada level yang lebih kecil. Data pendukung yang digunakan untuk mengaplikasikan metode ini adalah Sensus Penduduk 2020 (SP 2020) dan PBDT 2015. Pada penelitian ini, karena keterbatasan ketersediaan data, dalam mengaplikasikan metode BARE, penulis mengasumsikan bahwa proporsi penduduk miskin yang digunakan pada PBDT 2015 dan Susenas 2020 adalah sama. BARE diaplikasikan menurut formula berikut.

$$\hat{X}_{ij} = \frac{n_{ij}}{n_j} \frac{x_j}{N_{ij}} \times 100\% \quad (10)$$

Dengan \hat{X}_{ij} : tingkat kemiskinan di level kecamatan tahun 2020, n_{ij} : jumlah penduduk miskin di kecamatan ke i pada kabupaten/kota ke j (PBDT 2015), n_j : jumlah penduduk miskin kabupaten/kota ke j (PBDT 2015), x_j adalah jumlah penduduk miskin kabupaten/kota (SUSENAS 2020), N_{ij} : jumlah penduduk level kecamatan (Sensus Penduduk 2020). Gambar 16 menunjukkan visualisasi angka kemiskinan resmi level kabupaten hasil Susenas 2020 dan hasil estimasi angka kemiskinan hasil pengaplikasian BARE.



Gambar 16. Kemiskinan Resmi Level Kabupaten (kanan) dan Kemiskinan Level Kecamatan Hasil SAE

3.2.2.2 Ekstraksi Fitur

Ekstraksi fitur dilakukan untuk mengubah *dataset* yang semula berbentuk raster (citra satelit) dan vektor *points* (POI) ke dalam bentuk vektor tabel. Pada penelitian ini, dilakukan dua skenario ekstraksi fitur yaitu ekstraksi fitur dengan *zonal statistics* pada *Dataset 1* dan ekstraksi fitur dengan *transfer learning Resnet-34* pada *Dataset 2*.

Ekstraksi Fitur Zonal Statistics dan Transformasi Data pada Dataset 1

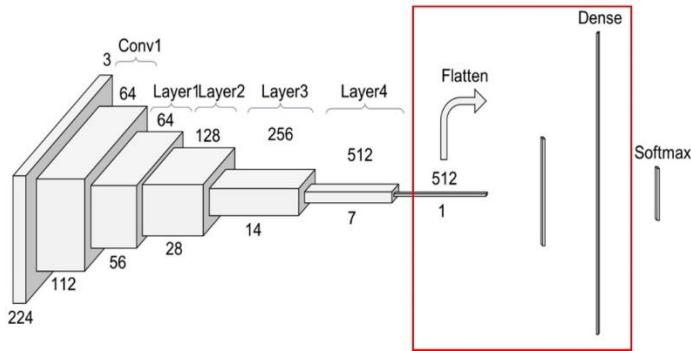
Pada data citra satelit multisumber, *zonal statistics* dilakukan untuk mendapatkan satu nilai median dari data raster yang merepresentasikan kondisi geografis pada level *grid* 1,5 km. Pada data POI, *zonal statistics* dilakukan pada penghitungan *POI Density* dan *POI Distance* level *grid* 1,5 km. *Zonal statistics*

dilakukan berdasarkan *shapefile* (shp) *grid* 1,5 km × 1,5 km. Hasil yang diperoleh dari tahap ini adalah *shapefile* (shp) *grid* 1,5 km × 1,5 km yang telah mengandung sepuluh atribut hasil *zonal statistics* (NTL, NDVI, BUI, NDWI, LST, CO, NO₂, SO₂, POI *Density*, dan POI *Distance*).

Hasil ekstraksi fitur *zonal statistics* kemudian ditransformasi dengan mengaplikasikan metode transformasi Yeo-Johnson. Terdapat dua tujuan utama penerapan transformasi data dalam penelitian ini, 1) mendapatkan nilai dengan jangkauan yang sama dengan tujuan tidak ada variabel yang mendominasi variabel lain, dan 2) mengakomodasi heteroskedastisitas dalam data sehingga dapat diperoleh analisis yang lebih baik. Transformasi Yeo-Johnson merupakan salah satu bentuk transformasi Box-Cox yang dapat menangani data baik positif maupun negatif, transformasi ini dapat diterapkan untuk menangani variabilitas variabel yang tidak sama di seluruh rentang dengan membuatnya lebih mirip Normal/Gaussian (Raymaekers & Rousseeuw, 2021).

Ekstraksi Fitur dengan *Transfer Learning Resnet-34*

Ekstraksi fitur dilakukan mengekstrak *fully connected layer* model *transfer learning* yang dibangun dengan mengaplikasikan arsitektur Resnet-34 (*pre-trained model* pada *dataset* berukuran besar ImageNet). ImageNet merupakan salah satu *dataset* berukuran besar yang secara umum dikenal sebagai *benchmark* dalam pengenalan citra/gambar (*image recognition*) (Deng et al., 2009). Gambar 17 menunjukkan ilustrasi bagian yang diekstrak dari arsitektur model.



Gambar 17. Arsitektur Resnet-34 dengan *Fully Connected Layer* yang Diekstrak

Model Resnet-34 dilatih dengan data latih (80% *dataset*) untuk mengklasifikasikan citra satelit siang hari ke dalam tiga kelas nilai intensitas cahaya malam (NTL rendah, NTL sedang, dan NTL tinggi). Model dievaluasi berdasarkan hasil prediksi data uji (20% *dataset*) untuk mengetahui performa model. Evaluasi dilakukan dengan ukuran evaluasi kasus klasifikasi yaitu akurasi, F1-score, Presisi, dan *Recall*. Model kemudian digunakan untuk memprediksi keseluruhan data (100% *dataset*). *Fully connected layer* yang diperoleh pada proses prediksi ini kemudian diekstrak sehingga diperoleh *dataset* vektor numerik dengan 512 fitur hasil ekstraksi.

Citra yang menjadi *input* dalam pengaplikasian *transfer learning* dengan Resnet-34 adalah citra siang hari (RGB) berukuran 256 x 256 piksel. Adapun *detail* arsitektur Resnet-34 yang dilatih dijelaskan melalui Tabel 7.

Tabel 7. Arsitektur Resnet-34

<i>Layer</i>	<i>Filter</i>	<i>Input Fitur</i>	<i>Output Fitur</i>	<i>Stride</i>	<i>Padding</i>	<i>Jumlah Layer</i>	<i>Ukuran Map</i>
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Input Awal	-	3	-	-	-	1	256
<i>Convolution 1</i>	7 x 7	3	64	(2,2)	(3,3)	1	128

<i>Layer</i>	Filter	Input Fitur	Output Fitur	<i>Stride</i>	<i>Padding</i>	Jumlah Layer	Ukuran Map
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
<i>Convolution 2</i>	3 x 3 max pool, stride 2						64
	3 x 3	64	64	(1,1)	(1,1)	6	
<i>Convolution 3</i>	3 x 3	64	128	(2,2)	(1,1)	1	32
	3 x 3	128	128	(1,1)	(1,1)	7	
<i>Convolution 4</i>	3 x 3	128	256	(1,1)	(1,1)	1	16
	3 x 3	256	256	(2,2)	(1,1)	11	
<i>Convolution 5</i>	3 x 3	256	512	(2,2)	(1,1)	1	8
	3 x 3	512	512	(1,1)	(1,1)	5	
<i>Average Pooling 512 Feature</i>							1

3.2.2.3 Pembangunan Indeks Kemiskinan Spasial Relatif (*Relative Spatial Poverty Index; RSPI*)

Pada penelitian ini, Indeks Kemiskinan Spasial Relatif (*Relative Spatial Poverty Index; RSPI*) dibangun untuk memetakan kemiskinan spasial atau daerah terdeprivasi spasial di Jawa Timur pada level *grid* 1,5 km berdasarkan *big data* citra satelit multisumber dan POI (*Dataset 1*). Terdapat empat tahapan yang dilakukan dalam pembangunan RSPI yaitu 1) identifikasi visual, 2) analisis korelasi dan pemilihan variabel, 3) penghitungan *weighted sum model* dengan dua pendekatan pembobot yaitu koefisien korelasi *Pearson* untuk RSPI₁ dan PCA untuk RSPI₂, dan

4) evaluasi hasil. Keseluruhan tahapan tersebut dijelaskan dengan detail pada rincian berikut.

Identifikasi Visual

Identifikasi visual pada data citra satelit dilakukan untuk mendapatkan gambaran bagaimana citra satelit dapat menunjukkan kemiskinan khususnya di Jawa Timur. Pada penelitian ini, diambil titik-titik ekstrim dan titik-titik tertentu yang dianggap mewakili titik lainnya untuk diidentifikasi secara terperinci. Identifikasi visual ini dilakukan dengan memanfaatkan citra satelit bersolusi tinggi *Google Satellite* dan *Google Map*.

Analisis Korelasi dan Pemilihan Variabel

Pada penelitian ini, indeks kemiskinan spasial relatif (RSPI) dibangun dengan *weighted sum model*. Karena kemiskinan spasial pada wilayah spesifik tertentu dapat memiliki karakteristik berbeda akibat perbedaan kondisi geografis (B. Wang et al., 2021) dan RSPI dibangun dengan *weighted-sum model* yang merupakan model linier, analisis korelasi dan pemilihan variabel perlu dilakukan demi memastikan bahwa variabel yang digunakan dapat secara linier merepresentasikan kemiskinan di Provinsi Jawa Timur.

Analisis korelasi dilakukan untuk mengetahui hubungan numerik citra satelit multisumber dan POI dengan data kemiskinan resmi di level kabupaten/kota. Analisis hubungan numerik ini dilakukan dengan menghitung koefisien korelasi *Pearson* dan *Spearman* serta *p-value* yang menunjukkan signifikansi korelasinya. Persamaan berikut menunjukkan formula untuk memperoleh koefisien korelasi *Pearson*.

$$r_{xy} = \frac{n \sum_1^n x_i y_i - (\sum_1^n x_i)(\sum_1^n y_i)}{\sqrt{(n \sum_1^n x_i^2 - (\sum_1^n x_i)^2)} \sqrt{(n \sum_1^n y_i^2 - (\sum_1^n y_i)^2)}} \quad (11)$$

Dengan r_{xy} mewakili korelasi antara x_i sebagai fitur pertama, y_i adalah fitur kedua, dan n adalah jumlah pengamatan. Korelasi *Spearman* dihitung dengan cara yang sama dengan mengubah nilai observasi menjadi nilai rangkingnya. Koefisien korelasi (r) berkisar antara 0 sampai 1. Arah hubungan ditunjukkan dengan tanda positif atau negatif. Tabel 8 menunjukkan pedoman interpretasi hasil koefisien korelasi (r) menurut Sugiyono (2010).

Tabel 8. Koefisien Korelasi dan Interpretasinya (Sugiyono, 2010)

Koefisien Korelasi (1)	Interpretasi (2)
$0,00 \leq r \leq 0,199$	Sangat Lemah
$0,2 \leq r \leq 0,399$	Lemah
$0,4 \leq r \leq 0,599$	Sedang
$0,6 \leq r \leq 0,799$	Kuat
$0,8 \leq r \leq 1,000$	Sangat Kuat

Selanjutnya, dilakukan uji signifikansi korelasi untuk mengetahui apakah koefisien korelasi yang diperoleh signifikan secara statistik pada α (tingkat signifikansi) 0,05. Hipotesis nol yang ditetapkan adalah bahwa tidak ada korelasi antara kedua variabel, sedangkan hipotesis alternatif didefinisikan sebagai asumsi bahwa ada korelasi antara kedua variabel.

Dari hasil analisis korelasi, variabel yang terpilih untuk pembangunan RSPI adalah variabel yang signifikan berkorelasi pada tingkat signifikansi 0,05 dan setidaknya berkorelasi sedang atau $\geq 0,4$ dengan data kemiskinan resmi level kabupaten. Dengan demikian, RSPI dibangun berdasarkan variabel-variabel yang secara linier mewakili kemiskinan di Jawa Timur.

Weighted Sum Model

Indeks kemiskinan spasial relatif (RSPI) dihitung dengan melakukan integrasi variabel-variabel geospasial terpilih yang mewakili kemiskinan di Jawa Timur. Untuk dapat melakukan integrasi variabel, diterapkan *weighted sum model*. Beberapa penelitian sebelumnya telah menerapkan metode ini untuk membangun indeks geospasial (Goyal et al., 2015; Liu & Xu, 2016; Y Wang & Chen, 2017). Formula berikut menunjukkan penerapan *weighted sum model* untuk pembangunan RSPI.

$$RSPI = \sum_{i=1}^p w_i x_i \quad (12)$$

Dengan p adalah jumlah variabel overlay yang digunakan, w adalah bobot yang ditetapkan, dan x adalah nilai yang diamati.

Pemilihan *weight* dilakukan dengan dua pendekatan. Pertama, digunakan bobot berbasis korelasi *Pearson*. Variabel dengan korelasi yang lebih tinggi diasumsikan mewakili kemiskinan dengan lebih baik. Kedua, digunakan bobot berbasis PCA. Bobot ini dihitung melalui komponen utama pertama, yang dibuat menggunakan metode analisis komponen utama (PCA). Beberapa penelitian telah menggunakan PCA sebagai pendekatan untuk menghitung indeks sosial ekonomi. Uddin et al., (2019) menggunakan PCA untuk memetakan kerentanan sosial-ekonomi wilayah pesisir. Ditemukan bahwa PCA adalah metode yang sangat berguna untuk mengidentifikasi daerah rentan di wilayah pesisir Bangladesh. Cartone & Postiglione (2021) menggunakan PCA untuk membangun indeks deprivasi spasial.

Evaluasi

Evaluasi merupakan tahapan penting untuk menentukan sejauh mana RSPI dapat menggambarkan kemiskinan di Jawa Timur. Pada penelitian ini, digunakan dua pendekatan penilaian evaluasi. Pertama, evaluasi numerik untuk mengukur secara numerik keeratan antara hasil yang diperoleh dengan kemiskinan resmi di level kabupaten. Dalam evaluasi ini, dilakukan penghitungan korelasi *Pearson* dan *Spearman*, korelasi, RMSE, MAE, MAPE, dan R^2 pada model regresi linier sederhana berdasarkan tingkat kemiskinan resmi level kabupaten. Nilai RMSE, MAE, MAPE, dan R^2 dihitung dengan formula sebagai berikut.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (13)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (14)$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \quad (15)$$

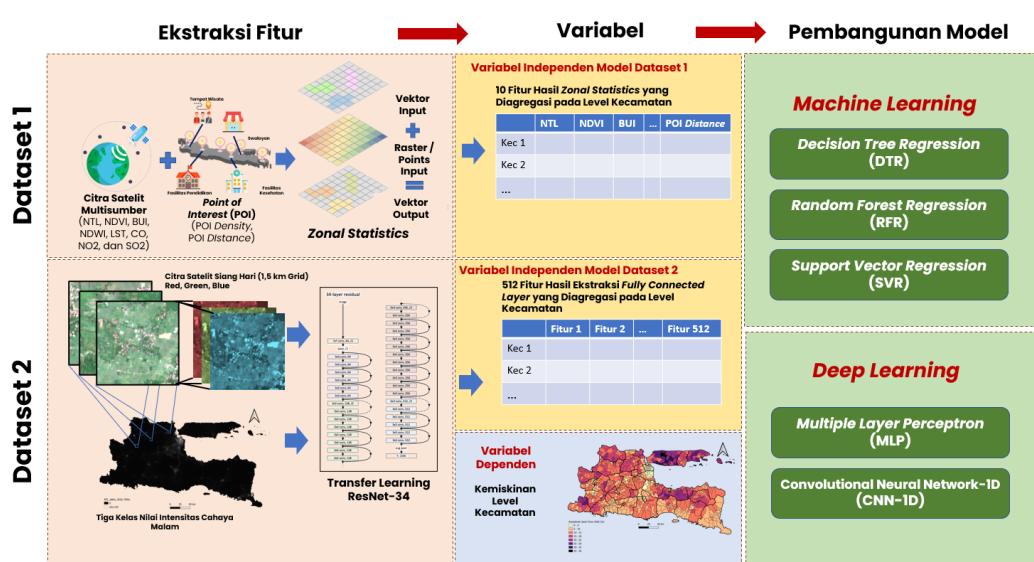
$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (16)$$

Kedua, untuk evaluasi deskriptif, dilakukan identifikasi visual hasil RSPI yang diperoleh dengan bantuan citra satelit resolusi tinggi. Beberapa penelitian sebelumnya telah menunjukkan bahwa identifikasi visual melalui citra resolusi tinggi dapat menjadi opsi evaluasi yang tidak dapat dilakukan secara numerik pada setiap piksel. Misalnya, Varshney et al., (2015) memperkirakan persentase bahan atap melalui gambar Google Earth, dan Shi et al., (2020) secara acak memilih enam titik untuk diidentifikasi melalui citra satelit resolusi tinggi untuk mengenali

kemiskinan. Dalam penelitian ini, dilakukan pemilihan secara acak enam piksel $1,5 \times 1,5$ km dan pengidentifikasi karakteristik geografis area tersebut dengan satelit resolusi tinggi *Google Earth* dan *Google Maps*.

3.2.2.4 Pembangunan Model Estimasi Kemiskinan

Untuk memenuhi Tujuan 2, dilakukan pembangunan model estimasi kemiskinan pada masing-masing *dataset* sehingga diperoleh model estimasi kemiskinan *Dataset 1* dan model estimasi kemiskinan *Dataset 2*. Hasil ekstraksi fitur yang berupa sepuluh fitur citra satelit multisumber dan POI (*Dataset 1*) dan 512 fitur citra satelit siang dan malam hari (*Dataset 2*) diagregasi pada level kecamatan. Hasil agregasi tersebut akan menjadi variabel independen pada masing-masing model yang digunakan untuk memprediksi kemiskinan pada level kecamatan sebagai variabel dependen. Gambar 18 menunjukkan visualisasi pembangunan model estimasi kemiskinan pada penelitian ini.



Gambar 18. Visualisasi Pembangunan Model Estimasi Kemiskinan

Pembangunan model estimasi kemiskinan dilakukan dengan pendekatan *machine learning* dan *deep learning*. Pada pendekatan *machine learning*, pembangunan model dilakukan dengan mengaplikasikan tiga algoritma *machine*

learning yaitu *Support Vector Regression* (SVR), *Decision Tree Regression* (DTR), dan *Random Forest Regression* (RFR). Pendekatan *machine learning* dipilih karena berfokus pada pencapaian akurasi terbaik (Makridakis et al., 2018). Pemilihan parameter dan *hyperparameter* setiap model tersebut dilakukan dengan mengaplikasikan *grid search* dengan *5-fold cross validation*.

Pada pendekatan *deep learning*, pembangunan model dilakukan dengan mengaplikasikan dua algoritma *deep learning* yaitu *Multiple Layer Perceptron* (MLP) dan *Convolutional Neural Network – 1D* (CNN-1D). Dibandingkan dengan penggunaan algoritma *machine learning* tradisional, pengimplementasian *deep learning* dapat meningkatkan performa model (Paterakis et al., 2017). Kelebihan *deep learning* adalah kemampuannya untuk beradaptasi pada data besar (Dong & Wang, 2016). Pemilihan parameter dan *hyperparameter* setiap model tersebut dilakukan melalui eksperimen *random* dengan evaluasi *5-fold cross validation* sehingga diperoleh dua model estimasi kemiskinan.

Pada penelitian ini, dilakukan perbandingan performa setiap model, baik *machine learning* maupun *deep learning*, dalam memprediksi data uji yang tidak digunakan dalam pemodelan. Model yang dipilih merupakan model dengan rata-rata ukuran evaluasi (RMSE, MAE, MAPE) terkecil pada level kecamatan dengan data uji hasil *5-fold cross validation*. Keluaran dari tahap pembangunan model ini adalah model estimasi kemiskinan *Dataset 1* dan model estimasi kemiskinan *Dataset 2*.

3.2.2.5 Pembangunan dan Evaluasi Peta Kemiskinan Level Grid 1,5 km

Untuk memenuhi Tujuan 3, kedua model estimasi yang dibangun pada Tujuan 2 digunakan untuk mengestimasi kemiskinan pada level *grid* 1,5 km,

sehingga diperoleh dua peta estimasi kemiskinan untuk masing-masing model. Hasil yang diperoleh kemudian di-*overlay* dengan peta estimasi *grid* populasi hasil SP2020 karena kemiskinan erat kaitannya dengan keberadaan populasi di suatu wilayah (Wilde et al., 2016). Untuk mendapatkan peta kemiskinan terbaik, evaluasi kemudian dilakukan secara numerik melalui penghitungan RMSE, MAE, dan MAPE. Evaluasi numerik dilakukan pada level kecamatan berdasarkan data kemiskinan level kecamatan hasil SAE dan pada level kabupaten berdasarkan data kemiskinan resmi level kabupaten. Peta kemiskinan terbaik kemudian dievaluasi secara deskriptif melalui identifikasi visual untuk melihat karakteristik geografis daerah yang bersesuaian dengan angka kemiskinan tertentu. Identifikasi visual dilakukan dengan memilih secara acak enam piksel $1,5 \times 1,5$ km. Identifikasi visual pada penelitian ini dilakukan dengan bantuan satelit resolusi tinggi *Google Earth* dan *Google Maps*.

3.2.2.6 Pembangunan *Map Dashboard* Berbasis Website

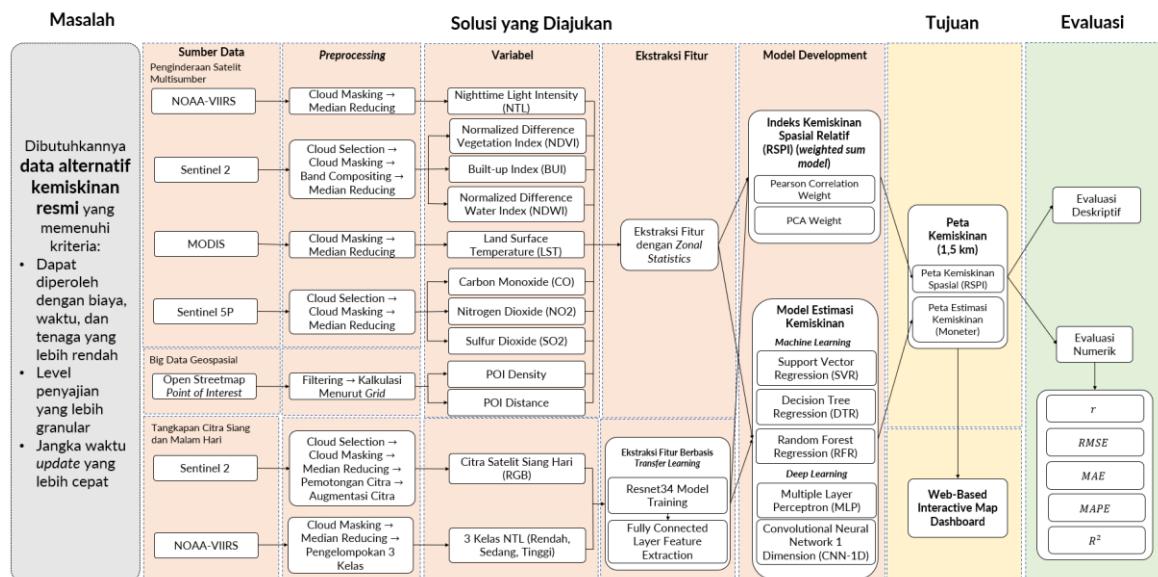
Pembangunan *map dashboard* dilakukan dengan dua pendekatan visualisasi data yaitu dua dimensi (2D) dan tiga dimensi (3D). Pembangunan *map dashboard* dua dimensi dilakukan dengan memanfaatkan *plugin* ‘QGIS2Web’. QGIS2Web adalah alat yang dapat mengubah *layer* geospasial menjadi file HTML, JavaScript, dan CSS dengan bantuan *library* Leaflet JS. QGIS2Web dapat membuat peta interaktif berbasis *website* yang memunculkan informasi spasial bagi pengguna. Pengaplikasian *plugin* ini memungkinkan pengguna memperoleh *map dashboard* interaktif yang fiturnya dapat dimodifikasi sesuai dengan kebutuhan pengguna.

Pembangunan *map dashboard* tiga dimensi dilakukan dengan menafaatkan *plugin* ‘QGIS2threejs’. QGIS2threejs adalah *plugin* yang dapat memvisualisasikan

data vektor dalam 3D pada tampilan *website*. *Map dashboard* yang dibangun pada penelitian ini dilengkapi berbagai fitur yang dapat memudahkan pengguna (pemangku kepentingan) dalam mengidentifikasi wilayah bersangkutan.

3.3 Kerangka Penelitian

Penelitian ini berfokus pada pemanfaatan *big data* citra satelit multisumber dan POI untuk membangun estimasi peta kemiskinan dengan mengimplementasikan *deep learning*. Kerangka pikir dibuat untuk menjelaskan alur logika penelitian mulai dari masalah yang mendasari alasan dilakukan penelitian, solusi yang diajukan, sasaran yang ingin dicapai, sampai indikator evaluasi pencapaian sasaran. Gambar 19 menunjukkan kerangka pikir peneltian ini yang dibuat dengan mengacu pada (Polancik, 2009).



Gambar 19. Kerangka Penelitian

Berdasarkan latar belakang yang telah diuraikan sebelumnya, secara garis besar dapat ditarik permasalahan utama yang menjadi fokus pada penelitian ini yaitu dibutuhkannya data alternatif kemiskinan resmi yang dapat diperoleh dengan biaya, waktu, dan tenaga yang lebih rendah, level penyajian yang lebih granular, dan jangka waktu *update* yang lebih cepat. Solusi yang diusulkan untuk mengatasi masalah tersebut adalah dengan memanfaatkan *big data* citra satelit multisumber dan POI yang *di-preprocessing* sedemikian rupa untuk mendapatkan variabel-variabel bermakna yang dapat menunjukkan kemiskinan. Pada penelitian ini digunakan dua jenis *dataset* yaitu *Dataset 1* (citra satelit multisumber dan POI: NTL, NDVI, BUI, NDWI, LST, CO, NO₂, SO₂, POI *Density*, dan POI *Distance*) dan *Dataset 2* (citra satelit siang dan malam hari).

Pada *Dataset 1* diaplikasikan ekstraksi fitur *zonal statistics* dan pada *Dataset 2* diaplikasikan ekstraksi fitur berbasis *transfer learning* dengan arsitektur *Resnet-34*. Hasil ekstraksi fitur *Dataset 1* kemudian digunakan untuk pembangunan RSPI. RSPI adalah indeks kemiskinan spasial relatif yang digunakan untuk memetakan daerah terdeprivasi spasial di Jawa Timur. Selain itu, hasil ekstraksi fitur *Dataset 1* juga digunakan untuk pembangunan model estimasi kemiskinan dengan mengimplementasikan algoritma-algoritma *machine learning* dan *deep learning*. Hasil ekstraksi fitur *Dataset 2* juga digunakan untuk pembangunan model estimasi kemiskinan. Kedua model estimasi kemiskinan terbaik yang diperoleh dari pembangunan estimasi kemiskinan dengan kedua *dataset* kemudian digunakan untuk membangun peta estimasi kemiskinan pada level *grid* dengan resolusi spasial 1,5 km.

Terdapat dua sasaran utama atau *output* dari penelitian ini yaitu peta kemiskinan spasial (RSPI) level *grid* 1,5 km dan peta estimasi kemiskinan (moneter) level *grid* 1,5 km. Hasil yang diperoleh kemudian dievaluasi secara deskriptif dan numerik melalui penghitungan koefisien korelasi (r), RMSE, MAE, MAPE, dan R^2 . Untuk memudahkan pemangku kepentingan dalam mengakses hasil penelitian, dilakukan pembangunan *map dashboard* interaktif berbasis *website* yang didukung berbagai fitur identifikasi visual.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Pembangunan Indeks Kemiskinan Spasial Relatif

Pembangunan Indeks Kemiskinan Spasial Relatif (*Relative Spatial Poverty Index*; RSPI) dilakukan untuk memperoleh indeks yang menunjukkan kemiskinan spasial atau daerah terdeprivasi spasial pada level *grid* 1,5 km. RSPI dibangun dengan *weighted sum model* berdasarkan variabel-variabel yang diperoleh dari *big data* citra satelit multisumber dan *point of interest* (POI). Variabel yang dipilih adalah variabel-variabel yang dapat secara linier berhubungan (signifikan berkorelasi) dengan kemiskinan di Jawa Timur.

4.1.1 Hasil Identifikasi Visual Citra Satelit Multisumber

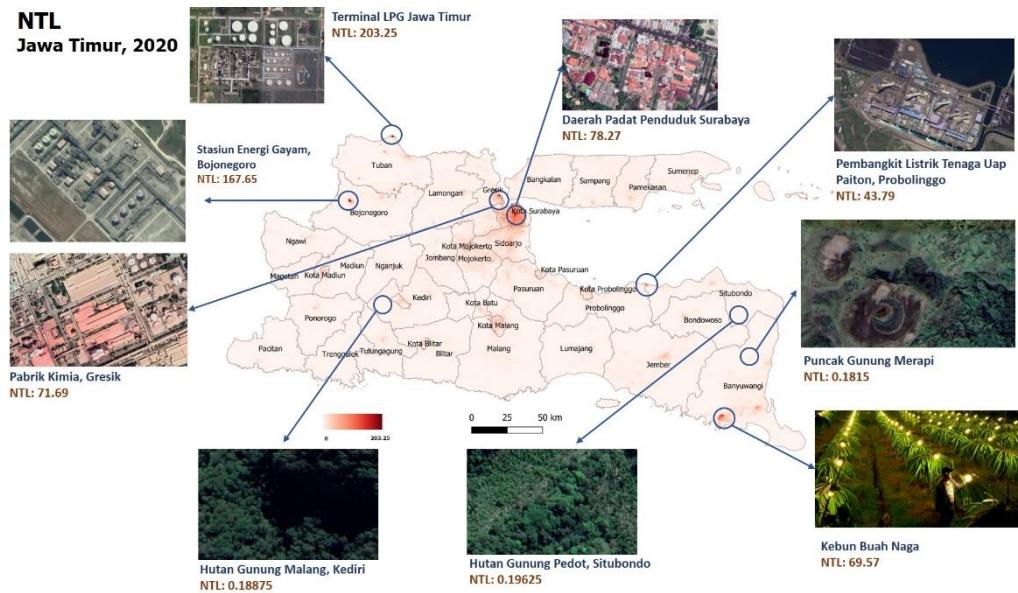
Untuk mendapatkan pemahaman yang lebih mendalam terkait penggunaan *big data* citra satelit penginderaan jauh multisumber dalam menunjukkan kemiskinan, dilakukan identifikasi visual pada beberapa titik unik melalui citra satelit resolusi tinggi *Google Satellite* yang disediakan oleh *Google Earth* sebagai *provider*.

4.1.1.1 *Night-time light* (NTL)

Night-time light (NTL) adalah citra satelit yang paling umum digunakan untuk menggambarkan kemiskinan (Naizhuo Zhao et al., 2020). NTL dapat merekam cahaya dari aktivitas manusia di malam hari dan telah terbukti memiliki kemampuan untuk mengidentifikasi berbagai parameter sosial ekonomi, termasuk kemiskinan. Semakin tinggi nilai NTL menunjukkan semakin tingginya aktivitas

ekonomi di suatu daerah (N. Zhou et al., 2015). Melalui analisis deskriptif, dilakukan pengamatan beberapa nilai NTL untuk mengidentifikasi fitur geografis yang sesuai dan membandingkannya dengan data kemiskinan resmi Jawa Timur. Gambar 20 menunjukkan beberapa nilai NTL dan pemeriksaan visual fitur geografisnya.

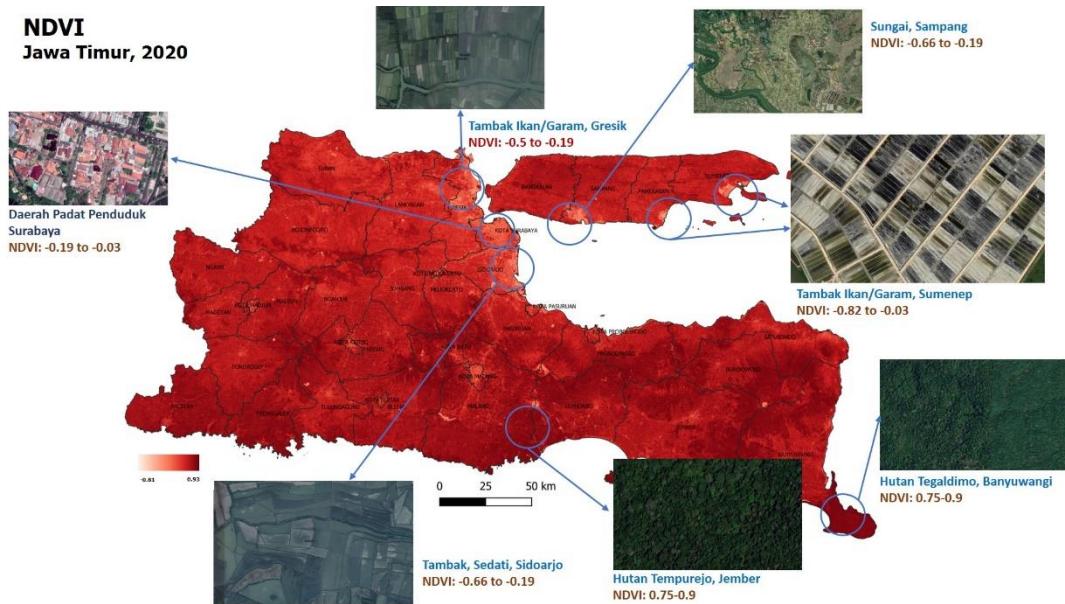
Dari Gambar 20 dapat terlihat beberapa anomali yang ada dalam penggunaan data NTL dalam mengidentifikasi kemiskinan di Jawa Timur. Pertama, dapat terlihat bahwa nilai NTL yang tinggi mengelompok di Kota Surabaya. Surabaya merupakan kota metropolitan terbesar di Indonesia setelah Jakarta. Namun, data kemiskinan resmi menunjukkan bahwa Kota Batu, Kota Malang, dan Kota Madiun sebagai tiga kabupaten/kota dengan tingkat kemiskinan terendah di Jawa Timur. Kedua, dapat terlihat pula bahwa sebagian besar nilai NTL tertinggi tidak berada di kabupaten/kota dengan kemiskinan rendah. Daerah dengan pembangkit energi dan pabrik yang beroperasi hingga larut malam cenderung memiliki nilai NTL yang tinggi. Ketiga, nilai NTL yang tinggi juga ditemukan pada perkebunan dengan penerangan sepanjang malam yang tidak menunjukkan kemiskinan. Anomali tersebut menunjukkan bahwa di beberapa daerah, misalnya di Jawa Timur, penggunaan nilai NTL sebagai pendekatan kemiskinan perlu didukung dengan penggunaan data lain untuk identifikasi yang lebih baik. Dari Gambar 20, dapat terlihat pula bahwa daerah dengan nilai NTL rendah umumnya adalah hutan di sekitar pegunungan.



Gambar 20. Identifikasi Visual NTL

4.1.1.2 Normalized Difference Vegetation Index (NDVI)

Dawson et al., (2018) mengungkapkan bahwa *Normalized Difference Vegetation Index* (NDVI) secara signifikan berkorelasi dengan kemiskinan (tinggi positif dan/atau tinggi negatif) di negara-negara berkembang. Dari Gambar 21, dapat terlihat bahwa nilai NDVI yang sangat rendah kemungkinan merupakan daerah yang tertutup air, seperti kolam, nilai ini biasanya lebih rendah daripada bangunan. Nilai NDVI yang tinggi menunjukkan kawasan hutan yang lebat. Hal ini sejalan dengan penelitian Maurya et al., (2012), yang menyatakan bahwa nilai NDVI negatif menunjukkan wilayah yang tidak bervegetasi seperti perairan, sedangkan nilai NDVI positif menunjukkan wilayah yang bervegetasi. Terlihat bahwa Kota Surabaya dan Kota Malang yang merupakan kawasan padat bangunan cenderung memiliki nilai NDVI yang lebih rendah, dan kemiskinan di kawasan tersebut juga rendah.

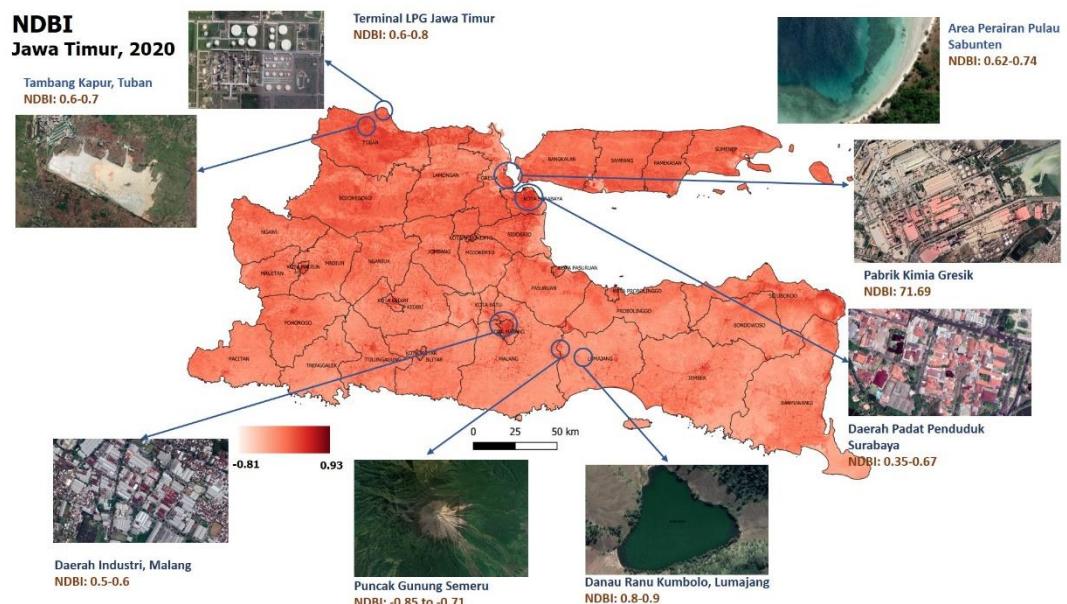


Gambar 21. Identifikasi Visual NDVI

4.1.1.3 Built-up Index (BUI)

Menurut Lee et al., (2010), *built-up index* (BUI) dapat digunakan dalam kasus pengklasifikasian daerah urban (perkotaan dan non-perkotaan). Nilai BUI yang lebih tinggi menunjukkan kemungkinan yang tinggi bahwa wilayah tersebut merupakan area terbangun. Namun, untuk wilayah Jawa Timur yang heterogen, nilai BUI yang sangat tinggi diperoleh tidak hanya di kawasan terbangun perkotaan tetapi juga di tambang kapur dan perairan, seperti terlihat pada Gambar 22. Penambangan kapur banyak ditemukan di Kabupaten Tuban dan Bojonegoro. Oleh karena itu, kawasan ini juga memiliki nilai BUI yang tinggi, selain kawasan perkotaan. Padahal, menurut data resmi kemiskinan, Tuban dan Bojonegoro merupakan kabupaten dengan tingkat kemiskinan tinggi. Selain itu, dapat terlihat pula daerah yang memiliki nilai BUI rendah umumnya berupa hutan dan kawah gunung. Hal inilah yang menyebabkan kabupaten/kota dengan banyak gunung

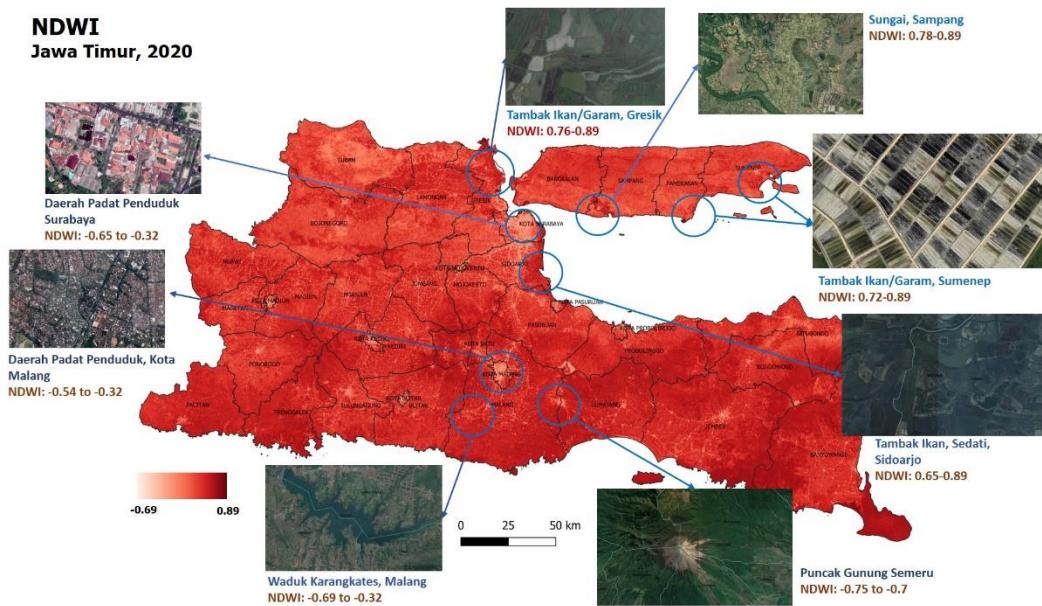
seperti Kediri, Malang, Lumajang, Jember, dan Pasuruan cenderung memiliki nilai BUI yang rendah.



Gambar 22. Identifikasi Visual BUI

4.1.1.4 Normalized Difference Water Index (NDWI)

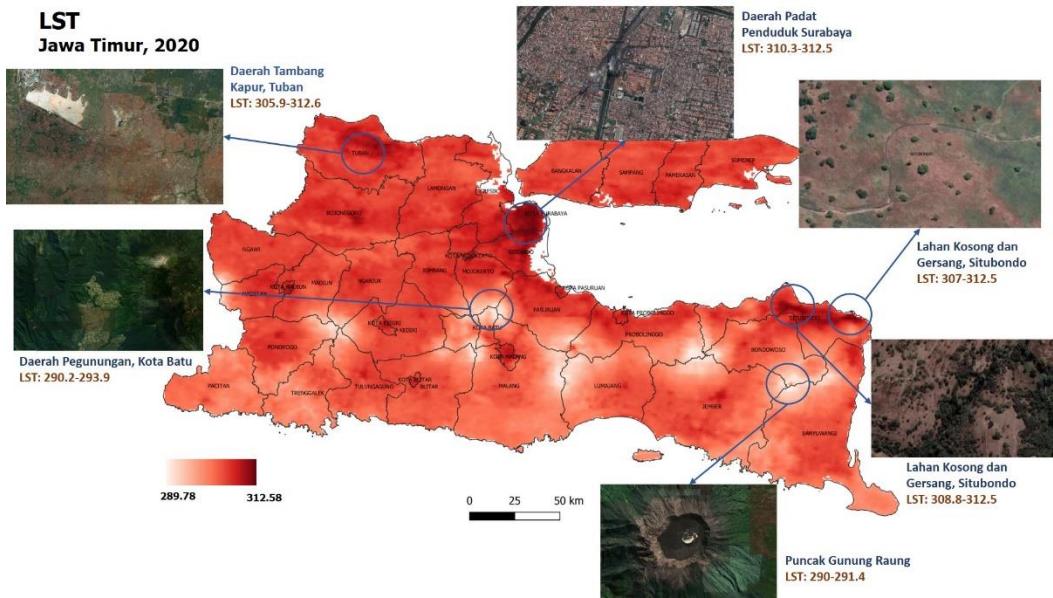
Gambar 23 menunjukkan distribusi *Normalized Difference Water Index* (NDWI). Secara teoritis, nilai NDWI di atas nol menunjukkan hasil citra perairan. Sebaliknya, nilai di bawah nol menunjukkan hasil citra bukan perairan (McFeeters, 1996). Seperti yang terlihat pada Gambar 23, daerah yang tergenang air kemungkinan besar memiliki nilai NDWI lebih dari nol, kecuali Waduk Karangkates yang memiliki nilai NDWI di bawah nol. Kabupaten/kota dengan banyak pegunungan seperti Kediri, Malang, Lumajang, Jember, dan Pasuruan cenderung memiliki nilai NDWI yang tinggi.



Gambar 23. Identifikasi Visual NDWI

4.1.1.5 Land Surface Temperature (LST)

Suhu permukaan tanah (*Land Surface Temperature*, LST) sering digunakan untuk mengidentifikasi daerah perkotaan. Dalam penelitian yang meneliti korelasi antara LST dan pulau panas perkotaan, Mia et al., (2017) menyatakan bahwa semakin tinggi nilai LST, semakin luas perkotaan. Namun, seperti terlihat pada Gambar 24, di Jawa Timur, daerah dengan LST tinggi tidak hanya merupakan daerah perkotaan tetapi juga daerah gersang dan daerah pertambangan batu gamping. Jawa Timur bagian utara merupakan daerah dengan banyak lahan gersang dan kosong serta tambang batu gamping yang cenderung memiliki nilai LST lebih tinggi dibandingkan dengan bagian selatan yang terdiri dari pegunungan. Dapat pula terlihat bahwa kabupaten/kota dengan tingkat kemiskinan tinggi cenderung memiliki nilai LST yang rendah, kecuali Kota Surabaya dan kabupaten/kota di sekitarnya.

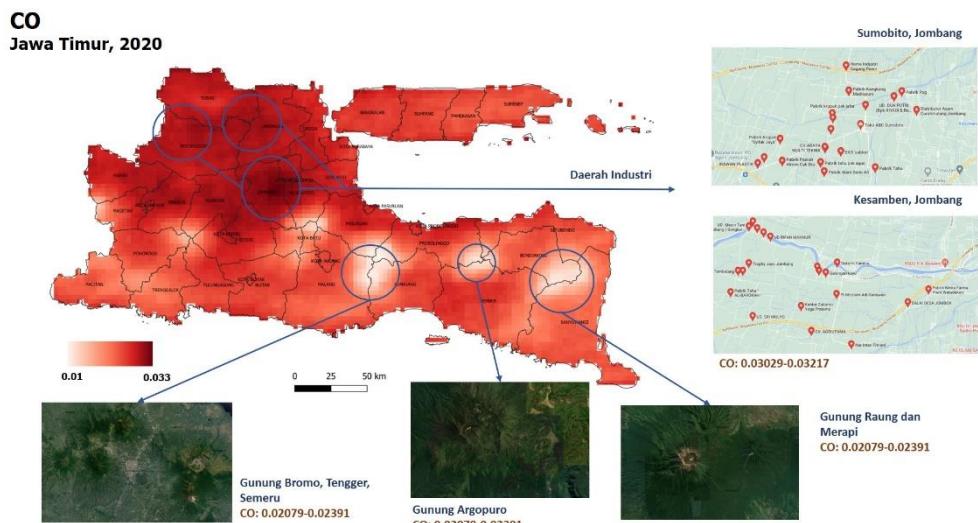


Gambar 24. Identifikasi Visual LST

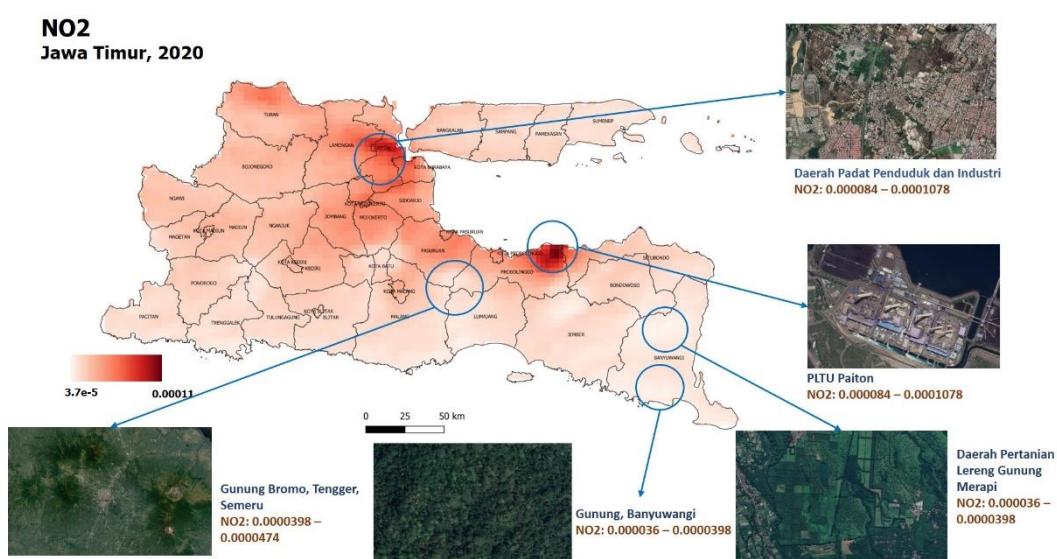
4.1.1.6 Polusi Udara

Pencemaran udara dapat menjadi salah satu indikator kegiatan ekonomi yang berkaitan dengan kemiskinan. Wu et al., (2019) menggunakan CO₂ (karbon dioksida) dan SO₂ (sulfur dioksida) untuk mengidentifikasi daerah miskin. Dalam penelitian ini, dilakukan pengkajian CO (karbon monoksida), NO₂ (nitrogen dioksida), dan SO₂ untuk menangkap polusi udara di Jawa Timur. Gambar 25, Gambar 26, dan Gambar 27 menunjukkan nilai indikator polusi Jawa Timur dan identifikasi visualnya. Nilai tinggi setiap indikator polusi menangkap informasi yang berbeda. Dari Gambar 25 terlihat bahwa daerah dengan nilai CO yang tinggi merupakan daerah padat industri. Nilai tersebut melebihi nilai CO Kota Surabaya yang merupakan kota metropolitan terbesar kedua di Indonesia. Dari Gambar 26, dapat terlihat bahwa daerah-daerah dengan nilai NO₂ tinggi adalah pembangkit listrik tenaga uap dan daerah padat penduduk dan industri. Dari Gambar 27, dapat terlihat bahwa nilai SO₂ tertinggi yang kita tangkap berada di daerah lereng gunung yang banyak penduduk. Di sisi lain, nilai rendah setiap indikator polusi menangkap

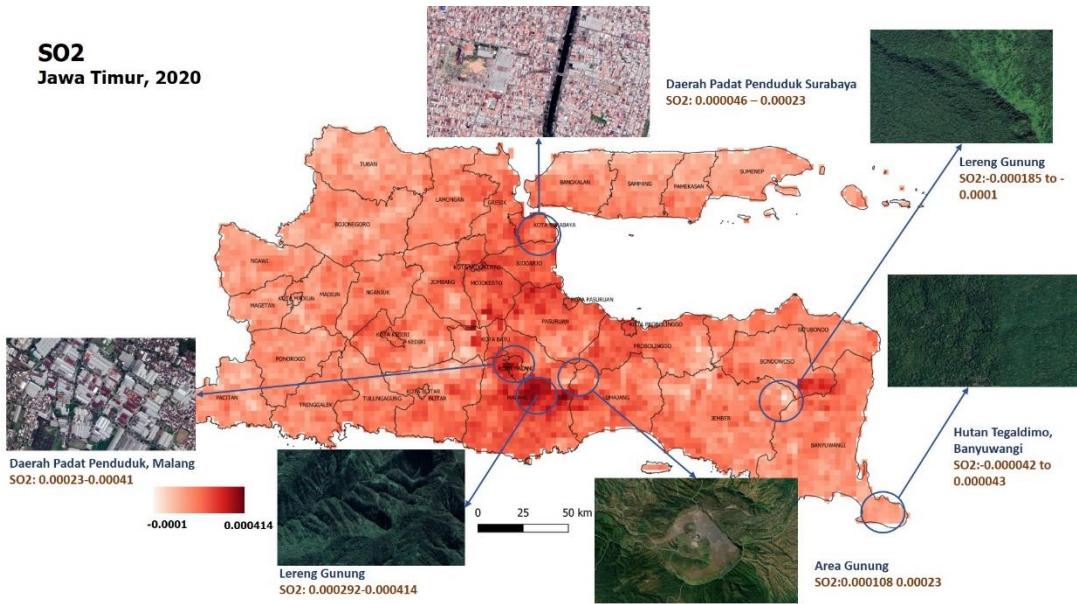
informasi serupa. Daerah dengan CO, NO₂, atau SO₂ yang rendah biasanya merupakan daerah pegunungan.



Gambar 25. Identifikasi Visual CO



Gambar 26. Identifikasi Visual NO₂

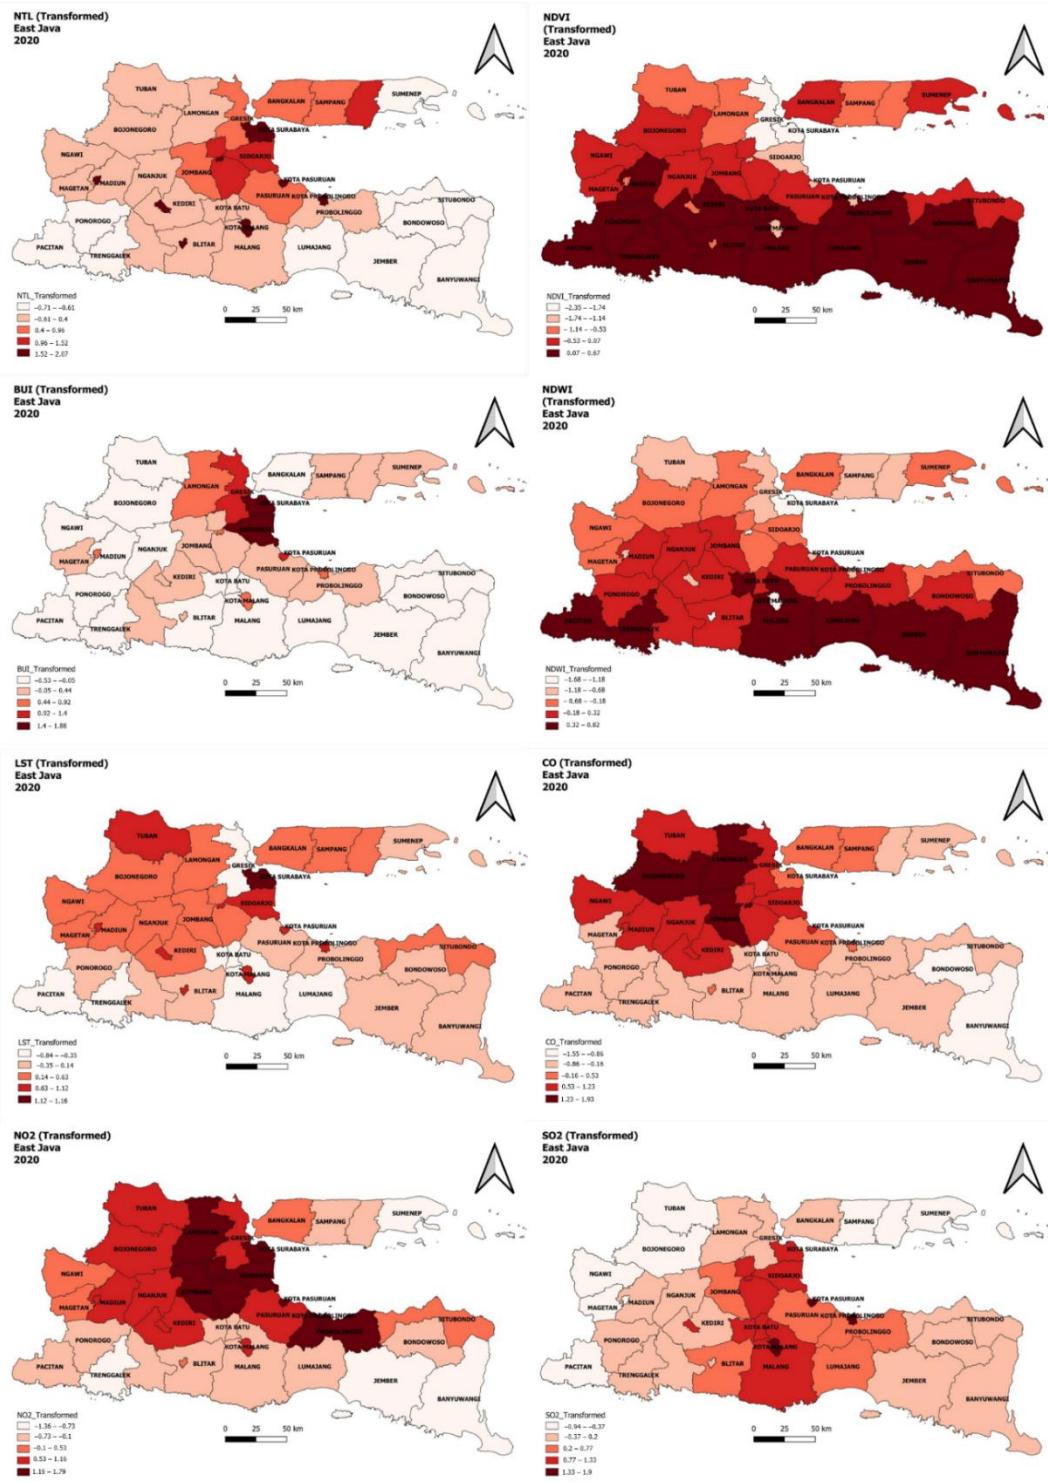


Gambar 27. Identifikasi Visual SO₂

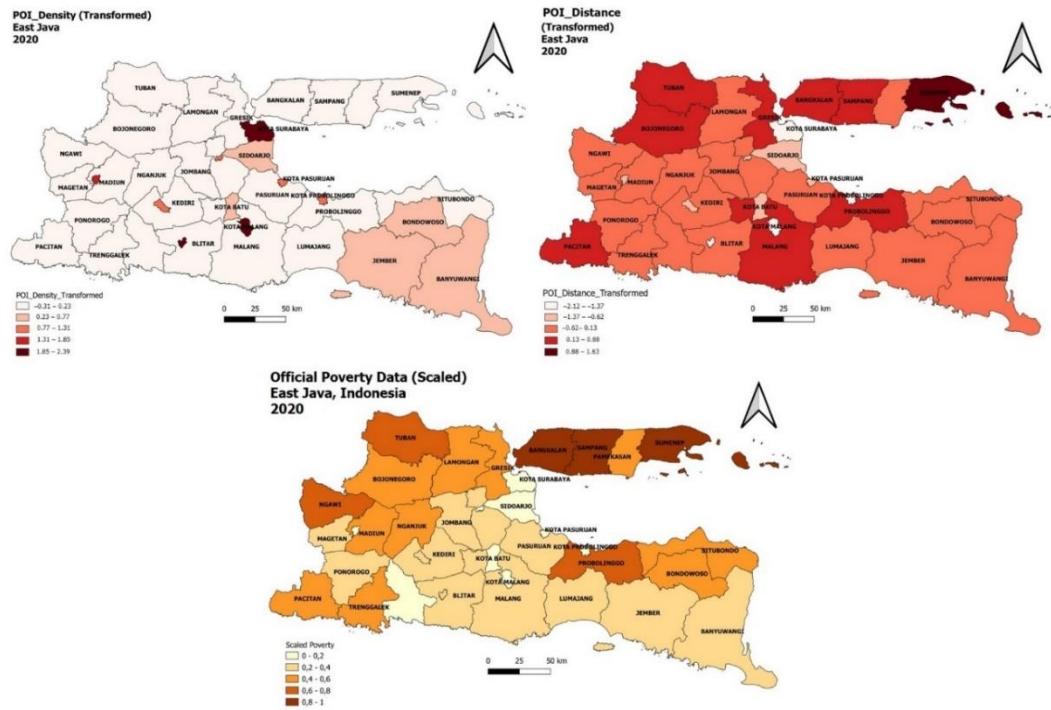
4.1.2 Hasil Analisis Korelasi

Pada penelitian ini, analisis korelasi dilakukan untuk mengetahui kedekatan dan arah hubungan antara masing-masing variabel geospasial dengan data kemiskinan resmi. Karena keterbatasan data kemiskinan resmi yang hanya tersedia pada level administratif kabupaten/kota, analisis korelasi tidak dapat dilakukan pada level *grid*, sehingga dilakukan agregasi pada level kabupaten/kota. Oleh karena itu, diperoleh 38 observasi untuk setiap variabel geospasial.

Gambar 28 dan Gambar 29 menunjukkan visualisasi peta masing-masing variabel geospasial beserta peta kemiskinan resmi untuk dapat dibandingkan pada level kabupaten/kota. Terlihat bahwa masing-masing variabel geospasial menggambarkan pola spasial yang berbeda untuk setiap wilayah.



Gambar 28. Visualisasi Data Citra Satelit Multisumber di Level Kabupaten



Gambar 29. Visualisasi Data POI dan Kemiskinan di Level Kabupaten

Variabel NTL yang merupakan proksi kegiatan ekonomi menunjukkan bahwa skor tinggi cenderung tersebar di daerah perkotaan dengan tingkat kemiskinan rendah. Variabel-varibel yang diperoleh dari citra satelit Sentinel-2 (NDVI, BUI, dan NDWI) yang mewakili tutupan lahan menunjukkan adanya pola yang homogen di wilayah selatan Jawa Timur yang merupakan wilayah dengan tingkat kemiskinan menengah ke bawah.

Nilai variabel LST cenderung tinggi di daerah perkotaan dengan tingkat kemiskinan yang rendah. Masing-masing variabel pencemaran udara (CO, NO₂, dan SO₂) yang diperoleh dari citra satelit Sentinel-5P menunjukkan pola yang berbeda. Nilai variabel CO tinggi di bagian barat laut Jawa Timur yang merupakan daerah dengan tingkat kemiskinan menengah-tinggi, nilai variabel NO₂ tinggi di kawasan industri dengan tingkat kemiskinan yang berbeda, sedangkan nilai variabel

SO_2 cenderung tinggi di daerah tengah yang merupakan daerah pegunungan yang padat penduduknya dengan tingkat kemiskinan yang relatif rendah. Variabel aksesibilitas (*POI density* dan *POI distance*) menangkap pola kawasan perkotaan dengan aksesibilitas tinggi dan tingkat kemiskinan rendah.

Untuk mendapatkan pemahaman yang lebih baik tentang hubungan antara variabel geospasial dan kemiskinan resmi di tingkat kabupaten/kota, dilakukan analisis korelasi. Melalui analisis ini, diperoleh *p-value* untuk menunjukkan variabel yang signifikan berkorelasi dan koefisien korelasi yang mewakili kedekatan dan arah hubungan. Koefisien korelasi dihitung dengan menggunakan dua pendekatan, yaitu korelasi *Pearson* dan *Spearman*. Tabel 9 menunjukkan hasil analisis korelasi yang diperoleh. Interpretasi kedekatan dan arah hubungan dilakukan, mengikuti metode yang digunakan oleh Sugiyono (2010).

Tabel 9. Hasil Analisis Korelasi Variabel Geospasial dan Kemiskinan Resmi

Variabel	Korelasi Pearson		Korelasi Spearman		Keeratan	Arah Hubungan	Signifikansi
	<i>r</i>	<i>p-value</i>	<i>r</i>	<i>p-value</i>			
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
NTL	-0,5	0,001	-0,49	0,001	Sedang	Negatif	Ya
NDVI	0,25	0,130	0,21	0,205	Lemah	Positif	Tidak
BUI	-0,45	0,004	-0,44	0,005	Sedang	Negatif	Ya
NDWI	0,14	0,401	0,14	0,401	Lemah	Positif	Tidak
LST	-0,29	0,077	-0,31	0,058	Lemah	Negatif	Tidak
CO	-0,065	0,698	-0,054	0,747	Sangat Lemah	Negatif	Tidak
NO_2	-0,25	0,130	-0,26	0,114	Lemah	Negatif	Tidak

Variabel	Korelasi Pearson		Korelasi Spearman		Keeratan	Arah Hubungan	Signifikansi
	r	p-value	r	p-value			
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
SO ₂	-0,6	6,84E-05	-0,63	2,25E-05	Kuat	Negatif	Ya
POI Density	-0,64	1,51E-05	-0,72	3,48E-07	Kuat	Negatif	Ya
POI Distance	0,73	1,98E-07	0,79	3,69E-09	Kuat	Positif	Ya

Seperti terlihat pada Tabel 9, variabel yang memiliki hubungan arah positif adalah NDVI, NDWI, dan POI *Distance*. Hal ini menunjukkan bahwa kenaikan nilai variabel-variabel tersebut akan sejalan dengan kenaikan nilai angka kemiskinan resmi. Sedangkan variabel yang memiliki hubungan arah negatif adalah NTL BUI, LST, CO, NO₂, SO₂, dan POI *Density*. Hal ini menunjukkan bahwa kenaikan nilai variabel-variabel tersebut akan sejalan dengan penurunan nilai resmi angka kemiskinan.

Dari Tabel 9 terlihat bahwa terdapat lima variabel yang signifikan secara statistik berkorelasi dengan angka kemiskinan resmi: NTL, BUI, SO₂, POI *Density*, dan POI *Distance*. Variabel SO₂, POI *Density*, dan POI *Distance* berkorelasi kuat dengan angka kemiskinan resmi, sedangkan NTL dan BUI berkorelasi sedang, dan sisanya berkorelasi lemah atau sangat lemah. Untuk memastikan bahwa indeks kemiskinan spasial relatif (RSPI) dapat digunakan untuk mewakili kemiskinan di Jawa Timur, dipilih variabel-variabel yang signifikan berkorelasi (*p-value* < 0,05) dan setidaknya berkorelasi sedang ($|r| \geq 0,4$) dengan tingkat kemiskinan resmi.

Oleh karena itu, dipilih lima variabel untuk menghitung RSPI Jawa Timur yaitu NTL, BUI, SO₂, POI *Density*, dan POI *Distance*.

4.1.3 Hasil Penghitungan Indeks RSPI

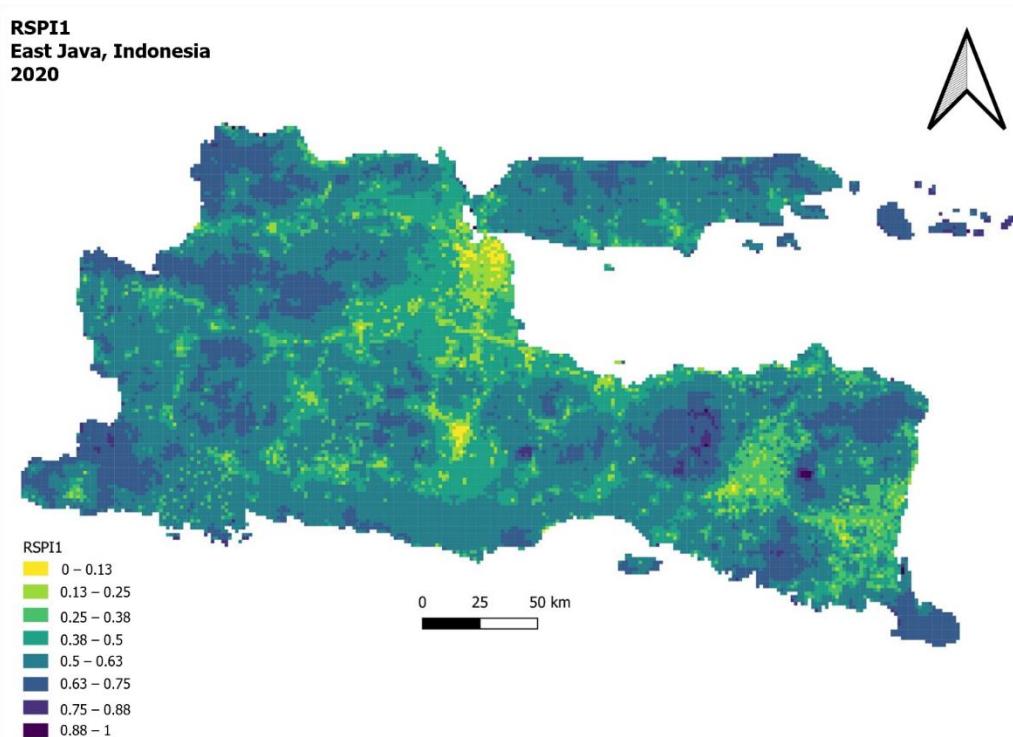
Indeks Kemiskinan Spasial Relatif (RSPI) dihitung dengan *weighted sum model* berdasarkan variabel yang signifikan berkorelasi atau setidaknya berkorelasi sedang dengan data kemiskinan resmi Jawa Timur yaitu NTL, BUI, SO₂, POI *Density*, dan POI *Distance*. Dua pendekatan perhitungan bobot digunakan dalam penelitian ini: bobot berbasis korelasi (W_1) dan bobot berbasis PCA (W_2). Bobot berbasis korelasi (W_1) diperoleh berdasarkan koefisien korelasi *Pearson*. Bobot berbasis PCA (W_2) diperoleh melalui komponen utama PCA pertama. Tabel 10 menunjukkan hasil perhitungan bobot.

Tabel 10. Hasil Penghitungan Bobot RSPI

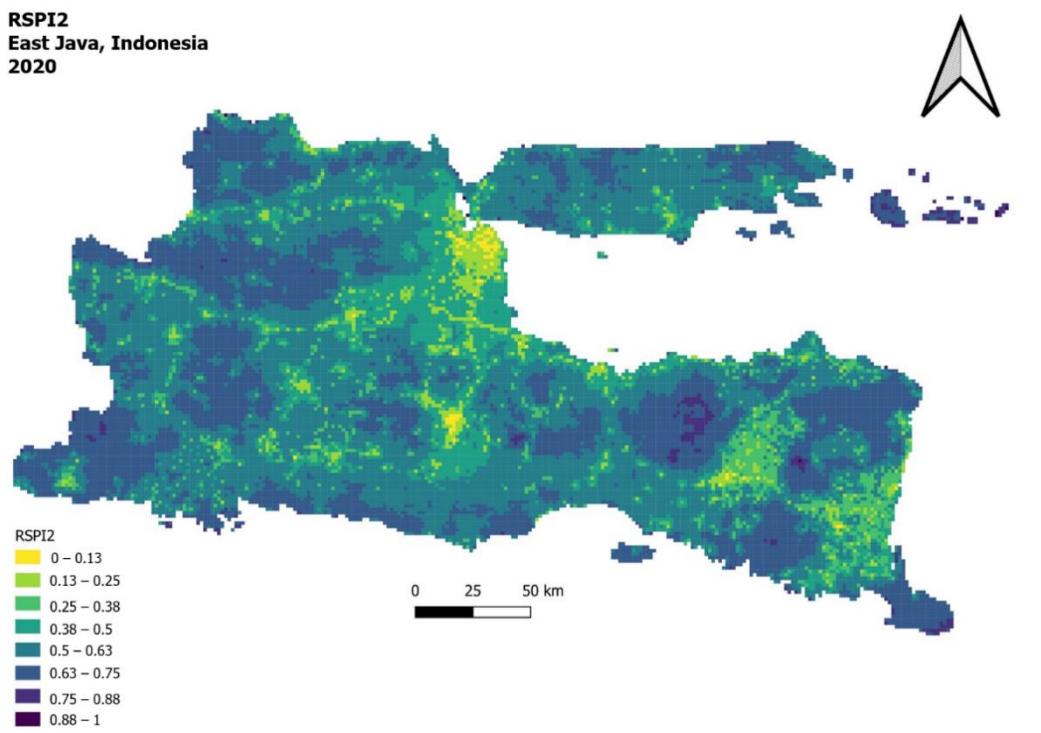
Variabel	W_1 (Koef. Korelasi Pearson)	W_2 (Komponen Pertama PCA)
(1)	(2)	(3)
NTL	-0,5	0,5
BUI	-0,45	0,26
SO ₂	-0,6	0,29
POI Density	-0,64	0,5
POI Distance	0,75	0,58

Dari kedua jenis pendekatan pembobotan tersebut, RSPI₁ dihitung menggunakan bobot W_1 dan RSPI₂ dihitung menggunakan bobot W_2 . Dalam penelitian ini, baik RSPI₁ dan RSPI₂ dihitung pada level $grid$ $1,5 \times 1,5$ km untuk

memperoleh peta kemiskinan spasial, seperti yang diilustrasikan pada Gambar 30 dan Gambar 31. Untuk menyederhanakan interpretasi, disajikan peta kemiskinan spasial relatif yang sudah diskala dengan *min-max scaling*, sehingga nilai yang ditampilkan berada dalam jangkauan 0-1. Dari Gambar 30 dan Gambar 31 terlihat bahwa peta kemiskinan yang dihasilkan oleh RSPI₁ dan RSPI₂ memberikan hasil yang serupa; nilai rendah cenderung terkonsentrasi di Jawa Timur bagian tengah. Bagian selatan dan barat laut Jawa Timur, dan Pulau Madura, cenderung memiliki nilai RSPI yang relatif tinggi. Untuk menilai kesamaan ini, dilakukan penghitungan nilai koefisien korelasi. Dari hasil penghitungan, diperoleh koefisien korelasi *Pearson* sebesar 0,99 dan korelasi *Spearman* sebesar 0,98. Hal ini menunjukkan bahwa RSPI₁ dan RSPI₂ berkorelasi kuat.



Gambar 30. Visualisasi RSPI₁



Gambar 31. Visualisasi RSPI₂

4.1.4 Hasil Evaluasi RSPI

RSPI yang diperoleh kemudian dievaluasi dengan dua pendekatan, yaitu evaluasi numerik dan evaluasi deskriptif.

4.1.4.1 Hasil Evaluasi Numerik RSPI

Evaluasi numerik berfokus pada penghitungan seberapa dekat nilai RSPI dengan data kemiskinan resmi secara numerik. Karena keterbatasan data resmi kemiskinan yang hanya tersedia sampai tingkat kabupaten/kota, maka tidak mungkin dilakukan evaluasi numerik pada setiap piksel. Oleh karena itu, diambil satu nilai rata-rata yang mewakili RSPI pada satu wilayah kabupaten/kota sehingga didapatkan 38 nilai RSPI. Evaluasi numerik dilakukan dengan dua pendekatan: analisis korelasi dan perhitungan RMSE. Tabel 11 menunjukkan analisis korelasi yang diperoleh.

Tabel 11. Analisis Korelasi RSPI dengan Kemiskinan Resmi Level Kabupaten

Indeks	Korelasi <i>Pearson</i>		Korelasi <i>Spearman</i>		Keeratan	Arah	Siginifikansi
	Koefisien Korelasi	<i>p</i> -Value	Koefisien Korelasi	<i>p</i> -Value			
(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
<i>RSPI</i> ₁	0,71	$5,97 \times 10^{-7}$	0,77	$1,58 \times 10^{-8}$	Strong	Positif	Ya
<i>RSPI</i> ₂	0,69	$1,64 \times 10^{-6}$	0,72	$3,48 \times 10^{-7}$	Strong	Positif	Ya

Dari Tabel 11, dapat terlihat bahwa baik *RSPI*₁ maupun *RSPI*₂ keduanya signifikan (*p-value* < 0,05) berkorelasi dengan data kemiskinan resmi level kabupaten. Koefisien korelasi *Pearson* dan *Spearman* menunjukkan bahwa *RSPI*₁ dan *RSPI*₂ berkorelasi positif kuat dengan data resmi kemiskinan. Koefisien korelasi tertinggi diperoleh *RSPI*₁ (koefisien korelasi *Pearson* = 0,71 (*p-value* = $5,97 \times 10^{-7}$) dan koefisien korelasi *Spearman* = 0,77 (*p-value* = $1,58 \times 10^{-8}$) yang dihitung menggunakan bobot berbasis korelasi. Arah positif menunjukkan bahwa nilai kenaikan variabel RSPI cenderung sejalan dengan persentase kenaikan data kemiskinan resmi. Model regresi linier sederhana juga dibangun dengan RSPI sebagai variabel independen dan tingkat kemiskinan resmi sebagai variabel terikat. Tabel 12 menunjukkan model yang diperoleh beserta nilai RMSE dan *R*² untuk *RSPI*₁ dan *RSPI*₂.

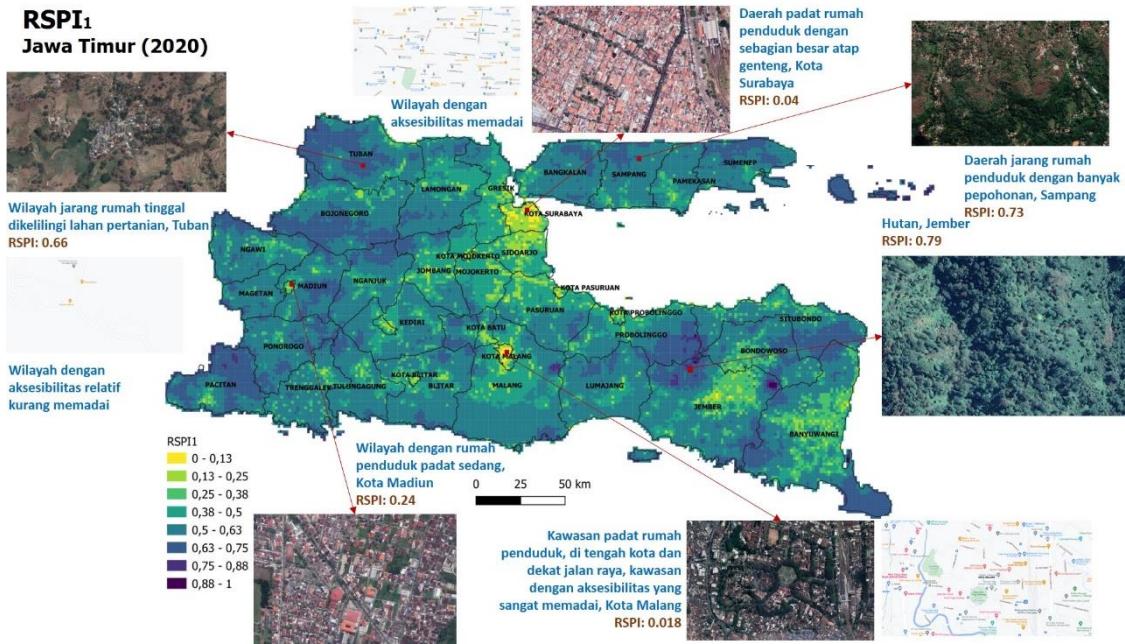
Tabel 12. Evaluasi Numerik RSPI

	RSPI ₁	RSPI ₂
(1)	(2)	(3)
Model	$Pov = 12,603 + 1,7063RSPI_1$	$Pov = 12,605 + 2,2191RSPI_2$
RMSE	3,18%	3,25%
<i>R</i> ²	0,50	0,48

Dari Tabel 12 dapat terlihat bahwa model yang dibangun berdasarkan RSPI₁ memiliki nilai RMSE terendah dan nilai R^2 tertinggi. Oleh karena itu RSPI₁ terpilih sebagai indeks terbaik untuk menjelaskan kemiskinan spasial.

4.1.4.2 Hasil Evaluasi Deskriptif RSPI

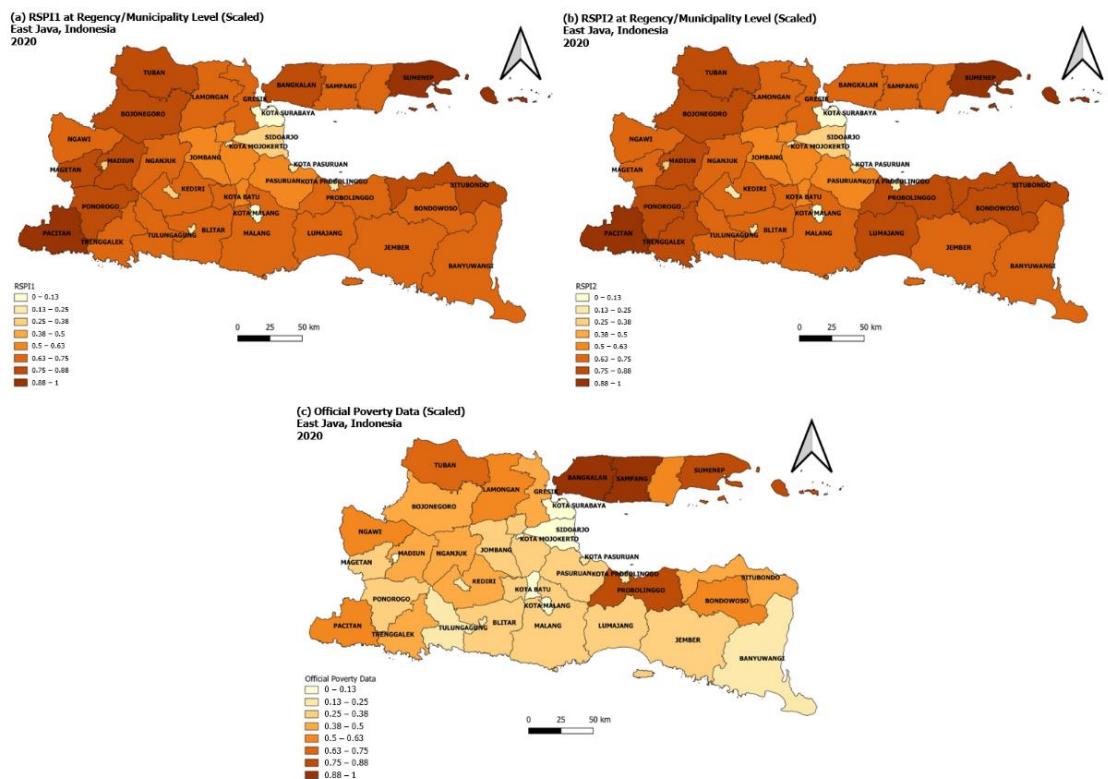
Beberapa penelitian sebelumnya telah menunjukkan bahwa identifikasi visual melalui citra resolusi tinggi dapat dijadikan opsi evaluasi yang tidak dapat dilakukan secara numerik pada setiap piksel (Shi et al., 2020; Varshney et al., 2015). Dalam penelitian ini, dilakukan pengambilan enam piksel $1,5 \times 1,5$ km secara acak dan pengidentifikasi karakteristik geografis wilayahnya melalui *Google Earth. Plot* RSPI yang dipilih adalah RSPI₁, yang merupakan indeks paling representatif dari data kemiskinan resmi. Gambar 32 menunjukkan hasil identifikasi visual RSPI. Terlihat bahwa daerah dengan skor RSPI tinggi cenderung merupakan daerah yang jarang penduduk dengan aksesibilitas yang kurang memadai. Kawasan ini cenderung merupakan kawasan deprivasi spasial dengan aksesibilitas yang terbatas. Di sisi lain, wilayah dengan skor RSPI rendah cenderung merupakan wilayah padat penduduk yang memiliki aksesibilitas memadai yang lebih baik. Daerah perkotaan cenderung memiliki nilai RSPI yang rendah.



Gambar 32. Hasil Identifikasi Visual RSPI

Meskipun *relative spatial poverty index* (RSPI) yang dihitung dapat memetakan kemiskinan dari sisi geografis, perbandingan secara deskriptif hasil RSPI dengan kemiskinan data kemiskinan resmi yang diperoleh dari sisi pengeluaran moneter perlu dikaji. Gambar 33 menunjukkan perbandingan antara agregat RSPI tingkat kabupaten/kota (Gambar 33 a, b) dengan data kemiskinan resmi (Gambar 33 c). Terlihat bahwa RSPI₁ dan RSPI₂ memberikan hasil yang serupa. Wilayah dengan kemiskinan spasial terendah adalah Kota Surabaya, Kota Malang, dan wilayah perkotaan lainnya. Daerah-daerah ini cenderung menjadi daerah yang tidak terdeprivasi secara moneter menurut data kemiskinan resmi. Bagian selatan Jawa Timur cenderung merupakan wilayah yang tidak terdeprivasi secara moneter, tetapi memiliki nilai RSPI yang tinggi. Oleh karena itu, dapat dikatakan bahwa meskipun tidak miskin (menurut angka kemiskinan resmi), daerah-daerah tersebut masih memiliki potensi untuk terkana perangkap kemiskinan spasial (*spatial poverty traps*) atau merupakan daerah tertinggal secara

geografis. Selain itu, terlihat bahwa kabupaten di Pulau Madura yang merupakan daerah dengan tingkat kemiskinan tinggi menurut data resmi kemiskinan cenderung memiliki skor RSPI yang tinggi. Hal ini menunjukkan bahwa, selain deprivasi moneter, wilayah ini juga deprivasi spasial.



Gambar 33. Perbandingan Visual RSPI dengan Kemiskinan Resmi Level Kabupaten

4.2 Hasil Pembangunan Model Estimasi Kemiskinan

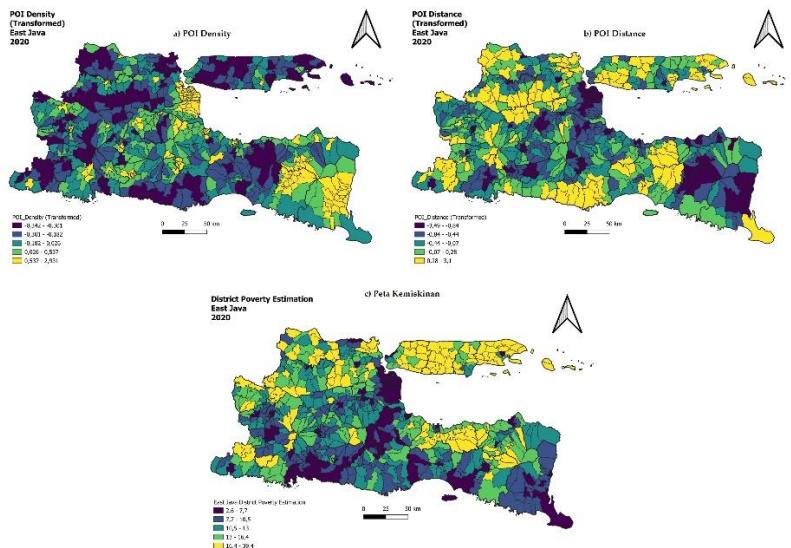
Untuk memenuhi Tujuan 2, dilakukan pembangunan model estimasi kemiskinan pada masing-masing *dataset* sehingga diperoleh model estimasi kemiskinan *Dataset 1* (citra satelit multisumber dan POI) dan model estimasi kemiskinan *Dataset 2* (citra satelit siang dan malam hari). Pembangunan model estimasi kemiskinan dilakukan dengan dua pendekatan yaitu *machine learning* dan *deep learning*. Pada pendekatan *machine learning*, pembangunan model dilakukan

dengan mengaplikasikan tiga algoritma *machine learning* yaitu *Support Vector Regression* (SVR), *Decision Tree Regression* (DTR), dan *Random Forest Regression* (RFR). Pada pendekatan *deep learning*, pembangunan model dilakukan dengan mengaplikasikan dua algoritma *deep learning* yaitu *Multiple Layer Perceptron* (MLP) dan *Convolutional Neural Network – 1D* (CNN-1D).

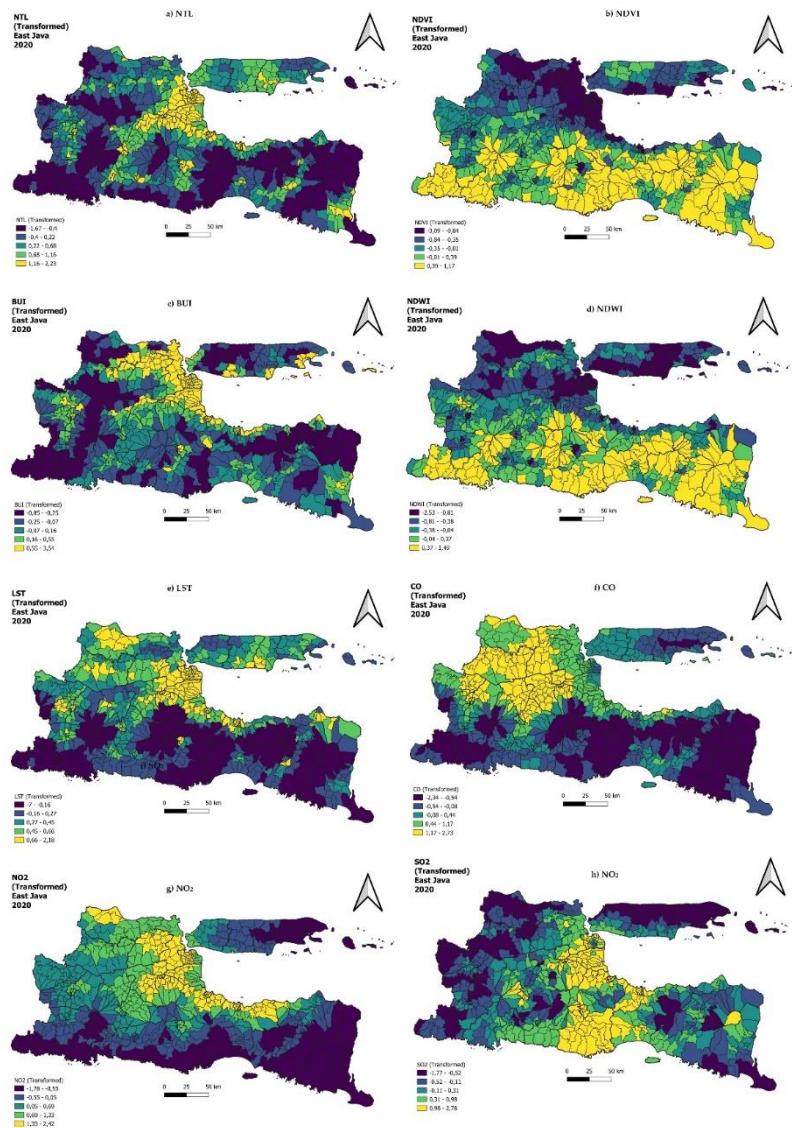
4.2.1 Pembangunan Model Estimasi Kemiskinan dengan *Big Data* Citra Satelit Multisumber dan POI

4.2.1.1 Hasil Agregasi Level Kecamatan

Pada pembangunan model regresi berdasarkan *Dataset 1* (citra satelit multisumber dan POI), nilai numerik hasil ekstraksi fitur *zonal statistics* yang diagregasi pada level kecamatan sebagai variabel independen digunakan untuk memprediksi nilai kemiskinan di level kecamatan sebagai variabel dependen. Gambar 34 dan Gambar 35 menunjukkan visualisasi data yang digunakan pada pembangunan model estimasi.



Gambar 34. Visualisasi Data a) POI Density, b) POI Distance, dan c) Kemiskinan Hasil SAE pada Level Kecamatan



Gambar 35. Visualisasi Data a) NTL, b) NDVI, c) BUI, d) NDWI, e) LST, f) CO, g) NO₂, dan h) SO₂ pada Level Kecamatan

4.2.1.2 Hasil Pembangunan Model Berbasis *Machine Learning*

Pada pembangunan model berbasis *machine learning*, pemilihan *parameter/hyperparameter* dilakukan dengan mengaplikasikan *grid search* dengan evaluasi *5-fold cross validation*. Tabel 13 menunjukkan hasil pemilihan *parameter/hyperparameter* yang dilakukan.

Tabel 13. Pemilihan Parameter/Hyperparameter Model *Machine Learning*

Model	Parameter/ <i>Hyperparameter</i>	Pilihan	Terpilih
(1)	(2)	(3)	(4)
<i>Support Vector Regression (SVR)</i>	C	0,01, 0,1, 1, 3	100
	epsilon	0,1, 0,2, 0,3, 0,4, 0,5	0,3
	gamma	10, 1, 0,1, 0,01	10
	kernel	linear, rbf, poly, sigmoid	rbf
<i>Decision Tree Regression (DTR)</i>	max_depth	1, 3, 9, 12	3
	min_samples_leaf	1, 3, 5	1
	min_weight_fraction_leaf	0,2, 0,4, 0,6	0,2
	max_features	auto, log2, sqrt, None	sqrt
	max_leaf_nodes	None, 10, 30, 50, 90	30
<i>Random Forest Regression (RFR)</i>	max_depth	80, 90, 100, 110	90
	max_features	2, 3, 4, 5	3
	min_samples_leaf	3, 4, 5	5
	min_samples_split	8, 10, 12	8
	n_estimators	100, 200, 300, 1000	100

4.2.1.3 Hasil Pembangunan Berbasis Model *Deep Learning*

Pada pembangunan model berbasis *deep learning*, pemilihan parameter/hyperparameter dilakukan dengan *random experiment* dengan evaluasi *5-fold cross validation*. Arsitektur MLP yang dibangun untuk memprediksi kemiskinan dengan *Dataset 1* (citra satelit multisumber dan POI) terdiri atas satu *input layer*, tiga *hidden layer* yang masing-masing terdiri atas 5, 3, dan 2 *neurons*, dan satu *output layer*. Fungsi aktivasi yang digunakan pada *hidden layer* adalah ReLU. Model dibangun dengan *Adam Optimizer*, *learning rate* 0.01, dan *loss function mean squared error* (MSE). Model kemudian dilatih dengan lima ratus *epochs* dan lima *batch*. Adapun arsitektur CNN-1D yang dibangun disajikan dalam

Tabel 14.

Tabel 14. Arsitektur CNN Model Estimasi *Dataset 1* (Citra Satelit Multisumber dan POI)

<i>Layer</i>	<i>Parameter/Hyperparameter</i>
(1)	(2)
<i>Convolutional</i>	<i>Filters = 64, Kernel Size = 7, Activation = ReLU</i>
<i>Max-pooling</i>	<i>Pool Size = 1</i>
<i>Convolutional</i>	<i>Filters = 32, Kernel Size = 3, Activation = ReLU</i>
<i>Max-pooling</i>	<i>Pool Size = 1</i>
<i>Convolutional</i>	<i>Filters = 16, Kernel Size = 1, Activation = ReLU</i>
<i>Max-pooling</i>	<i>Pool Size = 1</i>
<i>Flatten</i>	-
<i>Fully-connected</i>	32, Activation = ‘Relu’
<i>Dropout</i>	0.2

4.2.1.4 Hasil Evaluasi Pembangunan Model

Untuk setiap algoritma, dipilih model dengan *parameter/hyperparameter* terbaik atau memiliki nilai RMSE, MAE, dan MAPE paling kecil pada evaluasi rata-rata data uji *5-fold cross-validation*. Tabel 15 menunjukkan hasil evaluasi *5-fold cross validation* pada data uji setiap *fold* untuk masing-masing model terpilih.

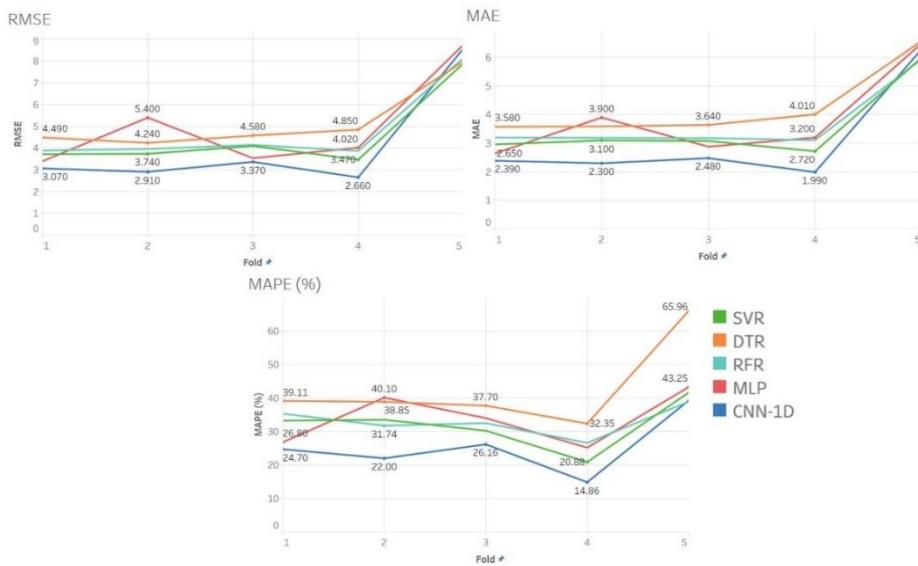
Gambar 36 menunjukkan visualisasi evaluasi numerik yang diperoleh.

Tabel 15. Hasil Evaluasi *5-Cross Validation* Pembangunan Model Berdasarkan *Dataset 1* (Citra Satelit Multisumber Dan POI)

<i>Fold</i>	<i>Algoritma</i>	<i>RMSE</i>	<i>MAE</i>	<i>MAPE</i>
(1)	(2)	(3)	(4)	(5)
1	SVR	3,72	2,96	33,23%
	DTR	4,49	3,58	39,11%
	RFR	3,89	3,2	35,29%

<i>Fold</i>	Algoritma	RMSE	MAE	MAPE
(1)	(2)	(3)	(4)	(5)
	MLP	3,4	2,65	26,8%
	CNN-1D	3,07	2,39	24,7%
2	SVR	3,74	3,1	33,51%
	DTR	4,24	3,59	38,85%
	RFR	3,96	3,19	31,74%
	MLP	5,4	3,9	40,1
	CNN-1D	2,91	2,3	22%
3	SVR	4,1	3,08	30,24%
	DTR	4,58	3,64	37,7%
	RFR	4,15	3,18	32,48%
	MLP	3,54	2,88	33,99%
	CNN-1D	3,37	2,48	26,16%
4	SVR	3,47	2,72	20,88%
	DTR	4,85	4,01	32,35%
	RFR	3,87	3,11	26,61%
	MLP	4,02	3,2	25,17%
	CNN-1D	2,66	1,99	14,86%
5	SVR	7,89	6	41,63%
	DTR	7,98	6,58	65,96%
	RFR	8,14	5,95	38,9%
	MLP	8,75	6,5	43,25%
	CNN-1D	8,58	6,3	39,25%

5-Cross Validation Poverty Estimation Model Based on Multisource Remote Sensing and POI



Gambar 36. Visualisasi Evaluasi pada *5-Fold Cross Validation* Pembangunan Model Berdasarkan *Dataset 1* (Citra Satelit Multisumber dan POI)

Dari Tabel 15 dan Gambar 37 dapat terlihat bahwa untuk setiap *fold*, model CNN-1D cenderung memiliki nilai RMSE, MAE, dan MAPE paling kecil. Akan tetapi, pada *fold* kelima nilai RMSE dan MAE terkecil diperoleh oleh model SVR serta nilai MAPE terkecil diperoleh oleh model RFR.

4.2.1.5 Pemilihan Model Terbaik

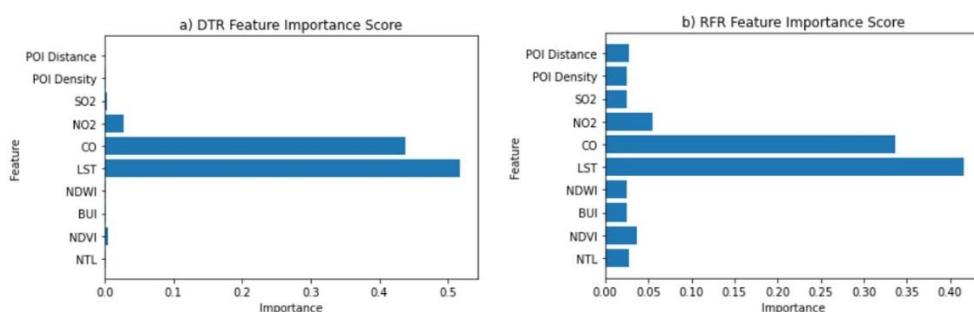
Rata-rata dari hasil evaluasi *5-fold cross validation* pada masing-masing model disajikan pada Tabel 16. Dari tabel tersebut dapat terlihat bahwa model CNN-1D memiliki kemampuan terbaik dalam memprediksi data uji karena memiliki nilai rata-rata RMSE, MAE, dan MAPE terkecil. Oleh karena itu, CNN-1D terpilih sebagai model terbaik untuk prediksi kemiskinan berdasarkan *Dataset 1* (citra satelit multisumber dan POI).

Tabel 16. Hasil Agregasi Rata-Rata Hasil Evaluasi *5-Fold Cross Validation* pada Pembangunan Model Kemiskinan *Dataset 1*

Model	<i>5-Fold Cross Validation</i> (Rata-Rata)		
	RMSE	MAE	MAPE
(1)	(2)	(3)	(4)
SVR	4,76	3,66	31,6%
DTR	5,16	4,22	41,4%
RFR	4,77	3,68	32,7%
MLP	5,01	3,82	33,83%
CNN-1D	4,12	3,09	25,39%

4.2.1.6 Analisis *Feature Importance*

Analisis *feature importance* dilakukan untuk mengetahui urutan kontribusi masing-masing fitur pada pemodelan *Dataset 1* (citra satelit multisumber dan POI). Gambar 37 menunjukkan hasil penghitungan *importance score* dari model DTR (a) dan RFR (b). Dari tersebut dapat terlihat bahwa fitur dengan *importance score* tertinggi adalah LST dan CO. Kedua fitur tersebut memiliki nilai *importance score* yang sangat tinggi dibanding fitur lainnya yaitu lebih dari 0,3. Kedelapan fitur sisanya memiliki nilai *importance score* yang sangat rendah yaitu kurang dari 0,1.



Gambar 37. Hasil Penghitungan *Feature Importance* pada a) Model DTR dan b) Model RFR

Hasil analisis *feature importance* menunjukkan bahwa fitur yang dominan memengaruhi model DTR dan RFR adalah LST dan CO, hal ini menunjukkan adanya potensi penyederhanaan model estimasi kemiskinan Jawa Timur dengan hanya mempertimbangkan kedua variabel tersebut. Tabel 17 menunjukkan akurasi model yang dibangun dengan hanya menggunakan kedua variabel tersebut. Adapun pemilihan parameter kembali dilakukan dengan *grid search*. Hasil terlampir merupakan hasil rata-rata evaluasi *5-fold cross validation*.

Tabel 17. Perbandingan Akurasi Model dengan Fitur Lengkap dan Fitur Hasil Seleksi

Fitur	Model	<i>5-Fold Cross Validation (Rata-Rata)</i>		
		RMSE	MAE	MAPE
(1)	(2)	(3)	(4)	(5)
Fitur Lengkap (10 Fitur)	<i>SVR</i>	4,76	3,66	31,6%
	<i>DTR</i>	5,16	4,22	41,4%
	<i>RFR</i>	4,77	3,68	32,7%
Fitur Terpilih (2 Fitur)	<i>SVR</i>	5,25	4,32	44,4%
	<i>DTR</i>	5,3	4,41	47,1%
	<i>RFR</i>	5,63	4,5	43,4%

Dari Tabel 17, dapat terlihat bahwa nilai RMSE, MAE, dan MAPE pada pembangunan model dengan hanya mempertimbangkan dua fitur terpilih cenderung lebih tinggi dibandingkan dengan model yang dibangun dengan sepuluh fitur. Hal ini menunjukkan bahwa penyederhanaan model dapat dilakukan dengan mengorbankan keakuratan model. Model alternatif yang dibangun dari variabel LST dan CO ini berpotensi untuk digunakan pada beberapa skenario khusus seperti

wilayah tertutup awan yang perlu dipertimbangkan karena Indonesia merupakan negara tropis yang tidak lepas dari tutupan awan. Hal ini menjadi masalah bagi penggunaan data yang bersumber dari Sentinel-2 yang sangat bergantung pada tutupan awan.

4.2.2 Hasil Pembangunan Model Estimasi Kemiskinan Berdasarkan Citra Satelit Siang dan Malam Hari

Pada penelitian ini, model estimasi kemiskinan juga dibangun berdasarkan *Dataset 2* (citra satelit siang dan malam hari) dengan mengimplementasikan ekstraksi fitur menggunakan *transfer learning* Resnet-34 yang sudah banyak diterapkan pada penelitian-penelitian sebelumnya.

4.2.2.1 Hasil Klasterisasi NTL

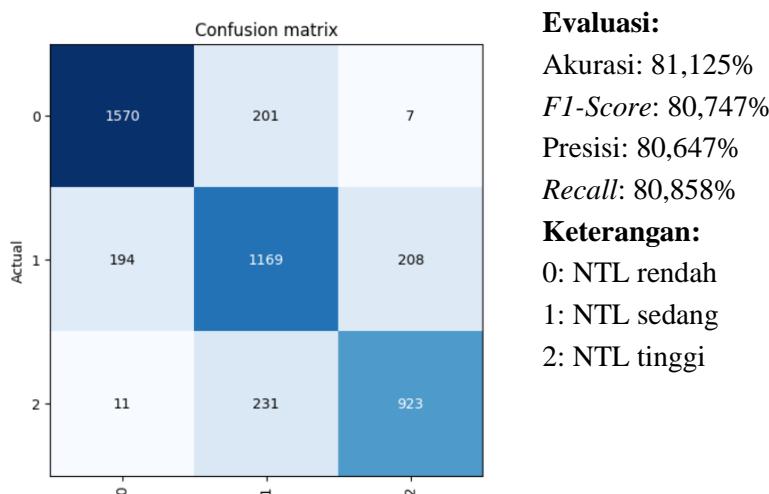
Pengaplikasian *deep learning* pada estimasi kemiskinan berdasarkan citra satelit siang dan malam hari dilakukan berdasarkan asumsi bahwa intensitas cahaya malam (*nighttime light intensity*; NTL) dapat secara konsisten menunjukkan aktivitas ekonomi di suatu daerah dan merupakan proksi dalam menggambarkan kemiskinan di suatu daerah (Jean et al., 2016a). Oleh karena itu, dilakukan *fine-tuning* pada *pre-trained* model Resnet-34 dengan melatih model agar dapat memprediksi kelas NTL berdasarkan citra satelit siang hari (RGB) yang merupakan *input* dari model.

Nilai NTL yang sudah ditransformasi dengan transformasi *Yeo-Johnson* kemudian diklasifikasikan menjadi tiga klaster dengan *Jenks Natural Breaks*. Kelas pertama adalah kumpulan nilai NTL yang rendah yaitu berada pada *range* 0,1 dan 0,366. Kelas kedua adalah kumpulan nilai NTL yang sedang yaitu berada pada

range 0,366 sampai 0,567. Kelas ketiga adalah kumpulan nilai NTL yang tinggi yaitu berada pada *range* 0,567 sampai 0,82.

4.2.2.2 Hasil Training Model Resnet-34

Fine tuning dilakukan dengan melatih model untuk dapat memprediksi klaster NTL berdasarkan citra satelit siang hari yang diinputkan. Hasil prediksi data uji model *transfer learning* dengan arsitektur *Resnet-34* yang diperoleh disajikan pada Gambar 38. Dari gambar tersebut dapat terlihat bahwa model klasifikasi yang dibangun dapat dengan baik memprediksi data uji dengan nilai akurasi, *F1-score*, presisi, dan *recall* lebih dari 80%.



Gambar 38. Confusion Matrix Model Resnet-34 pada Data Test

4.2.2.3 Hasil Pembangunan Model Berbasis Machine Learning

Dari hasil ekstraksi fitur pada *layer* terakhir model Resnet-34 yang merupakan *fully connected layer*, diperoleh sebanyak 512 fitur untuk setiap *grid* 1,5 km. Untuk dapat mengestimasi kemiskinan, dibangun model regresi pada level kecamatan dengan 512 fitur hasil ekstraksi sebagai variabel independen dan kemiskinan level kecamatan sebagai variabel dependen. Pada pembangunan model berbasis *machine learning*, pemilihan *parameter/hyperparameter* dilakukan

dengan mengaplikasikan *grid search* dengan evaluasi *5-fold cross validation*. Tabel 18 menunjukkan hasil pemilihan *parameter/hyperparameter* yang dilakukan.

Tabel 18. Pemilihan *Parameter/Hyperparameter* Pembangunan Model *Dataset 2* (Citra Satelit Siang dan Malam Hari)

Model	Parameter/ Hyperparameter	Pilihan	Terpilih
(1)	(2)	(3)	(4)
<i>Support Vector Regression (SVR)</i>	C	0,01, 0,1, 1, 3	1
	epsilon	0,1, 0,2, 0,3, 0,4, 0,5	0,5
	gamma	10, 1, 0,1, 0,01	0,01
	kernel	linear, rbf, poly, sigmoid	rbf
<i>Decision Tree Regression (DTR)</i>	max_depth	1, 3, 9, 12	12
	min_samples_leaf	1, 3, 5	3
	min_weight_fraction_leaf	0,2, 0,4, 0,6	0,2
	max_features	auto, log2, sqrt, None	sqrt
	max_leaf_nodes	None, 10, 30, 50, 90	50
<i>Random Forest Regression (RFR)</i>	max_depth	80, 90, 100, 110	110

Model (1)	Parameter/ Hyperparameter (2)	Pilihan (3)	Terpilih (4)
	max_features	2, 3, 4, 5	2
	min_samples_leaf	3, 4, 5	3
	min_samples_split	8, 10, 12	10
	n_estimators	100, 200, 300, 1000	200

4.2.2.4 Hasil Pembangunan Model Berbasis *Deep Learning*

Pada pembangunan model berbasis *deep learning*, pemilihan *parameter/hyperparameter* dilakukan dengan *random experiment* dengan evaluasi *5-fold cross validation*. Arsitektur MLP yang dibangun untuk memprediksi kemiskinan dengan *Dataset 2* (citra satelit siang dan malam hari) terdiri atas satu *input layer*, tiga *hidden layer* yang masing-masing terdiri atas 64, 32, dan 8 *neurons*, dan satu *output layer*. Fungsi aktivasi yang digunakan pada *hidden layer* adalah ReLU. Model dibangun dengan *Adam Optimizer*, *learning rate* 0.01, dan *loss function mean squared error* (MSE). Model kemudian dilatih dengan lima ratus *epochs*. Adapun arsitektur CNN-1D yang dibangun disajikan dalam Tabel 19.

Tabel 19. Arsitektur CNN Model Estimasi *Dataset 2* (Citra Satelit Siang dan Malam Hari)

<i>Layer</i>	<i>Parameter/Hyperparameter</i>
(1)	(2)
<i>Convolutional</i>	<i>Filters = 32, Kernel Size = 7, Activation = ReLU</i>
<i>Max-pooling</i>	<i>Pool Size = 1</i>
<i>Convolutional</i>	<i>Filters = 16, Kernel Size = 3, Activation = ReLU</i>
<i>Max-pooling</i>	<i>Pool Size = 1</i>
<i>Convolutional</i>	<i>Filters = 8, Kernel Size = 2, Activation = ReLU</i>
<i>Max-pooling</i>	<i>Pool Size = 1</i>
<i>Flatten</i>	-
<i>Fully-connected</i>	32, Activation = ‘Relu’
<i>Dropout</i>	0.5

4.2.2.5 Hasil Evaluasi Pembangunan Model

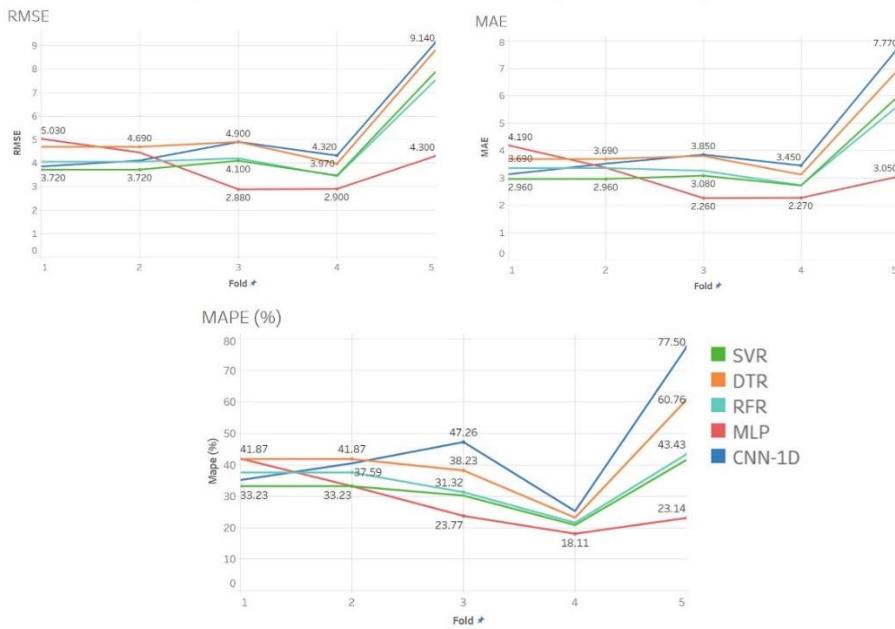
Untuk setiap algoritma, dipilih model dengan *parameter/hyperparameter* terbaik atau memiliki nilai RMSE, MAE, dan MAPE paling kecil pada evaluasi rata-rata data uji *5-fold cross-validation*. Tabel 20 menunjukkan hasil evaluasi *5-fold cross validation* pada data uji setiap *fold* untuk masing-masing model terpilih. Gambar 39 menunjukkan visualisasi evaluasi numerik yang diperoleh.

Tabel 20. Hasil Evaluasi *5-fold Cross Validation* Pembangunan Model Berdasarkan *Dataset 2* (Citra Satelit Siang dan Malam Hari)

<i>Fold</i>	<i>Algoritma</i>	<i>RMSE</i>	<i>MAE</i>	<i>MAPE</i>
(1)	(2)	(3)	(4)	(5)
1	Resnet34+SVR	3,72	2,96	33,23%
	Resnet34+DTR	4,69	3,69	41,87%
	Resnet34+RFR	4,06	3,36	37,59%
	Resnet34+MLP	5,03	4,19	42,00%

<i>Fold</i>	Algoritma	RMSE	MAE	MAPE
(1)	(2)	(3)	(4)	(5)
	Resnet34+CNN-1D	3,85	3,13	35,17%
2	Resnet34+SVR	3,72	2,96	33,23%
	Resnet34+DTR	4,69	3,69	41,87%
	Resnet34+RFR	4,06	3,36	37,59%
	Resnet34+MLP	4,45	3,37	33%
	Resnet34+CNN-1D	4,11	3,52	40%
3	Resnet34+SVR	4,1	3,08	30,24%
	Resnet34+DTR	4,9	3,8	38,23%
	Resnet34+RFR	4,2	3,26	31,32%
	Resnet34+MLP	2,88	2,26	23,77%
	Resnet34+CNN-1D	4,9	3,85	47,26%
4	Resnet34+SVR	3,47	2,72	20,88%
	Resnet34+DTR	3,97	3,12	23,22%
	Resnet34+RFR	3,44	2,73	21,62%
	Resnet34+MLP	2,9	2,27	18,11%
	Resnet34+CNN-1D	4,32	3,45	25,30%
5	Resnet34+SVR	7,89	6	41,63%
	Resnet34+DTR	8,82	6,97	60,76%
	Resnet34+RFR	7,54	5,65	43,43%
	Resnet34+MLP	4,3	3,05	23,14%
	Resnet34+CNN-1D	9,14	7,77	77,50%

5-Cross Validation Poverty Estimation Model Based on Daytime and Nighttime Satellite Imagery



Gambar 39. Visualisasi evaluasi pada *5-fold cross validation* pembangunan model berdasarkan *Dataset 2* (citra satelit siang dan malam hari)

Dari Tabel 20 dan Gambar 37 dapat terlihat bahwa pada *fold 1* dan *fold 2*, model SVR cenderung memiliki nilai RMSE, MAE, dan MAPE paling kecil. Pada *fold 3*, 4, dan 5, model MLP cenderung memiliki nilai RMSE, MAE, dan MAPE paling kecil.

4.2.2.6 Pemilihan Model Terbaik

Rata-rata hasil evaluasi *5-fold cross validation* pada masing-masing model disajikan pada Tabel 21. Dari tabel tersebut dapat terlihat bahwa model Resnet34+MLP memiliki kemampuan terbaik dalam memprediksi data uji karena memiliki nilai rata-rata RMSE, MAE, dan MAPE terendah. Oleh karena itu, Resnet34+MLP terpilih sebagai model terbaik untuk prediksi kemiskinan berdasarkan *Dataset 2* (citra satelit siang dan malam hari). Model terbaik kemudian dilatih dengan seluruh data untuk kepentingan prediksi pada resolusi spasial 1,5 km.

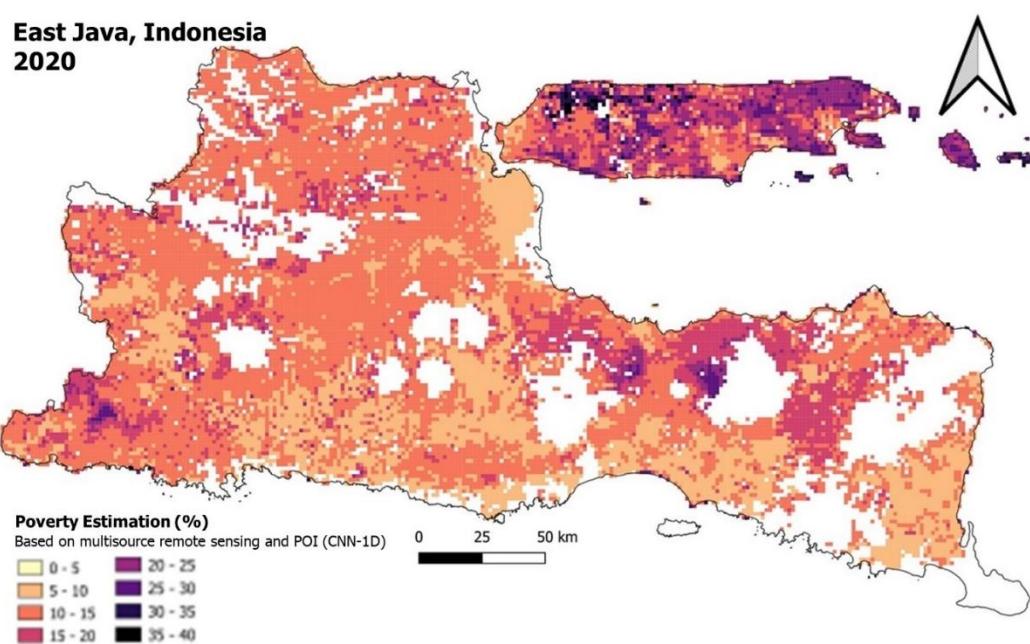
Tabel 21. Hasil Evaluasi Rata-Rata 5-Fold Cross Validation

Model	5-Cross Validation (Rata-Rata)		
	RMSE	MAE	MAPE
(1)	(2)	(3)	(4)
Resnet34+SVR	4,58	3,57	31,9%
Resnet34+DTR	5,19	4,2	41,6%
Resnet34+RFR	4,60	3,61	34%
Resnet34+MLP	3,911	3,028	28,05%
Resnet34+CNN-1D	5,264	4,344	45,144%

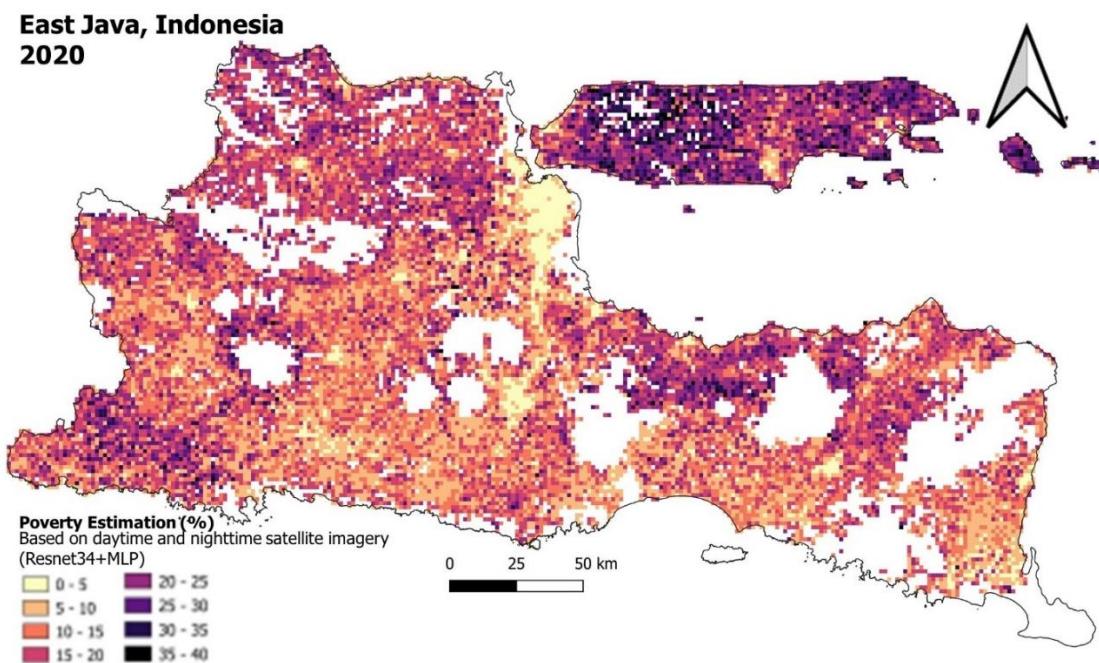
4.3 Pembangunan dan Evaluasi Peta Kemiskinan Level Grid 1,5 km

4.3.1 Pembangunan Peta Kemiskinan Level Grid 1,5 km

Kedua model estimasi kemiskinan yang telah dibangun pada Tujuan 2 (CNN-1D dan Resnet-34 + MLP) kemudian digunakan untuk memprediksi kemiskinan pada level *grid* dengan resolusi spasial 1,5 km sehingga didapat dua peta kemiskinan. Peta kemiskinan kemudian di-*overlay* dengan peta estimasi sebaran penduduk level *grid* Hasil Sensus Penduduk 2020. *Overlay* dilakukan karena kemiskinan erat kaitannya dengan keberadaan penduduk (Wilde et al., 2016). Gambar 40 menunjukkan hasil estimasi pemetaan kemiskinan yang dibangun berdasarkan model CNN-1D dengan *Dataset* 1 (citra satelit multisumber dan POI) pada level grid 1,5 km. Gambar 41 menunjukkan hasil estimasi pemetaan kemiskinan yang dibangun berdasarkan model Resnet34+MLP dengan *Dataset* 2 (citra satelit siang dan malam hari) pada level grid 1,5 km.



Gambar 40. Estimasi Pemetaan Kemiskinan yang Dibangun Berdasarkan Model CNN-1D Dengan *Dataset 1*



Gambar 41. Estimasi Pemetaan Kemiskinan yang Dibangun Berdasarkan Model Resnet-34 + MLP Dengan *Dataset 2*

Dari Gambar 40 dan Gambar 41 dapat telihat bahwa estimasi pemetaan kemiskinan yang dibangun dengan model CNN-1D dengan *Dataset 1* (citra satelit multisumber dan POI) memiliki sebaran yang berbeda dari estimasi pemetaan kemiskinan yang

dibangun berdasarkan citra satelit siang dan malam hari. Untuk memperoleh peta kemiskinan terbaik dilakukan evaluasi melalui pendekatan numerik dan deskriptif.

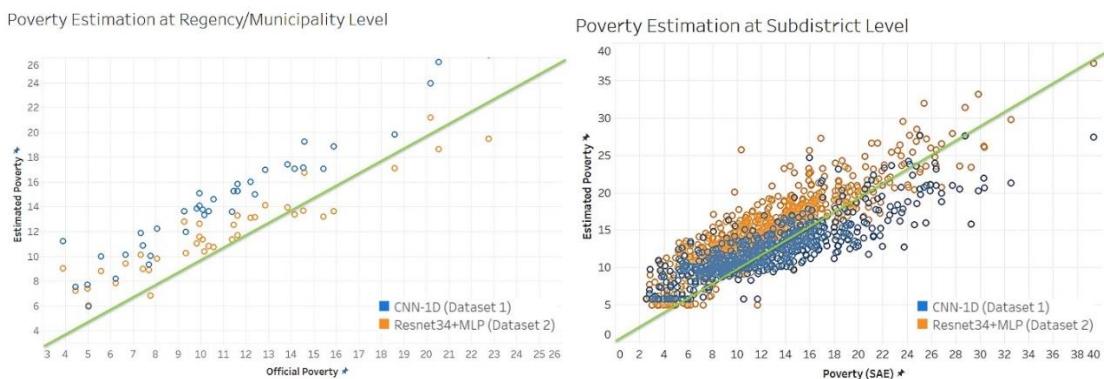
4.3.2 Hasil Evaluasi Numerik

Untuk mengetahui hasil pemetaan mana yang lebih merepresentasikan kemiskinan, idealnya evaluasi dilakukan di level *grid*. Akan tetapi, karena keterbatasan penyajian data kemiskinan yang hanya sampai pada level kabupaten/kota dan estimasi dengan hasil estimasi SAE yang dilakukan hanya sampai level kecamatan, evaluasi numerik hanya akan dilakukan pada level kecamatan dan level kabupaten. Tabel 22 menunjukkan hasil evaluasi pada level kecamatan dan kabupaten.

Tabel 22. Hasil Evaluasi Numerik pada Level Kecamatan dan Kabupaten

Evaluasi	Kecamatan		Kabupaten	
Dataset	Citra Satelit Multisumber dan POI	Citra Satelit Siang dan Malam Hari	Citra Satelit Multisumber dan POI	Citra Satelit Siang dan Malam Hari
(1)	(2)	(3)	(4)	(5)
Model	CNN – 1D	Resnet-34 + MLP	CNN – 1D	Resnet-34 + MLP
RMSE	3,15	3,69	1,95	3,63
MAE	2,39	2,65	1,61	3,42
MAPE	23,6%	25%	19,99%	37,88%

Gambar 42 menunjukkan scatter plot perbandingan nilai prediksi dengan nilai aktual kemiskinan pada level kabupaten/kota atau kecamatan.



Gambar 42. Scatter Plot Hasil Estimasi Kemiskinan

Dari Tabel 23 dapat diketahui bahwa peta kemiskinan hasil prediksi model CNN-1D yang dibangun berdasarkan *Dataset 1* (citra satelit multisumber dan POI) lebih dapat merepresentasikan kemiskinan pada level kecamatan dan kabupaten karena memiliki RMSE, MAE, dan MAPE terkecil. Pemetaan yang dibangun dengan model ini memperoleh nilai RMSE 3,15, MAE 2,39, dan MAPE 23,6% pada level kecamatan serta RMSE 1,95, MAE 1,61, dan MAPE 19,99% pada level kabupaten. Oleh karena itu, peta kemiskinan yang dibangun dari model CNN-1D berdasarkan citra satelit multisumber dan POI dipilih sebagai peta kemiskinan terbaik pada penelitian ini.

Tabel 23 menunjukkan hasil penghitungan nilai korelasi (baik *Pearson* maupun *Spearman-rank*) dan *adjusted R²* hasil estimasi pemetaan kemiskinan terbaik. Dari tabel tersebut dapat terlihat bahwa hasil pemetaan kemiskinan yang dibangun berkorelasi kuat dengan kemiskinan pada level kecamatan maupun kabupaten/kota. Nilai *adjusted R²* menunjukkan bahwa sebanyak 70% varians kemiskinan level kecamatan dan 84% varians kemiskinan level kabupaten dapat dijelaskan oleh variabel-variabel independent dalam model.

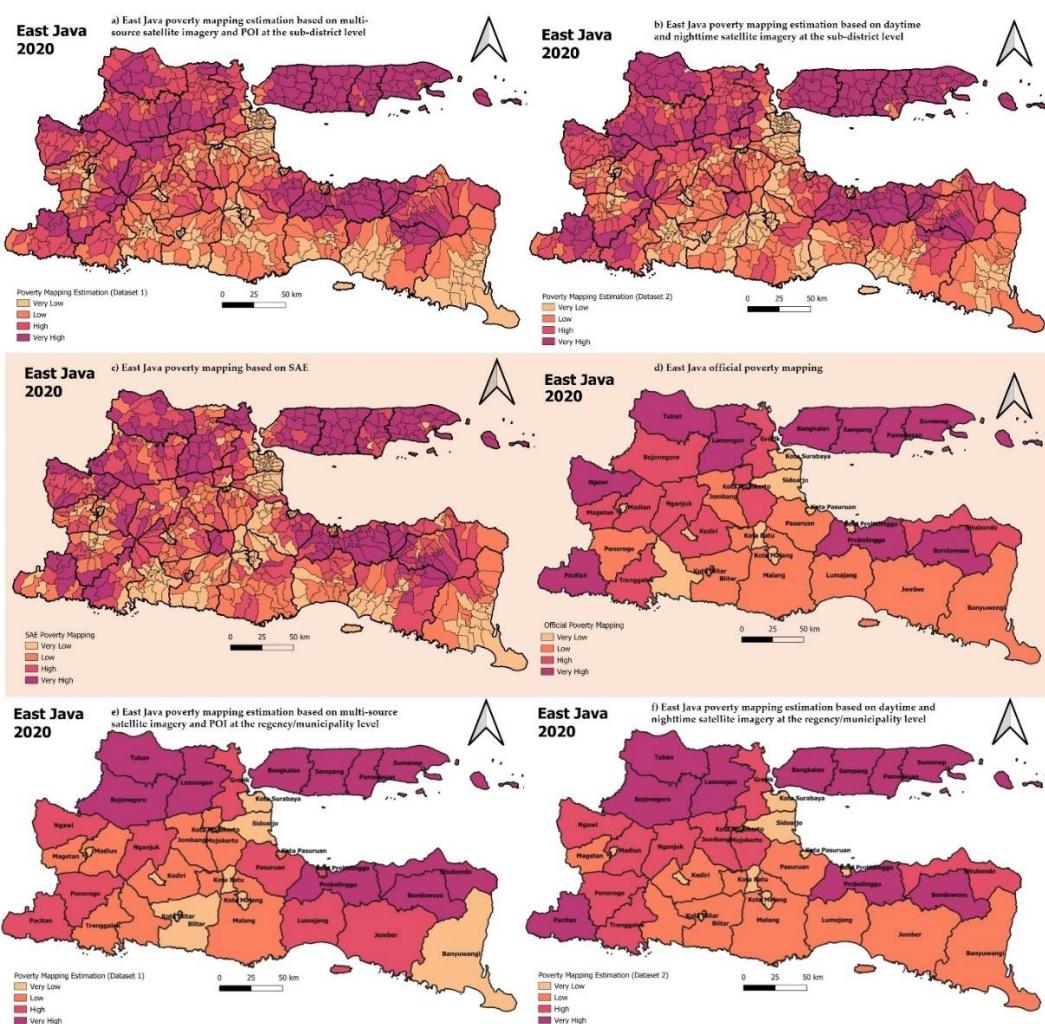
Tabel 23. Hasil Penghitungan Korelasi dan Koefisien Determinasi Hasil Pemetaan Model Terbaik

Evaluasi	Kecamatan	Kabupaten/Kota
(1)	(2)	(3)
Pearson Correlation	0,84	0,94
Spearman-Rank Correlation	0,83	0,94
R ²	0,71	0,88
Adjusted R ²	0,7	0,84

Gambar 43 menunjukkan visualisasi hasil prediksi pada level kecamatan (a dan b) dan kemiskinan level kecamatan hasil SAE (c) serta visualisasi hasil prediksi pada level kabupaten (e dan f) dan kemiskinan level kecamatan hasil SAE (d) yang diklasifikasikan ke dalam empat kelas (sangat rendah, rendah, tinggi, dan sangat tinggi). Dari gambar tersebut didapatkan pola kemiripan yaitu kemiskinan yang cenderung terfokus pada wilayah Pulau Madura. Pulau Madura merupakan daerah yang kurang subur berupa dataran tinggi tanpa gunung berapi dan lahan pertanian yang kering (Wasonowati et al., 2019). Kemiskinan tinggi juga banyak terdapat pada wilayah barat laut provinsi Jawa Timur seperti Kabupaten Tuban, Lamongan, dan Bojonegoro yang didominasi oleh keadaan tanah yang berbukit dan banyak terdapat gunung kapur. Kabupaten Probolinggo, Bondowoso, dan Situbondo juga memiliki memiliki kemiskinan yang tinggi, wilayah ini merupakan wilayah pesisir (Probolinggo dan Situbondo) yang masih terdapat banyak lahan kosong yang gersang. Kabupaten Bondowoso merupakan daerah dengan kelerengan bervariasi sehingga rawan terjadi bencana banjir dan tanah longsor.

Wilayah dengan kemiskinan rendah cenderung terpusat di wilayah tengah dan selatan pulau Jawa. Di wilayah Tengah terdapat Kota Surabaya yang

merupakan dataran rendah dan kota metropolitan (Santoso & Aulia, 2018), Kota Malang, dan Kota Batu yang merupakan daerah yang berkembang dengan baik dengan dataran tinggi yang subur dan daerah pariwisata (Wisnubroto et al., 2021). Wilayah selatan Jawa Timur yaitu Kabupaten Malang, Lumajang, dan Jember merupakan wilayah dengan tanah yang subur dan banyak menghasilkan.

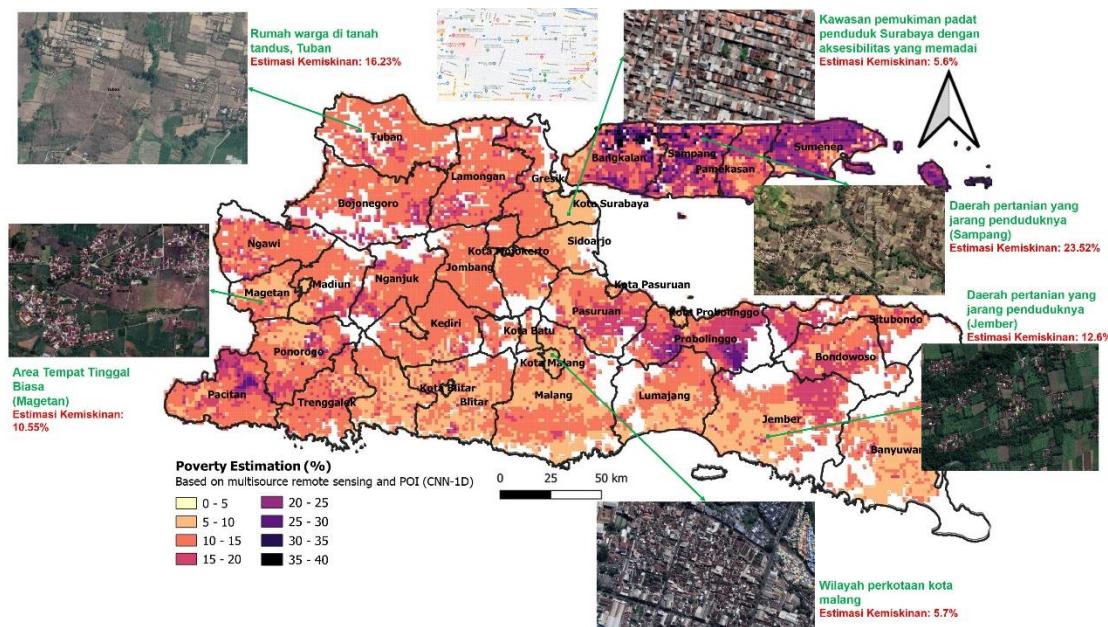


Gambar 43. Visualisasi Hasil Estimasi Kemiskinan pada Level Kecamatan dan Kabupaten

4.3.3 Hasil Evaluasi Deskriptif

Beberapa penelitian sebelumnya telah menunjukkan bahwa identifikasi visual menggunakan gambar resolusi tinggi dapat digunakan sebagai alternatif evaluasi yang tidak dapat dilakukan secara kuantitatif pada setiap piksel (Shi et al.,

2020; Varshney et al., 2015). Dalam penelitian ini, dipilih secara acak enam piksel $1,5 \times 1,5$ km. Evaluasi kemudian dilakukan untuk mengidentifikasi fitur geografisnya menggunakan gambar beresolusi tinggi *Google Satellite*. Peta kemiskinan yang dipilih adalah peta kemiskinan terbaik yang paling dekat dengan kemiskinan resmi yang dibangun berdasarkan CNN-1D dengan *Dataset 1* (citra satelit multi-sumber dan POI). Gambar 44 menunjukkan hasil identifikasi visual peta kemiskinan. Dapat dilihat bahwa estimasi kemiskinan yang tinggi biasanya ditemukan di daerah berpenduduk jarang yang dikelilingi oleh tanah kosong, yang biasanya merupakan lahan pertanian. Estimasi kemiskinan yang rendah, di sisi lain, lebih mungkin ditemukan di daerah berpenduduk padat dengan akses yang mudah. Hal ini sejalan dengan laporan Badan Pusat Statistik yang menyatakan bahwa kemiskinan di perdesaan lebih tinggi daripada di perkotaan (BPS, 2020).



Gambar 44. Evaluasi Deskriptif Hasil Estimasi Pemetaan Kemiskinan

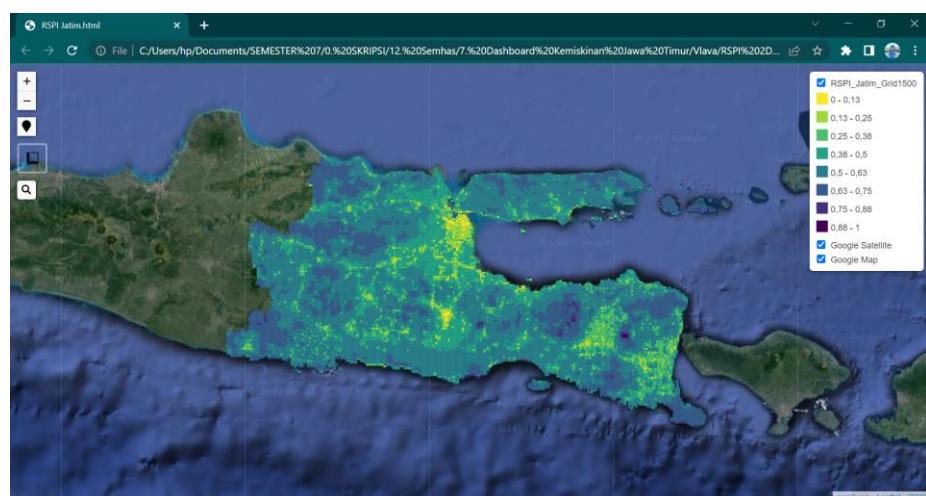
4.4 Hasil Pembangunan *Dashboard* Visualisasi Hasil Penelitian

Pemetaan kemiskinan yang dibangun pada penelitian ini memiliki beberapa kelebihan yang dapat mengisi keterbatasan data kemiskinan resmi yaitu: 1) penyajian data lebih granular (sampai level grid 1,5km), 2) diperoleh dari sumber data yang tidak berbayar dengan waktu dan tenaga relatif rendah untuk memperolehnya, dan 3) dibangun dengan data yang sesuai dengan keadaan lapangan, mewakili populasi, dan periode pembaruan cepat (paling lama satu bulan). Akan tetapi, penggunaan data ini juga memiliki beberapa kelemahan seperti 1) kualitas data citra satelit yang bergantung pada tutupan awan dan POI yang bergantung input pengguna OSM, 2) belum dapat dilakukan evaluasi yang benar-benar akurat sampai level grid 1,5km, dan 3) hanya dapat memberikan informasi kemiskinan berdasarkan wilayah. Di sisi lain, kelemahan tersebut dapat dilengkapi oleh data kemiskinan resmi. Oleh karena itu, terdapat potensi integrasi kedua data kemiskinan ini untuk pengambilan keputusan yang lebih baik. Untuk mendukung potensi integrasi dan mempermudah pemangku kepentingan dalam mengakses hasil penelitian, visualisasi pemetaan kemiskinan kemudian disajikan dalam bentuk *map dashboard* interaktif. *Map dashboard* interaktif disajikan dengan dua versi yaitu dua dimensi (2D) dan tiga dimensi (3D).

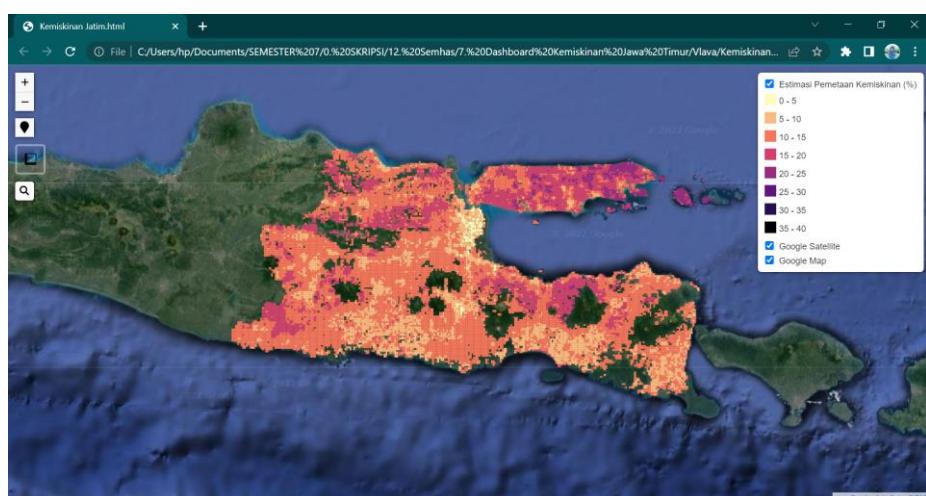
4.4.1 Hasil Pembangunan *Dashboard* 2 Dimensi (2D)

Kelebihan dari penggunaan *map dashboard* 2D adalah memudahkan pengguna (pemangku kepentingan) untuk melakukan identifikasi wilayah sederhana pada masing-masing *grid* 1,5 km dengan bantuan citra satelit resolusi tinggi *Google Satellite*. Terdapat dua jenis *map dashboard* 2D yang dibangun pada penelitian ini yaitu *map dashboard* 2D untuk RSPI dan *map dashboard* 2D untuk

estimasi kemiskinan seperti yang tertera pada Gambar 45 (RSPI) dan Gambar 46 (estimasi kemiskinan). Dari *map dashboard* RSPI, pengguna dapat memantau daerah terdeprivasi spasial pada level *grid* 1,5 km. Sedangkan dari *map dashboard* estimasi kemiskinan, pengguna dapat memantau estimasi kemiskinan moneter pada level *grid* 1,5 km.



Gambar 45. *Map Dashboard* 2D RSPI



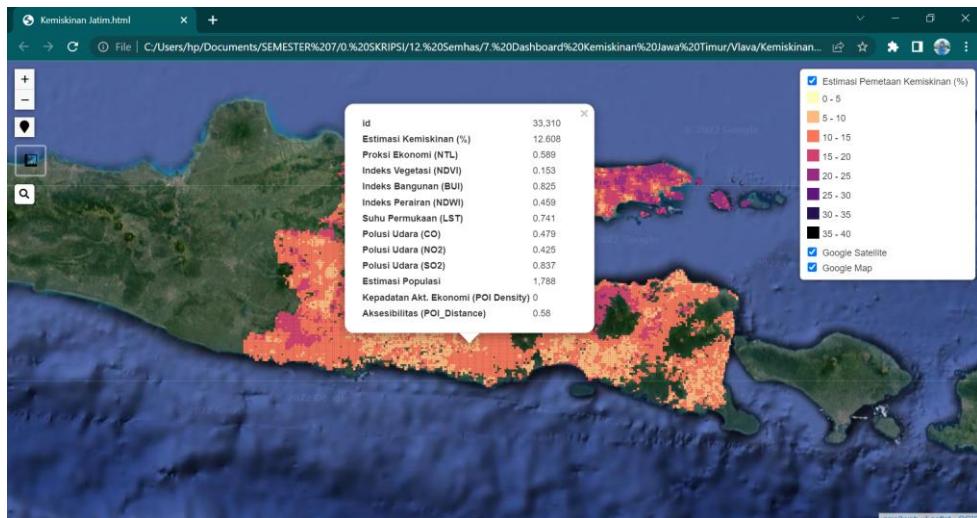
Gambar 46. *Map Dashboard* 2D Estimasi Kemiskinan

Dashboard 2D yang dibangun pada penelitian ini dilengkapi dengan beberapa fitur pendukung yang dapat membantu pemangku kepentingan dalam mengidentifikasi kemiskinan secara lebih granular pada level *grid* 1,5km. Beberapa

fitur pendukung tersebut diantaranya *hover*, legenda, *zoom*, *measure distance* dan *search*.

4.4.1.1 Fitur Hover Map Dashboard 2D

Fitur *hover* digunakan untuk memudahkan pengguna melihat data estimasi kemiskinan beserta data pendukung yang digunakan pada pembangunan model seperti proksi ekonomi (NTL), indeks vegetasi (NDVI), indeks bangunan (BUI), indeks perairan (NDWI), suhu permukaan (LST), polusi udara yang dilihat dari tiga pendekatan (CO, NO₂, dan SO₂), kepadatan aktivitas ekonomi (POI *density*), dan aksesibilitas (POI *distance*) dengan hanya mengarahkan *pointer mouse* ke titik yang mau diidentifikasi. Nilai yang ditampilkan merupakan nilai dengan skala 0-1. Gambar 47 menunjukkan visualisasi pengaplikasian fitur *hover* pada *map dashboard*.

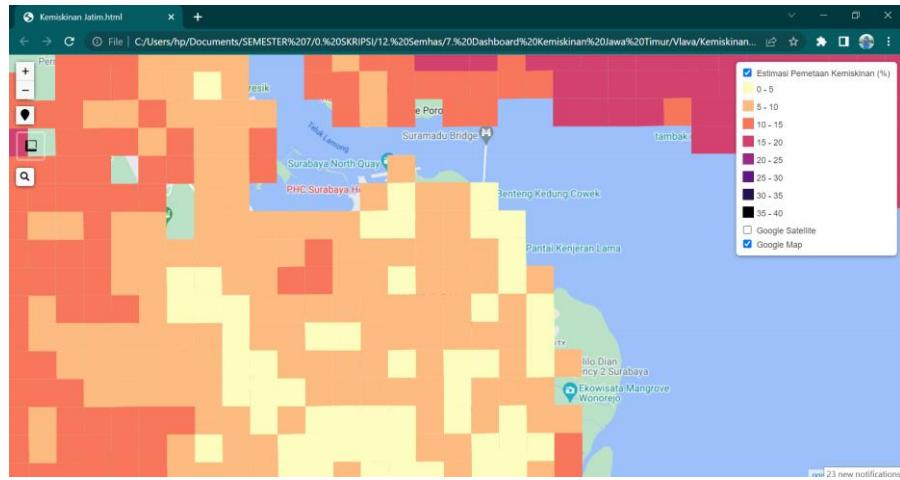


Gambar 47. Visualisasi Penggunaan Fitur *Hover*

4.4.1.2 Fitur Zoom Map Dashboard 2D

Fitur *zoom* dilakukan untuk memperbesar tampilan (*zoom in*) dan memperkecil tampilan (*zoom out*). Dengan adanya fitur ini pengguna dapat dengan lebih fleksibel memfokuskan wilayah yang ingin diamati. Fitur *zoom in* dan *zoom*

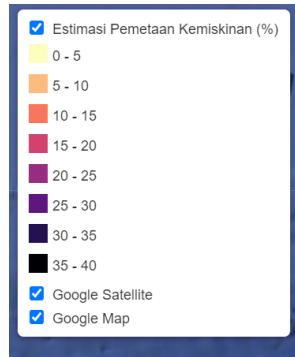
out dapat diaplikasikan dengan *scroll mouse*. Gambar 48 menunjukkan visualisasi penerapan *zoom in*.



Gambar 48. Visualisasi Penggunaan Fitur *Zoom*

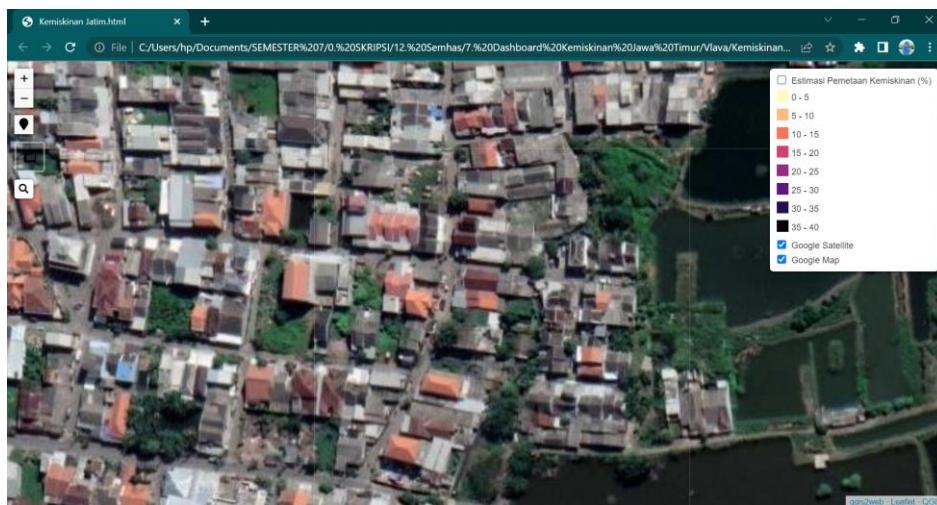
4.4.1.3 Fitur Legenda *Map Dashboard* 2D

Fitur legenda berguna untuk menampilkan nilai estimasi kemiskinan menurut warna yang tertera pada peta. Semakin muda warna semakin rendah nilai estimasi kemiskinan di wilayah tersebut. Fitur ini dilengkapi dengan *check boxes* yang memungkinkan pengguna memilih *layer* apa saja yang mau ditampilkan pada *dashboard*. Fitur ini berguna untuk kepentingan identifikasi visual dengan *Google Satellite* dan identifikasi wilayah dengan *Google Maps*. Dengan adanya fitur ini pengguna dapat dengan mudah melihat detail lapangan *grid* yang bersesuaian. Gambar 49 menunjukkan visualisasi fitur legenda pada *map dashboard* yang dibangun.



Gambar 49. Visualisasi Penggunaan Fitur Legenda

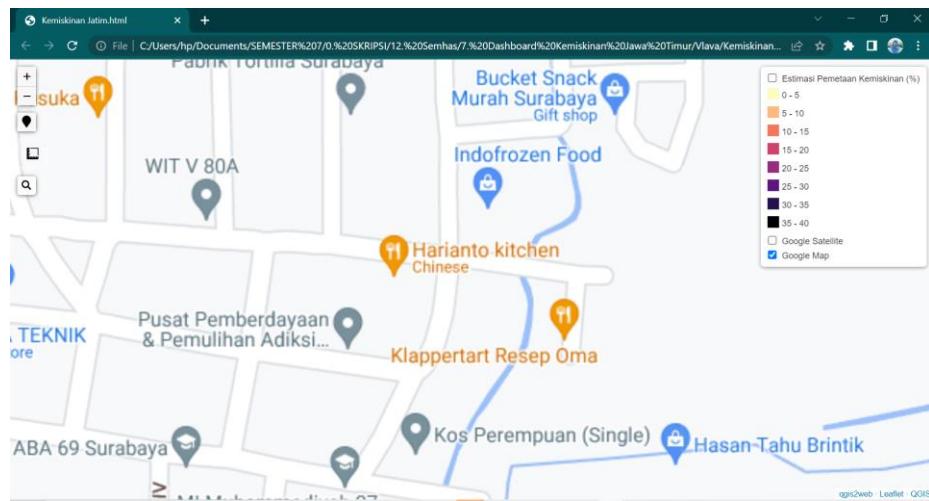
Gambar 50 menunjukkan visualisasi identifikasi visual yang dilakukan dengan menghilangkan *layer* peta estimasi kemiskinan di wilayah Kota Surabaya. Identifikasi visual dapat dimanfaatkan untuk melakukan verifikasi lapangan sederhana wilayah yang bersesuaian dengan *grid* dengan melihat tampilannya dari atas.



Gambar 50. Visualisasi Identifikasi Visual *Google Satellite* dengan Fitur Legenda

Gambar 51 menunjukkan visualisasi identifikasi wilayah yang dilakukan dengan menghilangkan *layer* peta estimasi kemiskinan dan *Google Satellite* di wilayah Kota Surabaya. Identifikasi wilayah bermanfaat untuk mengetahui detail wilayah yang bersesuaian dengan *grid* termasuk titik-titik lokasi penting yang

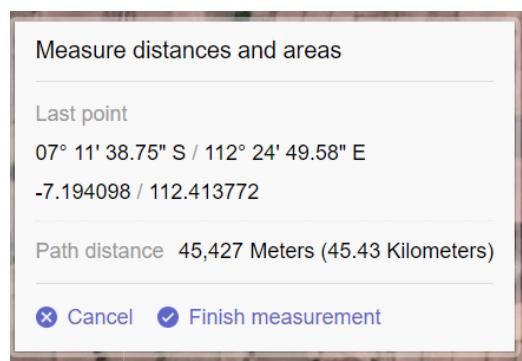
terdapat pada *grid* tersebut. Fitur ini berpotensi untuk dimanfaatkan dalam pencarian wilayah penyaluran bantuan sosial.



Gambar 51. Visualisasi Identifikasi Wilayah *Google Maps* dengan Fitur Legenda

4.4.1.4 Fitur *Measure Distance Map Dashboard 2D*

Fitur *measure distance* dapat digunakan untuk mengukur jarak dua titik yang terdapat pada peta. Fitur ini bermanfaat untuk mengukur jarak suatu wilayah misalnya kantor pemerintahan dengan daerah target bantuan sosial. Gambar 52 menunjukkan visualisasi pemanfaatan fitur *measure distance* pada *map dashboard* untuk menghitung jarak Bandara Juanda dengan pemukiman terpencil di Kabupaten Lamongan.



Gambar 52. Visualisasi Penggunaan Fitur *Measure Distance*

4.4.1.5 Fitur *Search Map Dashboard* 2D

Fitur *search* dapat digunakan untuk mencari tempat tertentu pada peta. Fitur ini dapat bermanfaat untuk mengetahui estimasi kemiskinan pada wilayah di sekitar titik tertentu. Gambar 53 menunjukkan visualisasi pencarian Jalan Ahmad Yani pada *map dashboard*.



Gambar 53. Visualisasi Penggunaan Fitur *Search*

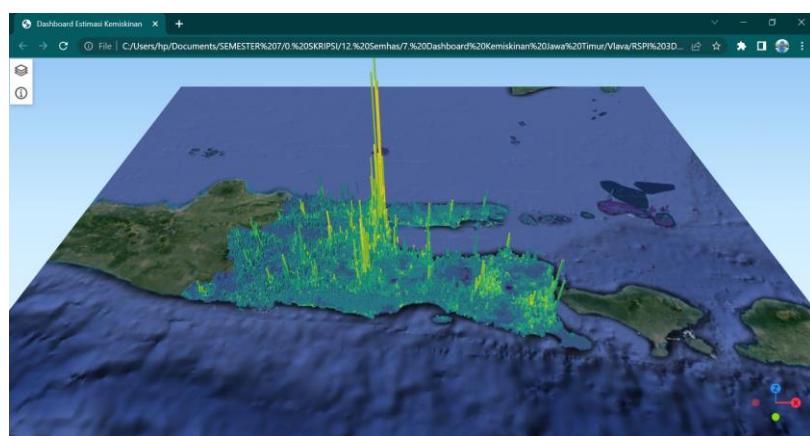
Gambar 54 menunjukkan visualisasi penerapan fitur *search* untuk mencari Bandara Juanda. Dari hasil identifikasi yang dilakukan, estimasi kemiskinan pada wilayah di sekitar Bandara Juanda adalah 3,85%.



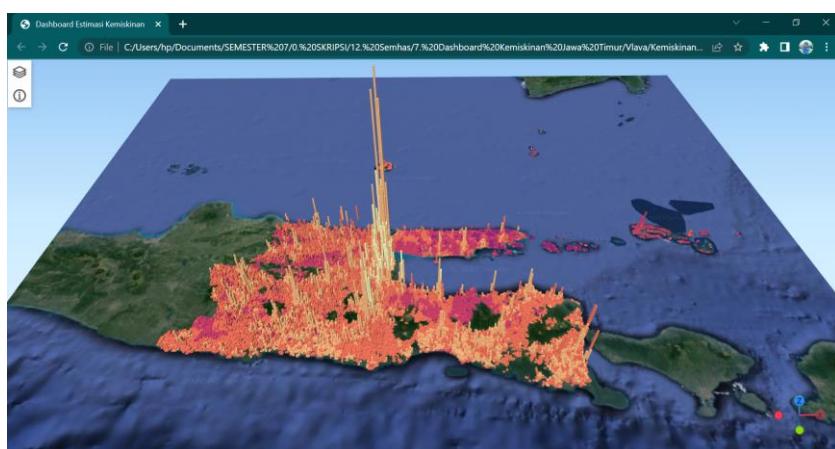
Gambar 54. Visualisasi Penggunaan Fitur *Search* untuk Estimasi Kemiskinan di Sekitar Titik Tertentu

4.4.2 Hasil Pembangunan *Dashboard 3 Dimensi* (3D)

Kelebihan dari penggunaan *map dashboard* 3D adalah memudahkan pengguna (pemangku kepentingan) untuk melakukan identifikasi wilayah sekaligus memperoleh informasi terkait estimasi populasi yang mendiami *grid* tersebut. Semakin tinggi balok, semakin tinggi pula estimasi populasi di wilayah *grid* yang bersesuaian. Terdapat dua jenis *map dashboard* 3D yang dibangun pada penelitian ini yaitu *map dashboard* 3D untuk RSPI dan *map dashboard* 3D untuk estimasi kemiskinan seperti yang tertera pada Gambar 55 (RSPI) dan Gambar 56 (estimasi kemiskinan).



Gambar 55. *Map Dashboard* 3D RSPI

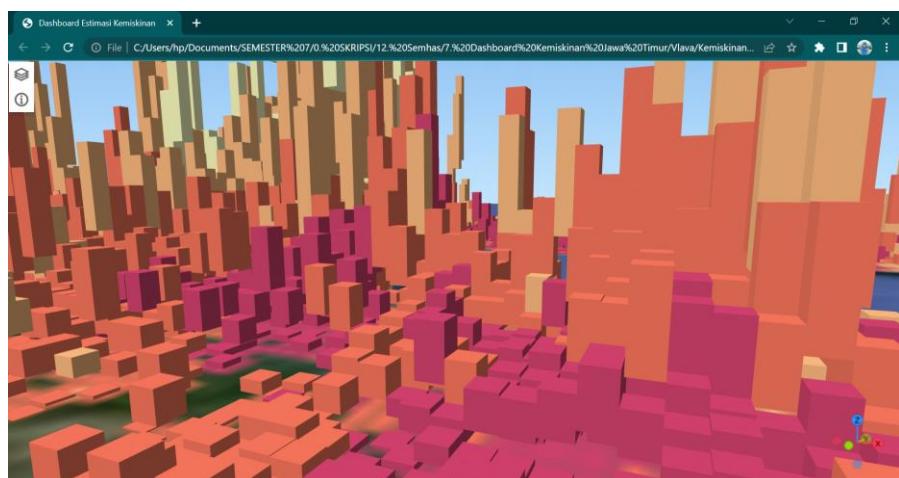


Gambar 56. *Map Dashboard* 3D Estimasi Kemiskinan

Dashboard 3D yang dibangun pada penelitian ini dilengkapi dengan beberapa fitur pendukung yang dapat membantu pemangku kepentingan dalam mengidentifikasi kemiskinan secara lebih granular pada level *grid* 1,5km. Beberapa fitur pendukung tersebut diantaranya *zoom*, *rotate*, dan *orbit*, serta *measure distance* dan *grid info*.

4.4.2.1 Fitur *Zoom*, *Rotate*, dan *Orbit Map Dashboard* 3D

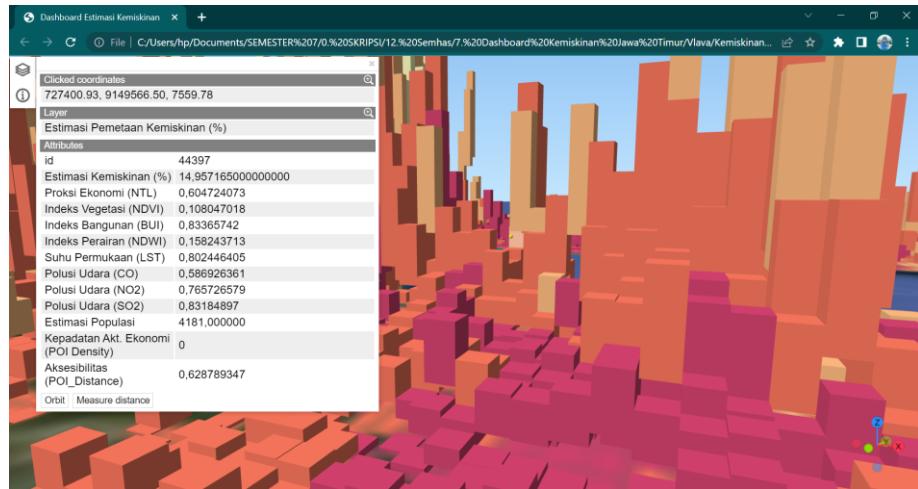
Fitur *zoom*, *rotate*, dan *orbit* membantu pengguna memfokuskan pengamatan pada titik tertentu. Gambar 57 menunjukkan pengaplikasian fitur ini untuk pengamatan mendetail pada wilayah Kabupaten Pasuruan.



Gambar 57. Hasil Implementasi Fitur *Zoom*, *Rotate*, dan *Orbit Map Dashboard* 3D

Fitur *grid info* dapat digunakan untuk mengetahui informasi detail dari suatu titik. Informasi detail yang dimaksud meliputi nilai estimasi kemiskinan beserta data pendukung yang digunakan pada pembangunan model seperti proksi ekonomi (NTL), indeks vegetasi (NDVI), indeks bangunan (BUI), indeks perairan (NDWI), suhu permukaan (LST), polusi udara yang dilihat dari tiga pendekatan (CO, NO₂,

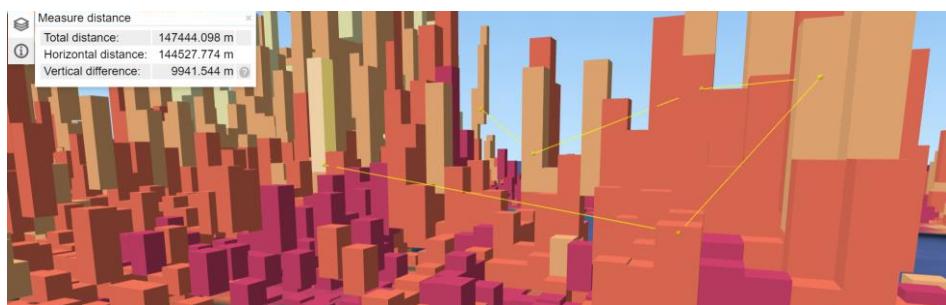
dan SO₂), kepadatan aktivitas ekonomi (POI *density*), dan aksesibilitas (POI *distance*). Untuk menggunakan fitur ini pengguna dapat mengklik balok yang ingin diidentifikasi. Gambar 58 menunjukkan fitur *grid info* yang ditampilkan pada salah satu balok.



Gambar 58. Hasil Implementasi Fitur *Grid Info*

4.4.2.3 Fitur *Measure Distance Dashboard 3D*

Fitur *measure distance* dapat digunakan untuk mengukur jarak dua atau lebih titik yang berupa rute pada peta. Gambar 59 menunjukkan aplikasi dari fitur ini untuk mengukur jarak rute beberapa titik di Kabupaten Pasuruan.



Gambar 59. Hasil Implementasi Fitur *Measure Distance Map Dashboard 3D*

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Penelitian ini mengusulkan pendekatan baru untuk menyediakan peta kemiskinan Jawa Timur yang lebih granular dalam hal cakupan (sampai level *grid* dengan resolusi spasial 1,5 km) dengan biaya dan waktu pembaruan yang lebih singkat guna mendukung pemantauan kemiskinan yang lebih baik dalam pencapaian target pengentasan kemiskinan pemerintah Indonesia. Penelitian ini memanfaatkan dua *Dataset* utama yaitu *big data* citra satelit multisumber dan *Point of Interest* (POI) (*Dataset* 1) serta citra satelit siang dan malam hari (*Dataset* 2). Dari hasil penelitian yang dilakukan, dapat diambil empat poin kesimpulan menurut tujuan yang didefinisikan.

Untuk menjawab Tujuan 1 yaitu membangun indeks kemiskinan spasial relatif yang dapat memetakan kemiskinan spasial, telah dibangun *Relative Spatial Poverty Index* (RSPI) yang dapat memetakan daerah terdeprivasi spasial di Jawa Timur pada level *grid* 1,5 km. RSPI berkorelasi kuat ($r_{Pearson} = 0,71$; $r_{Spearman} = 0,79$) dengan data kemiskinan resmi pada level kabupaten/kota. Dari hasil identifikasi visual didapatkan bahwa daerah dengan skor RSPI tinggi cenderung merupakan daerah yang jarang penduduk dengan aksesibilitas yang kurang memadai. Kawasan ini cenderung merupakan kawasan deprivasi spasial dengan aksesibilitas yang terbatas.

Dari Tujuan 2 yaitu membangun model estimasi kemiskinan, telah dibangun model estimasi kemiskinan dengan dua skenario. Pertama, model dibangun menggunakan *Dataset 1* (citra satelit multisumber dan POI) dengan ekstraksi fitur *zonal statistics* sebagai pendekatan baru yang diusulkan dalam penelitian ini. Kedua, model dibangun menggunakan *Dataset 2* (data satelit siang dan malam) dengan ekstraksi fitur *transfer learning Resnet-34* sebagai pendekatan yang banyak digunakan pada penelitian sebelumnya. Pada setiap skenario, dilakukan pembandingan performa model *machine learning* yang berbeda yaitu *Support Vector Regression* (SVR), *Decision Tree Regression* (DTR), dan *Random Forest Regression* (RFR) serta model *deep learning* yaitu *Multiple Layer Perceptron* (MLP) dan *Convolutional Neural Network-1D* (CNN-1D). Berdasarkan hasil evaluasi pembangunan model, model CNN-1D dipilih sebagai model terbaik pada skenario pertama dan model *Resnet-34+MLP* dipilih sebagai model terbaik pada skenario kedua. Hal ini menunjukkan bahwa dalam penelitian ini model *deep learning* mengungguli model *machine learning*.

Menjawab Tujuan 3, yaitu membangun dan mengevaluasi estimasi pemetaan kemiskinan, telah dibangun estimasi pemetaan kemiskinan pada level *grid* 1,5 km berdasarkan kedua model estimasi yang dibangun pada Tujuan 2. Berdasarkan evaluasi menggunakan data kemiskinan resmi level kabupaten/kota, hasil estimasi pemetaan kemiskinan yang dibangun menggunakan model CNN-1D pada skenario pertama yang merupakan pendekatan yang diusulkan dalam penelitian dipilih sebagai pemetaan terbaik dengan nilai RMSE 1,95, MAE 1,61, MAPE 19,99%, korelasi *Pearson* 0,94, dan *adjusted R²* 0,84. Hasil identifikasi visual menunjukkan bahwa estimasi kemiskinan yang tinggi biasanya ditemukan

pada jarang penduduk dan dikelilingi oleh lahan kosong, yang biasanya merupakan lahan pertanian. Di sisi lain, estimasi kemiskinan yang rendah lebih mungkin ditemukan di daerah berpenduduk padat dengan aksesibilitas yang lebih memadai. Hal ini sejalan dengan laporan Badan Pusat Statistik (BPS) yang menyatakan bahwa kemiskinan di perdesaan lebih tinggi daripada di perkotaan.

Untuk memenuhi Tujuan 4 yaitu membangun *map dashboard* interaktif berbasis *website* untuk menyajikan hasil pemetaan kemiskinan, telah dibangun *map dashboard* dalam penyajian dua dimensi (2D) dan tiga dimensi (3D). *Map dashboard* interaktif 2D dibangun untuk memudahkan pengguna (pemangku kepentingan) dalam melakukan identifikasi wilayah dengan berbagai fitur interaktif yang tersedia seperti *hover*, legenda (dengan *layer Google Satellite* dan *Google Maps*), *zoom*, *measure distance* dan *search*. *Map dashboard* interaktif 3D dibangun untuk memudahkan pengguna untuk melakukan identifikasi wilayah sekaligus memperoleh informasi terkait estimasi populasi yang mendiami *grid* tersebut dengan fitur pendukung *zoom*, *rotate*, dan *orbit*, serta *measure distance* dan *grid info*.

5.2. Saran

5.2.1 Saran Untuk Pemangku Kepentingan

Pemangku kepentingan dapat memanfaatkan *map dashboard* interaktif berbasis *website* yang menyajikan peta kemiskinan Provinsi Jawa Timur pada level *grid* 1,5 km sebagai data alternatif rujukan pengambilan keputusan terkait pengentasan kemiskinan di Indonesia khususnya Provinsi Jawa Timur. Data yang disajikan dapat menjadi rujukan dalam pemetaan wilayah miskin dan wilayah

terdeprivasi spasial. *Map dashboard* yang dibangun dapat digunakan dalam memonitor estimasi angka kemiskinan dengan lebih aktual dan terperinci dari segi waktu dan wilayah. Informasi tersebut dapat dimanfaatkan dalam usaha pengentasan kemiskinan seperti pemetaan wilayah untuk penyaluran bantuan sosial. Untuk mendukung estimasi berkelanjutan, model estimasi kemiskinan yang dibangun berpotensi untuk dapat dimanfaatkan dalam estimasi angka kemiskinan bulanan sehingga dapat memperkaya rujukan data aktual.

5.2.2. Saran Untuk Penelitian Selanjutnya

Untuk memperkaya informasi kemiskinan, penelitian selanjutnya dapat menggunakan metode yang sama untuk estimasi kemiskinan multidimensional atau kemiskinan menurut jenis kelamin dan umur. Penelitian selanjutnya dapat menggunakan variasi *big data* lain yang terbukti memiliki keterkaitan dengan kemiskinan pada studi kasus internasional seperti *Facebook Advertising Data* dan *Mobile Phone Data* pada estimasi kemiskinan di Indonesia. Penelitian serupa pada wilayah studi kasus lain juga dapat dilakukan dengan merujuk metode yang digunakan pada penelitian ini. Selain itu, penelitian selanjutnya juga dapat mengkaji keakuratan estimasi kemiskinan bulanan berdasarkan model yang dibangun pada penelitian ini.

DAFTAR PUSTAKA

- Abirami, S., & Chitra, P. (2020). Energy-efficient edge based real-time healthcare support system. In *Advances in computers* (Vol. 117, Issue 1, pp. 339–368). Elsevier.
- Afifah, U. N., & Faradis, R. (2019). Sosial Ekonomi Nasional Survey (Susenas) Data Optimization with Small Area Estimation (SAE) Case Study: Village Level Poverty Estimation in Belitung Timur Regency. *Seminar Nasional Official Statistics, 2019*(1), 132–139. <https://doi.org/https://doi.org/10.34123/semnasoffstat.v2019i1.147>
- Ahmed, S. (2018). Assessment of urban heat islands and impact of climate change on socioeconomic over Suez Governorate using remote sensing and GIS techniques. *The Egyptian Journal of Remote Sensing and Space Science*, 21(1), 15–25. <https://doi.org/https://doi.org/10.1016/j.ejrs.2017.08.001>
- Alcock, P. (1997). *Understanding poverty*. Macmillan International Higher Education.
- Alkire, S., Kanagaratnam, U., & Suppa, N. (2021). *The global multidimensional poverty index (MPI) 2021*.
- Asian Development Bank. (2020). *Introduction to Small Area Estimation Techniques: A Practical Guide for National Statistics Offices* (Issue May). <https://www.adb.org/sites/default/files/publication/609476/small-area-estimation-guide-nsos.pdf>
- ASROL, A., & Ahmad, H. (2018). Analysis of factors that affect poverty in Indonesia. *Revista Espacios*, 39(45).
- Bakhsh, K., Akmal, T., Ahmad, T., & Abbas, Q. (2022). Investigating the nexus among sulfur dioxide emission, energy consumption, and economic growth: empirical evidence from Pakistan. *Environmental Science and Pollution Research*, 29(5), 7214–7224. <https://doi.org/https://doi.org/10.1016/j.landurbplan.2014.11.009>
- Bappenas. (2020). *Rencana Pembangunan Jangka Menengah Nasional (RPJMN) 2020-2024*.
- Belaidouni, S., & Miraoui, M. (2016). Machine learning technologies in smart spaces. *Proceedings of the 10th International Conference on Mobile Ubiquitous Computing, Systems, Services and Technologies, Venice, Italy*, 9–13.
- Bengio, Y., Goodfellow, I., & Courville, A. (2017). *Deep learning* (Vol. 1). MIT press Cambridge, MA, USA.
- Bexell, M., & Jönsson, K. (2017). Responsibility and the United Nations' sustainable development goals. *Forum for Development Studies*, 44(1), 13–29.
- Billings, M. E., & Thornton, J. D. (2021). The legacy of racial and ethnic segregation on health: the story of continuous positive airway pressure use. In *American Journal of Respiratory and Critical Care Medicine* (Vol. 204, Issue

- 3, pp. 252–254). American Thoracic Society.
- Bishop, C. M., & Nasrabadi, N. M. (2006). *Pattern recognition and machine learning* (Vol. 4, Issue 4). Springer.
- Bloice, M. D., Stocker, C., & Holzinger, A. (2017). Augmentor: an image augmentation library for machine learning. *ArXiv Preprint ArXiv:1708.04680*.
- BPS. (2020). *Data dan Informasi Kemiskinan Kabupaten/Kota Tahun 2020*.
- BPS. (2021). *Data dan Informasi Kemiskinan Kabupaten/Kota Tahun 2021*. <https://bps.go.id/>
- BPS. (2022). *Teknik Pengumpulan Data dan Preprocessing Citra Satelit*. BPS.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Campbell, J. B., & Wynne, R. H. (2011). *Introduction to remote sensing*. Guilford Press.
- Cartone, A., & Postiglione, P. (2021). Principal component analysis for geographical data: the role of spatial effects in the definition of composite indicators. *Spatial Economic Analysis*, 16(2), 126–147. <https://doi.org/https://doi.org/10.1080/17421772.2020.1775876>
- Chen, Z., Yu, B., Hu, Y., Huang, C., Shi, K., & Wu, J. (2015). Estimating house vacancy rate in metropolitan areas using NPP-VIIRS nighttime light composite data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 8(5), 2188–2197. <https://doi.org/10.1109/JSTARS.2015.2418201>
- Chi, G., Fang, H., Chatterjee, S., & Blumenstock, J. E. (2022). Microestimates of wealth for all low-and middle-income countries. *Proceedings of the National Academy of Sciences*, 119(3).
- Coondoo, D., Majumder, A., & Chattopadhyay, S. (2011). District-level poverty estimation: a proposed method. *Journal of Applied Statistics*, 38(10), 2327–2343.
- Copernicus Sentinel-5P (processed by ESA). (2018). TROPOMI Level 2 Carbon Monoxide total column products. In Version 01. <https://doi.org/https://doi.org/10.5270/S5P-1hkp7rp>
- Copernicus Sentinel-5P (processed by ESA). (2021). *TROPOMI Level 2 Nitrogen Dioxide total column products*. <https://doi.org/https://doi.org/10.5270/S5P-9bnp8q8>
- Dawson, T., Sandoval, J. S., Sagan, V., & Crawford, T. (2018). A spatial analysis of the relationship between vegetation and poverty. *ISPRS International Journal of Geo-Information*, 7(3), 83. <https://doi.org/https://doi.org/10.3390/ijgi7030083>
- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248–255.
- Dong, B., & Wang, X. (2016). Comparison deep learning method to traditional

- methods using for network intrusion detection. *2016 8th IEEE International Conference on Communication Software and Networks (ICCSN)*, 581–585.
- Elvidge, C. D., Baugh, K., Zhizhin, M., Hsu, F. C., & Ghosh, T. (2017). VIIRS night-time lights. *International Journal of Remote Sensing*, 38(21), 5860–5879.
- Elvidge, C. D., Sutton, P. C., Ghosh, T., Tuttle, B. T., Baugh, K. E., Bhaduri, B., & Bright, E. (2009). A global poverty map derived from satellite data. *Computers & Geosciences*, 35(8), 1652–1660. <https://doi.org/https://doi.org/10.1016/j.cageo.2009.01.009>
- Fujii, H., & Managi, S. (2016). Economic development and multiple air pollutant emissions from the industrial sector. *Environmental Science and Pollution Research*, 23(3), 2802–2812.
- Gao, B.-C. (1996). NDWI—A normalized difference water index for remote sensing of vegetation liquid water from space. *Remote Sensing of Environment*, 58(3), 257–266.
- Ghosh, T., Anderson, S. J., Elvidge, C. D., & Sutton, P. C. (2013). Using nighttime satellite imagery as a proxy measure of human well-being. *Sustainability*, 5(12), 4988–5019. <https://doi.org/https://doi.org/10.3390/su5124988>
- Gilpin, L. H., Bau, D., Yuan, B. Z., Bajwa, A., Specter, M., & Kagal, L. (2018). Explaining explanations: An overview of interpretability of machine learning. *2018 IEEE 5th International Conference on Data Science and Advanced Analytics (DSAA)*, 80–89.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT press.
- Goyal, M. K., Singh, V., & Meena, A. H. (2015). Geospatial and hydrological modeling to assess hydropower potential zones and site location over rainfall dependent Inland catchment. *Water Resources Management*, 29(8), 2875–2894.
- Han, C., Gu, Z., & Yang, H. (2021). EKC Test of the Relationship between Nitrogen Dioxide Pollution and Economic Growth—A Spatial Econometric Analysis Based on Chinese City Data. *International Journal of Environmental Research and Public Health*, 18(18), 9697. <https://doi.org/https://doi.org/10.3390/ijerph18189697>
- Hauberg, S., Freifeld, O., Larsen, A. B. L., Fisher, J., & Hansen, L. (2016). Dreaming more data: Class-dependent distributions over diffeomorphisms for learned data augmentation. *Artificial Intelligence and Statistics*, 342–350.
- He, C., Shi, P., Xie, D., & Zhao, Y. (2010). Improving the normalized difference built-up index to map urban built-up areas using a semiautomatic segmentation approach. *Remote Sensing Letters*, 1(4), 213–221.
- Huang, G., Zhou, W., & Cadenasso, M. L. (2011). Is everyone hot in the city? Spatial pattern of land surface temperatures, land cover and neighborhood socioeconomic characteristics in Baltimore, MD. *Journal of Environmental Management*, 92(7), 1753–1759. <https://doi.org/https://doi.org/10.1016/j.jenvman.2011.02.006>

- Ij, H. (2018). Statistics versus machine learning. *Nat Methods*, 15(4), 233.
- Imran, M., Hosen, M., & Chowdhury, M. A. F. (2018). Does poverty lead to crime? Evidence from the United States of America. *International Journal of Social Economics*.
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016a). Combining satellite imagery and machine learning to predict poverty. *Science*, 353(6301), 790–794. <https://doi.org/10.1126/science.aaf7894>
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016b). Combining Satellite Imagery and Machine Learning to Predict poverty. *Science*, 353(6301), 790–794. <https://doi.org/https://doi.org/10.1126/science.aaf7894>
- Kaimaris, D., & Patias, P. (2016). Identification and area measurement of the built-up area with the Built-up Index (BUI). *Int. J. Adv. Remote Sens. GIS*, 5(1), 1844–1858. <http://technical.cloud-journals.com/index.php/IJARSG/article/view/Tech-627>
- Karanam, H. K., & Neela, V. B. (2017). Study of normalized difference built-up (NDBI) index in automatically mapping urban areas from Landsat TN imagery. *Int J Eng Sci Math*, 8, 239–248.
- Laurentcia, S., & Yusran, R. (2021). Evaluation of the Non-Cash Food Assistance Program in Poverty Reduction in Padang District. *Journal of Civic Education*, 4(1), 7–17. <https://doi.org/https://doi.org/10.24036/jce.v4i1.433>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.
- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.
- Ledesma, C., Garonita, O. L., Flores, L. J., & Tingzon, I. (2020). Interpretable Poverty Mapping using Social Media Data , Satellite Images , and Geospatial Information. *Thinking Machines Data Science*, 1–6.
- Ledesma, C., Garonita, O. L., Flores, L. J., Tingzon, I., & Dalisay, D. (2020). Interpretable poverty mapping using social media data, satellite images, and geospatial information. *ArXiv Preprint ArXiv:2011.13563*.
- Lee, J., Lee, S. S., Chi, K. H., & others. (2010). Development of an urban classification method using a built-up index. *Sixth WSEAS International Conference on Remote Sensing, Iwate Prefectural University, Japan*, 39–43.
- Li, Y., Cao, Z., Long, H., Liu, Y., & Li, W. (2017). Dynamic analysis of ecological environment combined with land cover and NDVI changes and implications for sustainable urban–rural development: The case of Mu Us Sandy Land, China. *Journal of Cleaner Production*, 142, 697–715.
- Lipton, M., & Ravallion, M. (1995). Poverty and policy. *Handbook of Development Economics*, 3, 2551–2657.
- Liu, Y., & Xu, Y. (2016). A geographic identification of multidimensional poverty

- in rural China under the framework of sustainable livelihoods analysis. *Applied Geography*, 73, 62–76. <https://doi.org/https://doi.org/10.1016/j.apgeog.2016.06.004>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and Machine Learning forecasting methods: Concerns and ways forward. *PloS One*, 13(3), e0194889.
- Martinez, A., Addawe, M., Bulan, J. A. N., Durante, R. L., Fenz, K., & Hoffer, M. (2020). *Mapping Poverty through Data Integration and Artificial Intelligence* (Issue September). <https://www.adb.org/publications/mapping-poverty-data-integration-ai>
- Maurya, R., Gupta, P. R., Shukla, A. S., & Sharma, M. K. (2012). Building extraction from very high resolution multispectral images using NDVI based segmentation and morphological operators. *IEEE-International Conference On Advances In Engineering, Science And Management (ICAESM-2012)*, 577–581.
- McCoy, M. D. (2017). Geospatial Big Data and archaeology: Prospects and problems too great to ignore. *Journal of Archaeological Science*, 84, 74–94.
- McFeeters, S. K. (1996). The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features. *International Journal of Remote Sensing*, 17(7), 1425–1432. <https://doi.org/https://doi.org/10.1080/01431169608948714>
- Mia, B., Bhattacharya, R., & Woobaidullah, A. S. M. (2017). Correlation and monitoring of land surface temperature, urban heat island with land use-land cover of Dhaka City using satellite imageries. *International Journal of Research in Geography*, 3(4), 10–20.
- Moore, G. K. (1979). What is a picture worth? A history of remote sensing/Quelle est la valeur d'une image? Un tour d'horizon de télédétection. *Hydrological Sciences Bulletin*, 24(4), 477–485.
- Moroff, N. U., Kurt, E., & Kamphues, J. (2021). Machine Learning and statistics: A Study for assessing innovative demand forecasting models. *Procedia Computer Science*, 180, 40–49.
- Ngestrini, R. (2019). *Predicting Poverty of a Region from Satellite Imagery using CNNs*.
- Nurmasari, Y. (2021). *Deteksi Perkebunan Kelapa Sawit di Indonesia Menggunakan Citra Satelit Optik Sentinel-2 dan Landsat-8*. Politeknik Statistika STIS.
- Nurmasari, Y., & Wijayanto, A. W. (2021). Oil Palm Plantation Detection in Indonesia using Sentinel-2 and Landsat-8 Optical Satellite Imagery (Case Study: Rokan Hulu Regency, Riau Province). *International Journal of Remote Sensing and Earth Sciences (IJReSES)*, 18(1), 1–18. <https://doi.org/http://dx.doi.org/10.30536/j.ijreses.2021.v18.a3537>
- Oktaviani, A., & Johan, Y. (2016). Perbandingan Resolusi Spasial, Temporal Dan Radiometrik Serta Kendalanya. *Jurnal Enggano*, 1(2), 74–79.

- Paterakis, N. G., Mocanu, E., Gibescu, M., Stappers, B., & van Alst, W. (2017). Deep learning versus traditional machine learning methods for aggregated energy demand prediction. *2017 IEEE PES Innovative Smart Grid Technologies Conference Europe (ISGT-Europe)*, 1–6.
- Patterson, J., & Gibson, A. (2017). *Deep learning: A practitioner's approach*. “O'Reilly Media, Inc.”
- PBB. (2015). *About the Sustainable Development Goals*. SDGs. <https://www.un.org/sustainabledevelopment/sustainable-development-goals/>
- PBB. (2020). *End poverty in all its forms everywhere*. SDGs. <https://unstats.un.org/sdgs/report/2020/goal-01/>
- Polancik, G. (2009). Empirical Research Method Poster. *Jakarta: Rineka Cipta*.
- Purevdorj, T. S., Tateishi, R., Ishiyama, T., & Honda, Y. (1998). Relationships between percent vegetation cover and vegetation indices. *International Journal of Remote Sensing*, 19(18), 3519–3535. <https://doi.org/https://doi.org/10.1080/014311698213795>
- Putri, S. R., & Wijayanto, A. W. (2021). Learning Bayesian Network for Rainfall Prediction Modeling in Urban Area using Remote Sensing Satellite Data (Case Study: Jakarta, Indonesia). *Proceedings of The International Conference on Data Science and Official Statistics*, 2021(1), 77–90. <https://doi.org/https://doi.org/10.34123/icdsos.v2021i1.37>
- Putri, S. R., Wijayanto, A. W., & Sakti, A. D. (2022). Developing Relative Spatial Poverty Index Using Integrated Remote Sensing and Geospatial Big Data Approach: A Case Study of East Java, Indonesia. *ISPRS International Journal of Geo-Information*, 11(5), 275.
- Puttanapong, N., Martinez, A., Bulan, J. A. N., Addawe, M., Durante, R. L., & Martillan, M. (2022). Predicting poverty using geospatial data in Thailand. *ISPRS International Journal of Geo-Information*, 11(5), 293.
- Rassanjani, S. (2018). *Ending poverty: Factors that might influence the achievement of Sustainable Development Goals (SDGs) in Indonesia*.
- Rathore, S. S., & Kumar, S. (2016). A decision tree regression based approach for the number of software faults prediction. *ACM SIGSOFT Software Engineering Notes*, 41(1), 1–6.
- Raymaekers, J., & Rousseeuw, P. J. (2021). Transforming variables to central normality. *Machine Learning*, 1–23.
- Saadi, T. D. T. (2021). *Estimasi Luas Area Tanaman Padi dengan Deep Learning pada Citra Satelit Resolusi Menengah Sentinel-2 dan Landsat-8*. Politeknik Statistika STIS.
- Saadi, T. D. T., & Wijayanto, A. W. (2021). Machine Learning Applied to Sentinel-2 and Landsat-8 Multispectral and Medium-Resolution Satellite Imagery for the Detection of Rice Production Areas in Nganjuk, East Java, Indonesia. *International Journal of Remote Sensing and Earth Sciences*, 18(1), 19–32. <http://repositori.lapan.go.id/id/eprint/1477>

- Sagiroglu, S., & Sinanc, D. (2013). Big data: A review. *2013 International Conference on Collaboration Technologies and Systems (CTS)*, 42–47.
- Santoso, E. B., & Aulia, B. U. (2018). Ecological sustainability level of Surabaya City based on ecological footprint approach. *{IOP} Conference Series: Earth and Environmental Science*, 202, 12044. <https://doi.org/10.1088/1755-1315/202/1/012044>
- Schowengerdt, R. A. (2006). *Remote sensing: models and methods for image processing*. Elsevier.
- Sen, S., Sugiarto, D., & Rochman, A. (2020). Komparasi Metode Multilayer Perceptron (MLP) dan Long Short Term Memory (LSTM) dalam Peramalan Harga Beras. *Ultimatics: Jurnal Teknik Informatika*, 12(1), 35–41.
- Sharma, K. (2019). Hunger in Jharkhand: dimensions of poverty and food security in palamu district. *South Asia Research*, 39(1), 43–60.
- Shenfield, A., & Howarth, M. (2020). A novel deep learning model for the detection and identification of rolling element-bearing faults. *Sensors*, 20(18), 5112.
- Shi, K., Chang, Z., Chen, Z., Wu, J., & Yu, B. (2020). Identifying and evaluating poverty using multisource remote sensing and point of interest (POI) data: A case study of Chongqing, China. *Journal of Cleaner Production*, 255, 120245. <https://doi.org/https://doi.org/10.1016/j.jclepro.2020.120245>
- Shi, K., Yang, Q., Fang, G., Yu, B., Chen, Z., Yang, C., & Wu, J. (2019). Evaluating spatiotemporal patterns of urban electricity consumption within different spatial boundaries: A case study of Chongqing, China. *Energy*, 167, 641–653. <https://doi.org/https://doi.org/10.1016/j.energy.2018.11.022>
- Shi, K., Yu, B., Hu, Y., Huang, C., Chen, Y., Huang, Y., Chen, Z., & Wu, J. (2015). Modeling and mapping total freight traffic in China using NPP-VIIRS nighttime light composite data. *GIScience & Remote Sensing*, 52(3), 274–289. <https://doi.org/https://doi.org/10.1080/15481603.2015.1022420>
- Somvanshi, M., Chavan, P., Tambade, S., & Shinde, S. V. (2016). A review of machine learning techniques using decision tree and support vector machine. *2016 International Conference on Computing Communication Control and Automation (ICCUBEA)*, 1–7.
- Stephens, R. D., & Cadle, S. H. (1991). Remote sensing measurements of carbon monoxide emissions from on-road vehicles. *Journal of the Air & Waste Management Association*, 41(1), 39–46.
- Sugiyono. (2010). *Metode Penelitian Pendidikan Pendekatan Kuantitatif, kualitatif, dan R&D*. Alfabeta.
- Suthaharan, S. (2016). Decision tree learning. In *Machine Learning Models and Algorithms for Big Data Classification* (pp. 237–269). Springer.
- Suwargana, N. (2013). Resolusi spasial, temporal dan spektral pada citra satelit Landsat, SPOT dan IKONOS. *Jurnal Ilmiah Widya*, 1(2), 167–174.
- Syah, A. F. (2010). Penginderaan jauh dan aplikasinya di wilayah pesisir dan lautan. *Jurnal Kelautan: Indonesian Journal of Marine Science and Technology*, 3(1),

- Tamilselvi, R., Sivasakthi, B., & Kavitha, R. (2015). An efficient preprocessing and postprocessing techniques in data mining. *International Journal of Research in Computer Applications and Robotics*, 3(4), 80–85.
- Tingzon, I., Orden, A., Sy, S., Sekara, V., Weber, I., Fatehkia, M., Garcia, M., & Dohyung, H. (2019). Mapping Poverty in the Philippines Using Machine Learning, Satellite Imagery, and Crowd-sourced Geospatial Information. *SPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 42, 425–431. <https://doi.org/10.5194/isprs-archives-XLII-4-W19-425-2019>
- Tingzon, I., Orden, A., Sy, S., Sekara, V., Weber, I., Fatehkia, M., Herranz, M. G., & Kim, D. (2019). Mapping poverty in the Philippines using machine learning, satellite imagery, and crowd-sourced geospatial information. *AI for Social Good ICML 2019 Workshop*. <https://pdfs.semanticscholar.org/9d96/bbd1bab6f66015096336052bd86662e14c6d.pdf>
- Triscowati, D. W., Sartono, B., Kurnia, A., Dirgahayu, D., & Wijayanto, A. W. (2020). Classification of rice-plant growth phase using supervised random forest method based on landsat-8 multitemporal data. *International Journal of Remote Sensing and Earth Sciences (IJReSES)*, 16(2), 187–196. <https://doi.org/http://dx.doi.org/10.30536/j.ijreses.2019.v16.a3217>
- Triscowati, D. W., Sartono, B., Kurnia, A., Domiri, D. D., & Wijayanto, A. W. (2019). Multitemporal remote sensing data for classification of food crops plant phase using supervised random forest. *Sixth Geoinformation Science Symposium*, 11311, 1131102. <https://doi.org/https://doi.org/10.1117/12.2547216>
- Uddin, M. N., Islam, A. K. M. S., Bala, S. K., Islam, G. M. T., Adhikary, S., Saha, D., Haque, S., Fahad, M. G. R., & Akter, R. (2019). Mapping of climate vulnerability of the coastal region of Bangladesh using principal component analysis. *Applied Geography*, 102, 47–57. <https://doi.org/https://doi.org/10.1016/j.apgeog.2018.12.011>
- V\u00e2\u00e7irghileanu, M., S\u00e3uavulescu, I., Mihai, B.-A., Nistor, C., & Dobre, R. (2020). Nitrogen Dioxide (NO₂) Pollution monitoring with Sentinel-5P satellite imagery over Europe during the coronavirus pandemic outbreak. *Remote Sensing*, 12(21), 3575.
- Varshney, K. R., Chen, G. H., Abelson, B., Nowocin, K., Sakhrani, V., Xu, L., & Spatocco, B. L. (2015). Targeting villages for rural development using satellite image analysis. *Big Data*, 3(1), 41–53.
- Veefkind, J. P., Aben, I., McMullan, K., Förster, H., De Vries, J., Otter, G., Claas, J., Eskes, H. J., De Haan, J. F., Kleipool, Q., & others. (2012). TROPOMI on the ESA Sentinel-5 Precursor: A GMES mission for global observations of the atmospheric composition for climate, air quality and ozone layer applications. *Remote Sensing of Environment*, 120, 70–83.
- Wan, Z., Zhang, Y., Zhang, Q., & Li, Z.-L. (2004). Quality assessment and

- validation of the MODIS global land surface temperature. *International Journal of Remote Sensing*, 25(1), 261–274.
- Wang, B., Tian, J., Yang, P., & He, B. (2021). Multi-Scale Features of Regional Poverty and the Impact of Geographic Capital: A Case Study of Yanbian Korean Autonomous Prefecture in Jilin Province, China. *Land*, 10(12). <https://doi.org/10.3390/land10121406>
- Wang, Y., & Chen, Y. (2017). Using VPI to Measure Poverty-Stricken Villages in China. *Social Indicators Research*, 133(3), 833–857. <https://doi.org/https://doi.org/10.1007/s11205-016-1391-5>
- Wang, Yu, Li, J., Wang, L., Lin, Y., Zhou, M., Yin, P., & Yao, S. (2021). The impact of carbon monoxide on years of life lost and modified effect by individual-and city-level characteristics: Evidence from a nationwide time-series study in China. *Ecotoxicology and Environmental Safety*, 210, 111884. <https://doi.org/https://doi.org/10.1016/j.ecoenv.2020.111884>
- Wasowati, C., Sulistyaningsih, E., Indradewa, D., & Kurniasih, B. (2019). Physiological characters of *Moringa oleifera* Lamk in Madura. *AIP Conference Proceedings*, 2120(1), 30024. <https://doi.org/https://doi.org/10.1063/1.5115628>
- Wen, L., Li, X., & Gao, L. (2020). A transfer convolutional neural network for fault diagnosis based on ResNet-50. *Neural Computing and Applications*, 32(10), 6111–6124.
- Wijayanto, A. W., Triscowati, D. W., & Marsuhandi, A. H. (2020). Maize field area detection in East Java, Indonesia: An integrated multispectral remote sensing and machine learning approach. *2020 12th International Conference on Information Technology and Electrical Engineering (ICITEE)*, 168–173. <https://doi.org/10.1109/ICITEE49829.2020.9271683>
- Wilde, P., Llobrener, J., & Ver Ploeg, M. (2016). Population density, poverty, and food retail access in the United States: an empirical approach. In *Feeding Cities* (pp. 39–54). Routledge.
- Wisnubroto, E. I., Rustiadi, E., Fauzi, A., & Murtilaksono, K. (2021). The dynamic changes in peri-urban agricultural area and typology of multi-function agriculture in Batu City, Indonesia. *IOP Conference Series: Earth and Environmental Science*, 667(1), 12093.
- World Bank. (2009). Handbook on Poverty and Inequality. In *Handbook on Poverty and Inequality*. The World Bank. <https://doi.org/10.1596/978-0-8213-7613-3>
- Wu, J., He, L.-Y., & Zhang, Z. (2019). *Does China Fall into Poverty-Environment Traps? Evidence from Long-term Income Dynamics and Urban Air Pollution*.
- Xu, Y., Mo, Y., & Zhu, S. (2021). Poverty mapping in the dian-gui-qian contiguous extremely poor area of southwest china based on multi-source geospatial data. *Sustainability*, 13(16), 8717.
- Yang, Y. Z., Cai, W. H., & Yang, J. (2017). Evaluation of MODIS land surface temperature data to estimate near-surface air temperature in Northeast China. *Remote Sensing*, 9(5), 410.

- Yao, Y., Li, X., Liu, X., Liu, P., Liang, Z., Zhang, J., & Mai, K. (2017). Sensing spatial distribution of urban land use by integrating points-of-interest and Google Word2Vec model. *International Journal of Geographical Information Science*, 31(4), 825–848.
- Yao, Y., Liu, X., Li, X., Zhang, J., Liang, Z., Mai, K., & Zhang, Y. (2017). Mapping fine-scale population distributions at the building level by integrating multisource geospatial big data. *International Journal of Geographical Information Science*, 31(6), 1220–1244.
- Yasin, H., Prahatama, A., & Utami, T. W. (2014). Prediksi harga saham menggunakan support vector regression dengan algoritma grid search. *Media Statistika*, 7(1), 29–35.
- Yin, J., Qiu, Y., & Zhang, B. (2020). Identification of poverty areas by remote sensing and machine learning: a case study in guizhou, southwest china. *ISPRS International Journal of Geo-Information*, 10(1), 11. <https://doi.org/https://doi.org/10.3390/ijgi10010011>
- Yu, B., Tang, M., Wu, Q., Yang, C., Deng, S., Shi, K., Peng, C., Wu, J., & Chen, Z. (2018). Urban built-up area extraction from log-transformed NPP-VIIRS nighttime light composite data. *IEEE Geoscience and Remote Sensing Letters*, 15(8), 1279–1283. <https://doi.org/10.1109/LGRS.2018.2830797>
- Zha, Y., Gao, J., & Ni, S. (2003). Use of normalized difference built-up index in automatically mapping urban areas from TM imagery. *International Journal of Remote Sensing*, 24(3), 583–594. <https://doi.org/https://doi.org/10.1080/01431160304987>
- Zhao, N., Liu, Y., Cao, G., Samson, E. L., & Zhang, J. (2017). Forecasting China's GDP at the Pixel Level using Nighttime Lights Time Series and Population Images. *GISci. Remote Sens.*, 54, 407–425.
- Zhao, Naizhuo, Cao, G., Zhang, W., Samson, E. L., & Chen, Y. (2020). Remote sensing and social sensing for socioeconomic systems: A comparison study between nighttime lights and location-based social media at the 500 m spatial resolution. *International Journal of Applied Earth Observation and Geoinformation*, 87, 102058. <https://doi.org/https://doi.org/10.1016/j.jag.2020.102058>
- Zhao, X., Yu, B., Liu, Y., Chen, Z., Li, Q., Wang, C., & Wu, J. (2019a). Estimation of poverty using random forest regression with multi-source data: A case study in Bangladesh. *Remote Sensing*, 11(4), 375. <https://doi.org/https://doi.org/10.3390/rs11040375>
- Zhao, X., Yu, B., Liu, Y., Chen, Z., Li, Q., Wang, C., & Wu, J. (2019b). Estimation of Poverty Using Random Forest Regression with Multi-source data: A case study in Bangladesh. *Remote Sensing*, 11(4), 1–18. <https://doi.org/10.3390/rs11040375>
- Zheng, Y., Zhou, Q., He, Y., Wang, C., Wang, X., & Wang, H. (2021). An Optimized Approach for Extracting Urban Land Based on Log-Transformed DMSP-OLS Nighttime Light, NDVI, and NDWI. *Remote Sensing*, 13(4), 766. <https://doi.org/https://doi.org/10.3390/rs13040766>

- Zhou, C., Li, F., Zhang, J., Zhao, J., Zhang, Y., & Wang, J. (2020). Analysis of Spatial and Temporal Variations of Vegetation Index in Liaodong Bay in the last 30 years based on the GEE Platform. *IOP Conference Series: Earth and Environmental Science*, 502(1), 12037.
- Zhou, D., Xiao, J., Bonafoni, S., Berger, C., Deilami, K., Zhou, Y., Frolking, S., Yao, R., Qiao, Z., & Sobrino, J. A. (2018). Satellite remote sensing of surface urban heat islands: Progress, challenges, and perspectives. *Remote Sensing*, 11(1), 48.
- Zhou, N., Hubacek, K., & Roberts, M. (2015). Analysis of spatial patterns of urban growth across South Asia using DMSP-OLS nighttime lights data. *Applied Geography*, 63, 292–303.
<https://doi.org/https://doi.org/10.1016/j.apgeog.2015.06.016>
- Zikopoulos, P., & Eaton, C. (2011). *Understanding big data: Analytics for enterprise class hadoop and streaming data*. McGraw-Hill Osborne Media.

LAMPIRAN

Lampiran 1. *Source Code Pengumpulan Data Satelit NOAA-VIIRS*

```
// Filter Jawa Timur
var indo =
ee.FeatureCollection("users/221810596/Indo_Kab_Kot");
var jatim = Indonesia.filterMetadata('PROVINSI', 'equals',
'JAWA TIMUR')

// Nighttime Data
var dataset =
ee.ImageCollection('NOAA/VIIRS/DNB/MONTHLY_V1/VCMSLCFG')
.filter(ee.Filter.date('2020-01-01', '2020-
12-31'));
var nighttime = dataset.select('avg_rad');
var nighttimeVis = {min: 0.0, max: 60.0};

// Crop Nighttime Data and Visualize It
Map.setCenter(112.749, -7.2499, 8);
var jatimnight = nighttime.median().clip(jatim);
Map.addLayer(jatimnight, nighttimeVis, 'Jatim Nighttime');

// Export GeoTIFF Image
Export.image.toDrive({
  image : jatimnight,
  description : '2020_Jatim_VIIRS',
  scale : 10,
  region : jatim,
  folder : '/content/gdrive/MyDrive/0. SKRIPSI/Pengumpulan
Data/',
  maxPixels: 1e10
})
```

Lampiran 2. *Source Code Pengumpulan Data Satelit Sentinel-2*

```
// Filter Jawa Timur
var indo =
ee.FeatureCollection("users/221810596/Indo_Kab_Kot");
var jatim = Indonesia.filterMetadata('PROVINSI', 'equals',
'JAWA TIMUR')

// Create Cloud Masking Function
var masking = function maskS2clouds(image) {
  var qa = image.select('QA60');
  var cloudBitMask = 1 << 10;
```

```

var cirrusBitMask = 1 << 11;
var mask = qa.bitwiseAnd(cloudBitMask).eq(0)
  .and(qa.bitwiseAnd(cirrusBitMask).eq(0));
return image.updateMask(mask).divide(10000);
}

// Filetring and Cloud Selection
var SENTINEL2_2020 = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterDate('2020-01-01', '2020-12-31')
  .filterBounds(jatim)
  .sort('CLOUD_COVER')
  .map(masking)
  .median()
  .clip(jatim);
print(SENTINEL2_2020)

// Band Selection
var Bands_SENTINEL2_2020 =
SENTINEL2_2020.select(['B1','B2','B3','B4','B8','B12']);

// Export GeoTIFF Image
Export.image.toDrive({
  image: Bands_SENTINEL2_2020,
  description: '2020_Jatim_Sentinel2',
  folder : '/content/gdrive/MyDrive/0. SKRIPSI/Pengumpulan
Data/',
  region: jatim,
  scale : 10,
  maxPixels: 1e10
});

```

Lampiran 3. *Source Code Pengumpulan Data Satelit MODIS*

```

// Filter Jawa Timur
var indo =
ee.FeatureCollection("users/221810596/Indo_Kab_Kot");
var jatim = Indonesia.filterMetadata('PROVINSI', 'equals',
'JAWA TIMUR')

// Quality Assessment
var masking = function maskme(image) {
  var qa = image.select('QC_Day');
  var Mandatory = 1 << 1;
  var DataQuality = 1 << 3;
  var LSTerror = 1 << 7
  var mask = qa.bitwiseAnd(cloudBitMask).eq(0)
    .and(qa.bitwiseAnd(cirrusBitMask).eq(0));

```

```

        return image.updateMask(mask);
    }

// Filetring
var LST_2020 = ee.ImageCollection("MODIS/006/MOD11A1")
    .filterDate('2020-01-01', '2020-12-31')
    .filterBounds(jatim);
print(LST_2020)

// Visualization
Map.addLayer(LST_2020.mean().select('LST_Day_1km'), {}, 'Daytime LST');

// Export GeoTIFF Image
Export.image.toDrive({
    image :
    LST_2020.median().clip(jatim).select('LST_Day_1km'),
    description: '2020_Jatim_MODIS',
    folder : '/content/gdrive/MyDrive/0. SKRIPSI/Pengumpulan
Data/',
    region: jatim,
    scale : 1000,
    maxPixels: 1e10
})

```

Lampiran 4. Source Code Pengumpulan Data Satelit Sentinel-5P

```

// Filter Jawa Timur
var indo =
ee.FeatureCollection("users/221810596/Indo_Kab_Kot");
var jatim = Indonesia.filterMetadata('PROVINSI', 'equals',
'JAWA TIMUR')

// Data CO
var CO = ee.ImageCollection('COPERNICUS/S5P/OFFL/L3_CO')
    .select('CO_column_number_density')
    .filterDate('2020-01-01', '2020-12-31');
var band_viz = {
    min: 0,
    max: 0.05
};

// Crop Jatim and Visualize It
var jatimCO = CO.median().clip(jatim);
Map.setCenter(112.749, -7.2499, 8);

```

```

// Crop Nighttime Data and Visualize It
Map.addLayer(jatimCO, band_viz, 'S5P CO');

// Export GeoTIFF Image
Export.image.toDrive({
  image : jatimCO,
  description: '2020_Jatim_MODIS',
  folder : '/content/gdrive/MyDrive/0. SKRIPSI/Pengumpulan
Data',
  region: jatim,
  scale : 1000,
  maxPixels: 1e10
})

```

Keterangan: *source code* disajikan untuk pengambilan data CO, pengambilan data SO₂ dapat dilakukan dengan mengganti ‘CO’ menjadi ‘SO₂’ begitu juga dengan NO₂

Lampiran 5. Source Code Resnet-34 Feature Extraction

Import Library

```

import fastai
from fastai import *
from fastai.vision import *
from fastai.metrics import error_rate
from fastai.callbacks import *
import torch
import torch.nn as nn
import torchvision.models as models
import torchvision.transforms as transforms
from torch.autograd import Variable

```

Augmentasi Citra

```

# by default Fastai uses horizontal flipping augmentation, we
add some more transformations to improve the training
aug_tfms=[contrast(scale=(0.9, 1.11),p=0.9)
          ,dihedral()
          ,symmetric_warp(magnitude=(-0.2,0.2))
          ]

tfms = get_transforms(flip_vert=True,
                      max_lighting=0.1,
                      xtra_tfms=aug_tfms,
                      )

```

```

data = ImageDataBunch.from_df(df=df, # using df to define training dataset
                                seed = 23,
                                path = '/content/gdrive/MyDrive/0. SKRIPSI/4. CNN Seminar/Data/',
                                folder = 'jpg_jatim',
                                valid_pct=0.2, # 20% of data will be used for validation
                                fn_col='file', # filename column
                                label_col='NTL_Klas', # classes
                                ds_tfms=tfms, # use transformations defined above
                                size=256# image size
                                ).normalize(imagenet_stats) # use the normalization that was used to train the pretrained model, in this case Imagenet database was used

```

Pemberian Bobot

```

from sklearn.utils.class_weight import compute_class_weight
# import scikit learn's compute_class_weight function

klaster_ntl = df['NTL_Klas'].to_numpy() # convert the bin_class into an array

wt = compute_class_weight(class_weight = 'balanced', classes = np.unique(klaster_ntl), y = klaster_ntl) #compute weights for each class

print("Computed weights: ", wt, "\n")
print(class_count)

```

Resnet-34 Training

```

learn = None
gc.collect()

w = torch.cuda.FloatTensor(wt)
learn = cnn_learner(
    data,
    models.resnet34,
    metrics = error_rate,
    loss_func=torch.nn.CrossEntropyLoss(weight=w)
)

```

```

callbacks = [SaveModelCallback(learn, monitor='error_rate', mode='min', name="sklearn_wt"),
             ShowGraph(learn),
             EarlyStoppingCallback(learn, min_delta=0.0001, patience=3)
            ]

learn.callbacks = callbacks

learn.fit_one_cycle(14, wd=0.1)

interp = ClassificationInterpretation.from_learner(learn)
interp.plot_confusion_matrix(figsize=(5,5), dpi=100)

```

Load Model

```

learn = cnn_learner(data, models.resnet34, metrics = error_rate,
                     pretrained=False)
learn.load("../jatim_model.pth")

```

Prediksi

```

def my_predict(self, item:ItemBase, return_x=False, batch_first=True, with_dropout=False, **kwargs):
    "Return probabilities for `item`."
    batch = self.data.one_item(item)
    res = self.pred_batch(batch=batch, with_dropout=with_dropout)
    raw_pred,x = grab_idx(res,0,batch_first=batch_first),batch[0]
    return (raw_pred)
setattr(Learner, 'my_predict', my_predict)

```

Ekstraksi Fitur

```

new_model = learn

print('learn length: ' + str(len(learn.model[1])))
print('-----')
print("Original fully-connected layer structure:")
print(learn.model[1])
print('')
print('')

layer_drops = 2

new_model.model[1] = new_model.model[1][:-layer_drops]

print('new_model length: ' + str(len(new_model.model[1])))

```

```

print('-----')
print("New fully-connected layer structure:")
print(new_model.model[1])

def Extract_Features (img):
    # Input: A jpg with the correct size (the input images were already resized during the tif to jpg conversion)
    # Return: A tensor of image features (second to last layer of the CNN)
    #those are the features that get weighted together to classify the image's nightlight class.

    img_feature_layer = new_model.my_predict(img).flatten()
    return(img_feature_layer)

features_out = np.empty((len(df.index), tensor_len))
features_out_img = df["file"]
# pred_out = np.empty((len(df["filename"]),1))
print(features_out.shape)
# print(pred_out.shape)
dfsave = df.copy(deep = True)

for i, path_i in enumerate(features_out_img):
    # open the image with the fastai open image function
    temp_img = open_image("/content/gdrive/MyDrive/0. SKRIPSI/4 . CNN Seminar/Data/jpg_jatim/"+path_i)
    # extract the features of the single image
    tempfeatures = Extract_Features (temp_img).flatten().reshape(1, -1).numpy()
    # store them for output
    features_out[i,:] = tempfeatures
    # get fitted values of the ridge regression and save the them
    # pred_out[i]      = float(best_ridge.predict(tempfeatures))
    # print(pred_out[i])

print(dfsave.shape)
print(df.shape)

features_out_pd = pd.DataFrame(data = features_out, index = features_out_img)

```

Lampiran 6. Source Code Pembangunan Model Support Vector Regression (SVR)

Pembangunan Model *Dataset 1* (Citra Satelit Multisumber dan POI)

```
svr = SVR(**{'C': 100,
'gamma': 10,
'kernel': 'rbf',
'epsilon': 0.3})
```

Pembangunan Model *Dataset 2* (Citra Satelit Siang dan Malam Hari)

```
svr = SVR(**{'C': 1,
'gamma': 0.01,
'kernel': 'rbf'})  
'epsilon': 0.1})
```

Lampiran 7. Source Code Pembangunan Model Decision Tree Regression (DTR)

Pembangunan Model *Dataset 1* (Citra Satelit Mulisumber dan POI)

```
model_dt=DecisionTreeRegressor(max_depth= 3,
max_features= 'sqrt',
max_leaf_nodes= 30,
min_samples_leaf= 1,
min_weight_fraction_leaf= 0.2,
splitter= 'best',
random_state=1234
)
```

Pembangunan Model *Dataset 2* (Citra Satelit Siang dan Malam Hari)

```
model_dt=DecisionTreeRegressor(max_depth= 12,
max_features= 'sqrt',
max_leaf_nodes= 50,
min_samples_leaf= 3,
min_weight_fraction_leaf= 0.2,
splitter= 'best',
random_state=1234)
```

Lampiran 8. Source Code Pembangunan Model Random Forest Regression (RFR)

Pembangunan Model *Dataset 1* (Citra Satelit Mulisumber dan POI)

```
rfr = RandomForestRegressor(bootstrap= True,
max_depth= 90,
max_features= 3,
min_samples_leaf=5,
min_samples_split= 8,
n_estimators= 100,
random_state = 42)
```

Pembangunan Model *Dataset 2* (Citra Satelit Siang dan Malam Hari)

```
rfr = RandomForestRegressor(bootstrap= True,
    max_depth= 110,
    max_features= 2,
    min_samples_leaf=3,
    min_samples_split= 10,
    n_estimators= 200)
```

Lampiran 9. Source Code Pembangunan Model *Multiple Layer Perceptron* (MLP)

Pembangunan Model *Dataset 1* (Citra Satelit Mulisumber dan POI)

```
def build_model():
    model = keras.Sequential([
        keras.layers.Input(shape=(10,)),
        keras.layers.Dense(5, activation=tf.nn.relu),
        keras.layers.Dense(3, activation=tf.nn.relu),
        keras.layers.Dense(2, activation=tf.nn.relu),
        keras.layers.Dense(1)
    ], name="MLP_model")

    optimizer = keras.optimizers.Adam(learning_rate=0.01)

    model.compile(loss='mae',
                  optimizer=optimizer,
                  metrics=['mae'])
    return model

model = build_model()
model.summary()
```

Pembangunan Model *Dataset 2* (Citra Satelit Siang dan Malam Hari)

```
def build_model():
    model = keras.Sequential([
        keras.layers.Input(shape=(512,)),
        keras.layers.Dense(64, activation=tf.nn.relu),
        keras.layers.Dense(32, activation=tf.nn.relu),
        keras.layers.Dense(8, activation=tf.nn.relu),
        keras.layers.Dense(1)
    ], name="MLP_model")

    optimizer = keras.optimizers.Adam(learning_rate=0.01)

    model.compile(loss='mae',
                  optimizer=optimizer,
                  metrics=['mae'])
    return model
```

```
model = build_model()
```

Lampiran 10. Source Code Pembangunan Model *Convolutional Neural Network – 1D (CNN-1D)*

Pembangunan Model *Dataset 1* (Citra Satelit Mulisumber dan POI)

```
def build_conv1D_model():

    n_timesteps = data_x.shape[1]
    n_features = data_x.shape[2]
    model = keras.Sequential(name="model_conv1D")
    model.add(keras.layers.Input(shape=(n_timesteps,n_features)))
    model.add(keras.layers.Conv1D(filters=64, kernel_size=7, activation='relu', name="Conv1D_1"))
    model.add(keras.layers.Dropout(0.5))
    model.add(keras.layers.Conv1D(filters=32, kernel_size=3, activation='relu', name="Conv1D_2"))
    model.add(keras.layers.Conv1D(filters=16, kernel_size=2, activation='relu', name="Conv1D_3"))
    model.add(keras.layers.MaxPooling1D(pool_size=1, name="MaxPooling1D"))
    model.add(keras.layers.Flatten())
    model.add(keras.layers.Dense(32, activation='relu', name="Dense_1"))

    model.add(keras.layers.Dense(n_features, name="Dense_2"))

    optimizer = keras.optimizers.Adam(learning_rate=0.01)

    model.compile(loss='mae',optimizer=optimizer,metrics=['mae'])
    return model

model = build_conv1D_model()
```

Pembangunan Model *Dataset 2* (Citra Satelit Siang dan Malam Hari)

```
def build_conv1D_model():

    n_timesteps = data_x.shape[1]
    n_features = data_x.shape[2]
    model = keras.Sequential(name="model_conv1D")
    model.add(keras.layers.Input(shape=(n_timesteps,n_features)))
    model.add(keras.layers.Conv1D(filters=32, kernel_size=7, activation='relu', name="Conv1D_1"))
```

```
    model.add(keras.layers.MaxPooling1D(pool_size=1, name="MaxP
ooling_1"))
    model.add(keras.layers.Conv1D(filters=16, kernel_size=3, ac
tivation='relu', name="Conv1D_2"))
    model.add(keras.layers.MaxPooling1D(pool_size=1, name="MaxP
ooling_2"))
    model.add(keras.layers.Conv1D(filters=8, kernel_size=2, ac
tivation='relu', name="Conv1D_3"))
    model.add(keras.layers.MaxPooling1D(pool_size=1, name="MaxP
ooling_3"))
    model.add(keras.layers.Flatten())
    model.add(keras.layers.Dense(n_features, name="Dense_2"))
    model.add(keras.layers.Dropout(0.5))

    optimizer = keras.optimizers.Adam(learning_rate=0.01)

    model.compile(loss='mae', optimizer=optimizer, metrics=[ 'mae'
])
    return model

model = build_conv1D_model()
model.summary()
```

RIWAYAT HIDUP

Penulis lahir di Tulungagung, Jawa Timur pada tanggal 12 November 2000 dan tumbuh dewasa di Sidoarjo, Jawa Timur. Pada tahun 2012 penulis menyelesaikan pendidikan sekolah dasar di SD Hang Tuah 10 Juanda dan melanjutkan pendidikan menengah pertama di SMPN 1 Sedati sampai tahun 2015. Penulis menamatkan pendidikan menengah atas di SMAN 1 Sidoarjo pada tahun 2018. Pada tahun 2018 penulis mendapatkan kesempatan untuk melanjutkan pendidikan di Politeknik Statistika STIS khususnya program studi D-IV Komputasi Statistik. Akhirnya pada tahun keempat (tahun 2022) atas berkat dan rahmat Allah SWT serta dukungan orang-orang terdekat penulis berhasil menyelesaikan pendidikan di Politeknik Statistika STIS.